

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

**CẢI THIẾN DỰ ĐOÁN NGUY CƠ ĐỘT QUỴ BẰNG
CÁCH TÍCH HỢP XGBOOST, PHÂN TÍCH THÀNH
PHẦN CHÍNH TỐI ƯU VÀ TRÍ TUỆ NHÂN TẠO
GIẢI THÍCH ĐƯỢC**

Học phần: HỌC MÁY VÀ KHAI PHÁ DỮ LIỆU

Giảng viên hướng dẫn: TRẦN TRỌNG HIẾU

Học viên thực hiện:

1. TỔNG VIỆT TÚ - Mã học viên: 25007845
2. NGUYỄN THỊ NHẬT LINH - Mã học viên:
25007871

HÀ NỘI - 09/2026

THÔNG TIN BÀI BÁO GỐC

Tên bài báo: Improving stroke risk prediction by integrating XGBoost, optimized principal component analysis, and explainable artificial intelligence.

Tác giả: Lesia Mochurad, Viktoriia Babii, Yuliia Boliubash và Yulianna Mochurad.

Tạp chí: BMC Medical Informatics and Decision Making (2025) 25:63.

DOI: <https://doi.org/10.1186/s12911-025-02894-z>.

Nguồn dữ liệu:

- <https://www.kaggle.com/fedesoriano/stroke-prediction-dataset>
- <https://www.kaggle.com/datasets/pranavp1999/stroke-prediction-health-care-synthetic-dataset>

GIỚI THIỆU BÁO CÁO

Báo cáo này được thực hiện trong khuôn khổ học phần Khai phá dữ liệu, với mục tiêu tìm hiểu và trình bày lại một công trình nghiên cứu ứng dụng học máy trong lĩnh vực y tế — cụ thể là bài toán dự đoán nguy cơ đột quy.

Lý do lựa chọn bài báo: đây là một nghiên cứu tích hợp đồng thời ba kỹ thuật đã được giới thiệu trong học phần: (1) thuật toán học máy có giám sát mạnh (XGBoost), (2) kỹ thuật giảm chiều dữ liệu (PCA), và (3) trí tuệ nhân tạo giải thích được (XAI, cụ thể là SHAP). Việc bài báo kết hợp cả ba khía cạnh này trong một quy trình xử lý dữ liệu y tế thực tế giúp minh họa rõ mối liên hệ giữa lý thuyết khai phá dữ liệu và một ứng dụng có ý nghĩa thực tiễn cao.

Mục tiêu của báo cáo:

- Trình bày lại có hệ thống nội dung bài báo gốc bằng tiếng Việt, bám sát cấu trúc: bối cảnh – phương pháp – kết quả – thảo luận – kết luận.
- Diễn giải các công thức và thuật toán then chốt (PCA bằng phép quay Jacobi song song hóa OpenMP, hàm mục tiêu XGBoost, phương pháp SHAP) theo cách dễ tiếp cận.
- Tự xây dựng và chạy lại pipeline thực nghiệm nhằm tái lập các kết quả mà tác giả công bố trên hai bộ dữ liệu.
- Đối chiếu có kiểm soát giữa kết quả tác giả và kết quả tái hiện của nhóm, từ đó xác định các thành phần của pipeline cần hiệu chỉnh để tiến gần kết quả gốc.
- Sau khi thiết lập được baseline tái hiện phù hợp, khảo sát các

hướng cải tiến và đánh giá liệu chúng có tạo ra lợi ích thực nghiệm so với phương pháp của tác giả hay không.

Phạm vi báo cáo: báo cáo phân biệt rõ ba lớp nội dung: (i) nội dung và kết quả được công bố trong bài báo gốc; (ii) kết quả tái hiện độc lập của nhóm; và (iii) các thử nghiệm cải tiến do nhóm đề xuất. Các kết quả của nhóm được ghi rõ nguồn thực nghiệm và chỉ được so sánh trực tiếp với tác giả khi sử dụng cùng định nghĩa chỉ số và giao thức đánh giá tương ứng.

TÓM TẮT

Tính cấp thiết của nghiên cứu xuất phát từ số lượng ngày càng tăng các bệnh của hệ mạch máu não, đặc biệt là đột quy, một trong những nguyên nhân hàng đầu gây tàn tật và tử vong trên thế giới. Để cải thiện các mô hình dự đoán nguy cơ đột quy về cả hiệu quả và khả năng diễn giải, chúng tôi đề xuất tích hợp các thuật toán học máy hiện đại với các phương pháp giảm chiều dữ liệu, cụ thể là XGBoost và phân tích thành phần chính (PCA) được tối ưu hóa, qua đó cấu trúc dữ liệu và tăng tốc độ xử lý, đặc biệt đối với các tập dữ liệu lớn. Lần đầu tiên, trí tuệ nhân tạo giải thích được (XAI) được tích hợp vào quá trình PCA, làm tăng tính minh bạch và khả năng diễn giải, giúp các chuyên gia y tế hiểu rõ hơn các yếu tố nguy cơ. Phương pháp đề xuất được kiểm thử trên hai tập dữ liệu, đạt độ chính xác lần lượt là 95% và 98%. Kiểm định chéo cho giá trị trung bình 0,99; các giá trị cao của hệ số tương quan Matthews (MCC) là 0,96 và Cohen's Kappa (CK) là 0,96 xác nhận khả năng khái quát hóa và độ tin cậy của mô hình. Tốc độ xử lý tăng gấp ba lần nhờ song song hóa OpenMP, tạo khả năng áp dụng trong thực tế. Do đó, phương pháp đề xuất có tính đổi mới và có tiềm năng cải thiện các hệ thống dự báo trong ngành chăm sóc sức khỏe.

Từ khóa: Học máy, công nghệ tính toán song song, phương pháp SHAP, cân bằng lớp, phương pháp PCA.

Mục lục

THÔNG TIN BÀI BÁO GỐC	i
GIỚI THIỆU BÁO CÁO	ii
TÓM TẮT	iv
MỤC LỤC	v
DANH MỤC CÁC CHỮ VIẾT TẮT	vii
DANH MỤC HÌNH VẼ	ix
DANH MỤC BẢNG BIỂU	xi
1 BỐI CẢNH	1
2 PHƯƠNG PHÁP	12
3 KẾT QUẢ	18
4 THẢO LUẬN	35
5 TÁI HIỆN KẾT QUẢ VÀ ĐỊNH HƯỚNG CẢI TIẾN	38
5.1 Đọc lại giao thức và kết quả công bố của tác giả	38
5.1.1 Ý nghĩa của các bảng so sánh trong bài báo . . .	38
5.1.2 Những thành phần có thể và chưa thể tái dựng chính xác	39
5.2 Giao thức tái hiện của nhóm	40
5.2.1 Nguyên tắc đánh giá	40
5.2.2 Số mẫu trước và sau balancing	41
5.3 Tái hiện kết quả theo dạng classification report	42

5.3.1 Dataset 1	42
5.3.2 Dataset 2	44
5.4 Diễn biến kết quả qua các bước xây dựng pipeline . . .	44
5.5 Ablation: balancing, PCA và tuning	46
5.6 Mở rộng/cải tiến trên cùng giao thức đánh giá	47
5.6.1 Dataset 1: SMOTE, SMOTENC và cost-sensitive learning	47
5.6.2 Dataset 2: undersampling và cost-sensitive learning	48
5.7 Tổng hợp: tái hiện và cải tiến trên cùng test set	49
5.8 Hạn chế và hướng cải tiến tiếp theo	50
5.9 Thử nghiệm mở rộng với các mô hình và cơ chế học cho dữ liệu mất cân bằng	51
5.9.1 Giao thức thực nghiệm mở rộng	51
5.9.2 Dataset 1: so sánh các họ mô hình mới	52
5.9.3 Dataset 2: class weighting so với data-level balancing	53
5.9.4 Đúc kết từ thử nghiệm mở rộng	54
KẾT LUẬN	55
TÀI LIỆU THAM KHẢO	58

DANH MỤC CÁC CHỮ VIẾT TẮT

Chữ viết tắt	Nội dung
AI	Trí tuệ nhân tạo (Artificial Intelligence)
ANN	Mạng nơ-ron nhân tạo (Artificial Neural Network)
CK	Hệ số Cohen's Kappa
CNN	Mạng nơ-ron tích chập (Convolutional Neural Network)
EDA	Phân tích dữ liệu khám phá (Exploratory Data Analysis)
IQR	Khoảng tứ phân vị (Interquartile Range)
k-NN	K láng giềng gần nhất (k-Nearest Neighbors)
LIME	Local Interpretable Model-agnostic Explanations
LSTM	Long Short-Term Memory
MCC	Hệ số tương quan Matthews (Matthews Correlation Coefficient)
OpenMP	Open Multi-Processing
PCA	Phân tích thành phần chính (Principal Component Analysis)
ROC-AUC	Diện tích dưới đường cong ROC
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SVM	Máy vector hỗ trợ (Support Vector Machine)
XAI	Trí tuệ nhân tạo giải thích được (Explainable Artificial Intelligence)

XGBoost

Extreme Gradient Boosting

Danh sách hình vẽ

2.1	Sơ đồ luồng của phương pháp đề xuất.	15
3.1	Ma trận hiệp phương sai (Dataset 1).	20
3.2	Phương sai tích lũy theo thành phần cho Dataset 1. . .	21
3.3	Tỷ lệ phương sai được giải thích bởi từng thành phần cho Dataset 1.	21
3.4	Trọng số đặc trưng trong thành phần chính thứ nhất cho Dataset 1.	22
3.5	Trọng số đặc trưng trong thành phần chính thứ hai cho Dataset 1.	23
3.6	SHAP Waterfall cho mẫu dữ liệu đầu tiên (Dataset 1). .	24
3.7	SHAP Bar (Dataset 1).	25
3.8	SHAP Beeswarm (Dataset 1).	26
3.9	Ma trận nhầm lẫn (Dataset 1).	27
3.10	Đường cong ROC-AUC (Dataset 1).	28
3.11	Ma trận nhầm lẫn (Dataset 2, có PCA).	30
3.12	Đường cong ROC-AUC (Dataset 2, có PCA).	30
3.13	Ma trận nhầm lẫn (Dataset 2, không PCA).	31
3.14	Đường cong ROC-AUC (Dataset 2, không PCA).	31
3.15	Phương sai tích lũy theo thành phần cho Dataset 2. . .	32
3.16	Tỷ lệ phương sai được giải thích bởi từng thành phần cho Dataset 2.	32
3.17	SHAP Waterfall cho mẫu dữ liệu đầu tiên (Dataset 2). .	33
3.18	SHAP Bar (Dataset 2).	33
3.19	SHAP Beeswarm (Dataset 2).	34

5.1	Quy trình đánh giá được sử dụng trong các thí nghiệm của nhóm.	41
5.2	Diễn biến hiệu năng qua các bước xây dựng pipeline trên Dataset 1.	46
5.3	Diễn biến hiệu năng qua các bước xây dựng pipeline trên Dataset 2.	46

Danh sách bảng

1.1 So sánh các phương pháp học máy hiện có cho dự đoán đột quy	4
3.1 Thời gian thực thi của thuật toán quay Jacobi dựa trên OpenMP cho Dataset 1	19
3.2 Ảnh hưởng của OpenMP đến thời gian tính toán (giây) đối với các ma trận có kích thước khác nhau	20
3.3 Thời gian thực thi các giai đoạn khác nhau của thuật toán đề xuất	26
3.4 So sánh kết quả thu được với kết quả hiện có	27
3.5 Kết quả kiểm định chéo 10 fold (Dataset 1)	28
3.6 So sánh kết quả thu được khi không dùng và khi dùng PCA	28
3.7 p -value của các kiểm định thống kê	29
4.1 So sánh các phương pháp dự đoán và kết quả trong nghiên cứu của chúng tôi với các nghiên cứu khác	35
4.2 Kết quả kiểm định chéo và các chỉ số hiệu năng bổ sung	36
5.1 Đọc lại support trong Table 5 và Table 7 của tác giả . .	39
5.2 Những thành phần có thể và chưa thể tái dựng chính xác từ bài báo	40
5.3 Số mẫu trong giao thức của nhóm trước và sau balancing	41
5.4 Dataset 1: classification report của nhóm trên test giữ nguyên phân bố	42
5.5 Dataset 1: đối chiếu Table 5 với kết quả tái hiện và cải tiến của nhóm	43

5.6 Dataset 2: classification report của nhóm trên test giữ nguyên phân bố	44
5.7 Diễn biến kết quả qua các bước xây dựng pipeline trên test giữ nguyên phân bố lớp	45
5.8 Dataset 1: các phương pháp xử lý mất cân bằng tại ngưỡng 0,5	47
5.9 Dataset 1: các điểm vận hành được lựa chọn từ validation	48
5.10 Dataset 2: các phương pháp xử lý mất cân bằng tại ngưỡng 0,5	48
5.11 Tổng hợp baseline tái hiện và phương án cải tiến của nhóm trên cùng test set	49
5.12 Dataset 1: kết quả các phương pháp mở rộng trên cùng outer test	52
5.13 Dataset 2: so sánh XGBoost cải tiến và LightGBM weighted trên full data	53

Chương 1

BỐI CẢNH

Đột quỵ vẫn là một trong những nguyên nhân hàng đầu gây tử vong và tàn tật trên toàn thế giới. Tỷ lệ đột quỵ gia tăng đòi hỏi các chiến lược phòng ngừa hiệu quả và chẩn đoán kịp thời. Việc sử dụng các công nghệ tiên tiến như học máy [1–3] có thể cải thiện đáng kể dự đoán nguy cơ và khả năng nhận diện sớm những bệnh nhân cần được chăm sóc. Hiểu được cơ chế của các rối loạn mạch máu não là chìa khóa để phát triển các chiến lược phòng ngừa và điều trị đột quỵ hiệu quả, qua đó giảm thiểu hậu quả của bệnh và cải thiện chất lượng cuộc sống của bệnh nhân.

Việc sử dụng trí tuệ nhân tạo trong bối cảnh này mở ra những triển vọng mới để cải thiện thực hành y khoa. Tích hợp các mô hình học máy như XGBoost hoặc mạng nơ-ron cho phép dự đoán chính xác nguy cơ đột quỵ dựa trên các đặc trưng riêng của từng bệnh nhân [4,5]. Điều này bao gồm cả các yếu tố nguy cơ truyền thống lẫn các tham số mới được xác định thông qua phân tích lượng dữ liệu lớn. Nhờ đó, các chuyên gia y tế có thể đánh giá nguy cơ và triển khai các biện pháp phòng ngừa kịp thời hiệu quả hơn. Các thuật toán học máy như XGBoost thể hiện mức độ chính xác cao khi giải quyết những bài toán phức tạp, bao gồm cả dự báo y khoa. Việc tối ưu các thuật toán này cho những mục tiêu cụ thể, trong đó có dự đoán nguy cơ đột quỵ, là một bước quan trọng để nâng cao hiệu quả của các quyết định y tế.

Giảm tác động của các bất thường và nhiễu trong dữ liệu là một bước then chốt trong xử lý dữ liệu, bởi chất lượng dữ liệu ảnh

hưởng trực tiếp đến độ chính xác và độ tin cậy của mô hình học máy. Các bất thường như ngoại lệ hoặc dữ liệu sai có thể làm sai lệch đáng kể kết quả phân tích, dẫn đến các kết luận không chính xác hoặc thậm chí các khuyến nghị có hại [6]. Phân tích thành phần chính (PCA) giúp xác định và loại bỏ các bất thường này bằng cách tập trung vào những đặc trưng chính và giàu thông tin nhất của tập dữ liệu [7,8]. Điều này không chỉ cải thiện chất lượng dữ liệu mà còn nâng cao độ tin cậy của kết quả, bởi các mô hình được huấn luyện trên dữ liệu đã làm sạch có thể đưa ra dự báo chính xác và ổn định hơn.

Ngoài ra, PCA làm giảm độ phức tạp của mô hình, điều đặc biệt quan trọng trong các ứng dụng y khoa nơi các quyết định có thể ảnh hưởng đến sức khỏe bệnh nhân [9]. Bằng cách giảm số lượng biến cần phân tích, PCA đơn giản hóa quá trình huấn luyện mô hình và dẫn đến xử lý dữ liệu nhanh hơn. Sự đơn giản của các mô hình sau khi áp dụng PCA khiến chúng dễ hiểu và dễ diễn giải hơn đối với các chuyên gia y tế vốn có thể không có kiến thức chuyên sâu về thống kê hay học máy. Điều này quan trọng vì bác sĩ và nhân viên lâm sàng cần hiểu cách thức và lý do một dự báo cụ thể được đưa ra trước khi sử dụng trong thực hành. Hơn nữa, giảm số lượng biến giúp tránh quá tải thông tin, từ đó nâng cao khả năng hiểu các yếu tố nguy cơ nền tảng. Khi nhà cung cấp dịch vụ y tế có thể tập trung vào một số ít biến then chốt, họ sẽ dễ đưa ra quyết định điều trị và phòng ngừa có cơ sở hơn. Vì vậy, PCA không chỉ cải thiện chất lượng dữ liệu mà còn khiến dữ liệu dễ tiếp cận và dễ hiểu hơn đối với các chuyên gia, qua đó có thể tác động tích cực đến kết quả điều trị của bệnh nhân. Nhìn chung, ứng dụng PCA trong nghiên cứu và thực hành y khoa là một bước quan trọng hướng tới tối ưu hóa quá trình

ra quyết định và tăng hiệu quả của can thiệp y tế.

Tuy nhiên, thuật toán tuần tự ở giai đoạn tiền xử lý có thể tiêu tốn nhiều thời gian do độ phức tạp tính toán cao, bởi PCA truyền thống đòi hỏi tài nguyên đáng kể để tính các trị riêng và vector riêng của ma trận hiệp phương sai, đặc biệt nghiêm trọng đối với các tập dữ liệu lớn. Khi quá trình xử lý chỉ diễn ra trên một lõi CPU, tài nguyên tính toán sẵn có không được tận dụng, dẫn đến độ trễ. Bên cạnh đó, các bước xử lý bổ sung như làm sạch và chuẩn hóa dữ liệu cũng được thực hiện đơn luồng, làm tăng thời gian chạy hơn nữa. Ngay cả một mức tăng nhỏ về thời gian tại bước PCA cũng có thể tích lũy khi xử lý lượng dữ liệu lớn, biến thuật toán tuần tự thành nút thắt cổ chai trong quy trình mà tốc độ và hiệu quả là cực kỳ quan trọng. Vì vậy, trong nghiên cứu này, chúng tôi đề xuất sử dụng các công nghệ tính toán song song hiện đại, cụ thể là OpenMP, cho phép áp dụng phương pháp đề xuất trên bất kỳ hệ thống máy tính đa lõi nào [10–12]. Điều này sẽ tăng hiệu quả xử lý dữ liệu nhờ tối ưu hóa việc sử dụng tài nguyên tính toán, từ đó giảm thời gian thực thi thuật toán và nâng cao hiệu năng.

Việc áp dụng PCA có thể vẫn là một “hộp đen”, gây khó khăn cho việc diễn giải và hiểu những yếu tố nào đã đóng góp vào quá trình giảm chiều dữ liệu. Điều này có thể làm giảm niềm tin của các chuyên gia y tế và nhà nghiên cứu đối với mô hình, vì họ có thể không hiểu tại sao một số đặc trưng lại tác động đến kết quả mạnh hơn các đặc trưng khác. Vì vậy, cần tăng cường bước này bằng các kỹ thuật XAI [13], giúp xác định những đặc trưng có ảnh hưởng lớn nhất đến kết quả PCA, nhờ đó các nhà nghiên cứu và chuyên gia y tế hiểu rõ hơn cách các đặc tính cụ thể của dữ liệu hình thành kết quả phân tích. Tương tự nghiên cứu [14] đề xuất một cách tiếp cận để

tăng cường bảo mật điện toán đám mây bằng cách phân tích hành vi người dùng và đánh giá độ tin cậy của họ, chúng tôi sử dụng các phương pháp trí tuệ nhân tạo giải thích được nhằm cải thiện khả năng diễn giải và tính minh bạch của các mô hình dự đoán nguy cơ đột quỵ.

Dự đoán đột quỵ là một khía cạnh quan trọng của y học, bởi chẩn đoán kịp thời có thể làm giảm đáng kể hậu quả của bệnh và cải thiện chất lượng cuộc sống của bệnh nhân. Nhiều phương pháp học máy khác nhau được sử dụng trong nghiên cứu khoa học, mỗi phương pháp có ưu điểm và nhược điểm riêng. Bảng 1.1 trình bày so sánh các phương pháp học máy hiện có cho dự đoán đột quỵ.

Bảng 1.1. So sánh các phương pháp học máy hiện có cho dự đoán đột quỵ

Phương pháp	Mô tả	Ưu điểm	Nhược điểm
Hồi quy Logistic	Mô hình hóa xác suất đột quỵ dựa trên các yếu tố nguy cơ. Sử dụng hàm sigmoid và gradient descent để xây dựng mô hình. Đánh giá hiệu năng mô hình khi có và không có regularization.	Độ chính xác cao (trên 95%), có thể cải thiện thông qua regularization và dễ triển khai.	Độ chính xác hạn chế khi quan hệ phi tuyến; nhạy với lựa chọn tham số.

Phương pháp	Mô tả	Ưu điểm	Nhược điểm
Cây quyết định	Một tập các cây quyết định được huấn luyện trên các tập con dữ liệu khác nhau, sử dụng biểu quyết để đưa ra quyết định cuối cùng.	Trực quan hóa quyết định, dễ diễn giải.	Có xu hướng overfitting nếu không regularization.
Random Forest	Tổng hợp kết quả từ nhiều cây quyết định, làm giảm nguy cơ overfitting.	Độ chính xác cao (96%), độ tin cậy tốt.	Có thể chậm trên các tập dữ liệu lớn.
Naive Bayes	Phân loại dựa trên giả định các đặc trưng độc lập.	Đơn giản, hiệu quả trong nhiều bài toán phân loại.	Độ chính xác đạt 82%; hạn chế khi tồn tại quan hệ phức tạp giữa các đặc trưng.
k -láng giềng gần nhất (k-NN)	Phân loại các quan sát mới dựa trên các láng giềng gần nhất trong tập huấn luyện.	Đơn giản và rõ ràng.	Khó mở rộng, nhạy với lựa chọn tham số k .

Phương pháp	Mô tả	Ưu điểm	Nhược điểm
Máy vector hỗ trợ (SVM)	Sử dụng các hàm kernel để xử lý phân bố phi tuyến.	Hiệu quả cao trên dữ liệu nhiều chiều.	Nhạy với lựa chọn tham số, gặp khó khăn với tập dữ liệu lớn.
Học sâu	Sử dụng mạng nơ-ron tích chập (CNN) để phân tích ảnh y khoa.	Độ chính xác cao trong phát hiện các mẫu phức tạp.	Đòi hỏi tập dữ liệu lớn và tài nguyên tính toán mạnh.
Mạng nơ-ron nhân tạo (ANN)	Mô hình học máy sử dụng resampling, tránh rò rỉ dữ liệu, lựa chọn đặc trưng và các kỹ thuật diễn giải như permutation importance và LIME để dự đoán đột quy.	Khả năng diễn giải cao với LIME, resampling và lựa chọn đặc trưng hiệu quả; độ chính xác dự báo cao (95%).	Phụ thuộc vào kiểm định trên tập dữ liệu bên ngoài và cần tối ưu liên tục để đạt hiệu năng tốt hơn.
XGBoost	Thuật toán tăng cường gradient kết hợp nhiều phương pháp để đạt kết quả tốt hơn.	Hiệu quả dự báo và khả năng diễn giải cao; độ chính xác trên 97%.	Khó cấu hình tham số, yêu cầu tài nguyên tính toán.

Chúng tôi bổ sung phân tích trên bằng mô tả chi tiết hơn về các bài báo được khảo sát. Cụ thể, công trình [15] so sánh các thuật

toán như hồi quy logistic, phân loại cây quyết định, random forest và voting classifier. Kết quả cho thấy random forest đạt độ chính xác cao nhất, khoảng 96%, khi sử dụng một tập dữ liệu mở để dự đoán đột quỵ. Điều này nhấn mạnh tiềm năng của học máy trong cải thiện chẩn đoán y khoa.

Nghiên cứu [16] bổ sung cho các kết quả trên bằng việc đánh giá hiệu quả của các thuật toán phân loại, đặc biệt là Naive Bayes, đạt độ chính xác khoảng 82%. Tuy nhiên, cần lưu ý một số hạn chế như dữ liệu bị giới hạn ở một khu vực địa lý duy nhất. Những yếu tố này có thể hạn chế khả năng khái quát hóa kết quả. Đồng thời, độ nhạy cao của mô hình đối với tính không đồng nhất và dữ liệu thiếu đặt ra nghi vấn về độ chính xác của chúng.

Sự cải tiến của các phương pháp dự báo được nhấn mạnh trong các nghiên cứu [17] và [18], tập trung vào stacking và lựa chọn đặc trưng tự động. Nghiên cứu [17] cho thấy phương pháp stacking vượt trội hơn các thuật toán khác, đạt AUC 98,9%. Trong bối cảnh đó, nghiên cứu [18] tập trung vào lựa chọn tham số và nhấn mạnh tầm quan trọng của dữ liệu chất lượng cao để đạt kết quả tốt.

Tầm quan trọng của độ chính xác và độ tin cậy của mô hình tiếp tục được nhấn mạnh trong các nghiên cứu [19] và [20], nơi việc sử dụng XGBoost đạt độ chính xác 97,56% và AUC 0,8595 tương ứng. Điều này cho thấy tiềm năng áp dụng lâm sàng của các mô hình này cho dự đoán nguy cơ đột quỵ ở cấp cá nhân. Các kết quả như vậy mở ra cơ hội phát triển thêm các mô hình tích hợp nhiều loại dữ liệu bệnh nhân.

Công trình [21] mô tả việc sử dụng XGBoost để dự đoán sự xuất hiện của bệnh. Mô hình được huấn luyện và kiểm định kỹ lưỡng bằng chiến lược chia tập dữ liệu huấn luyện, đạt kết quả rất tốt trên

nhiều thước đo hiệu năng. Mô hình có độ chính xác cao (97%) trong dự đoán trường hợp không bị đột quỵ, nghĩa là dự đoán đúng bệnh nhân không bị đột quỵ trong 97% trường hợp. Tuy nhiên, độ chính xác khi dự đoán đột quỵ (20%) thấp hơn nhiều, tức mô hình chỉ dự đoán đúng trường hợp đột quỵ khoảng 20% thời gian. Công trình này cũng gặp dữ liệu thiếu ở biến “bmi”, nhấn mạnh tầm quan trọng của các phương pháp xử lý missing hiệu quả trong các bài toán dự báo y tế. Nghiên cứu tương lai có thể tập trung cải thiện mô hình, khảo sát các chiến lược cân bằng lớp khác nhau và bổ sung dữ liệu bệnh nhân nhằm nâng cao độ chính xác và độ đầy đủ của dự báo đột quỵ.

Công trình [22] phân tích nhiều phương pháp học máy cho dự đoán đột quỵ. Random Forest cho độ chính xác cao nhất khoảng 96%, nhờ khả năng học ensemble giúp giảm overfitting và tăng tính ổn định của mô hình. Các phương pháp này được áp dụng trên tập dữ liệu gồm các thông số sinh lý của bệnh nhân, cải thiện độ chính xác và độ tin cậy của dự báo. Tuy nhiên, vẫn tồn tại một số nhược điểm, bao gồm kích thước mẫu hạn chế có thể ảnh hưởng đến khả năng khái quát hóa của mô hình học máy. Ngoài ra còn có nguy cơ overtraining khi sử dụng một tập đặc trưng quá hẹp, có thể làm giảm hiệu quả trên dữ liệu đa dạng hơn.

Công trình [23] nghiên cứu việc sử dụng học sâu, đặc biệt là mạng nơ-ron tích chập (CNN) và mạng bộ nhớ dài-ngắn hạn (LSTM). Mặc dù các phương pháp này thể hiện tiềm năng, kết quả cho thấy các phương pháp học máy truyền thống trong một số trường hợp vẫn vượt học sâu, nhấn mạnh tầm quan trọng của cách tiếp cận kết hợp trong dự báo.

Các tác giả của [24] đề xuất phương pháp dự đoán đột quỵ tim bằng ANN với độ chính xác cao 95% và áp dụng các kỹ thuật XAI

nghư permutation importance và LIME để tăng khả năng diễn giải. Họ cũng sử dụng resampling và lựa chọn đặc trưng để cải thiện hiệu năng. Tuy nhiên, phương pháp của họ không bao gồm giảm chiều dữ liệu như PCA, trong khi trong nghiên cứu của chúng tôi PCA cải thiện độ chính xác và cấu trúc dữ liệu. Ngoài ra, các tác giả không sử dụng tính toán song song như chúng tôi sử dụng OpenMP, vốn giúp tăng tốc đáng kể xử lý trên các tập dữ liệu lớn. Chúng tôi còn tích hợp XAI trực tiếp vào quá trình giảm chiều, làm tăng tính rõ ràng của kết quả đối với chuyên gia y tế bằng cách cung cấp diễn giải tốt hơn về tác động của từng đặc trưng lên mô hình. Do đó, cách tiếp cận của chúng tôi cung cấp giảm chiều sâu hơn và xử lý dữ liệu hiệu quả, tăng khả năng diễn giải và tốc độ mô hình so với [24].

Công trình gần đây nhất [25] trình bày tối ưu XGBoost bằng các phương pháp ensemble và tối ưu Bayes để điều chỉnh siêu tham số. Mặc dù kết quả cho thấy hiệu năng mô hình cao, cách tiếp cận của chúng tôi nhấn mạnh tầm quan trọng của việc tích hợp phương pháp xử lý dữ liệu và cơ chế giải thích nhằm tăng tính minh bạch và độ tin cậy của các mô hình dự báo, vốn quan trọng trong ứng dụng lâm sàng.

Như vậy, tổng quan tài liệu cho thấy tiến bộ đáng kể trong việc sử dụng các thuật toán học máy để dự đoán đột quỵ. Các khía cạnh then chốt gồm chất lượng dữ liệu, phương pháp xử lý missing và cân bằng lớp, những yếu tố có thể cải thiện đáng kể độ chính xác và độ tin cậy của mô hình dự báo. Những thách thức chính vẫn là khả năng diễn giải thấp của mô hình học máy và độ phức tạp khi xử lý các tập dữ liệu y tế lớn có nhiều đặc trưng. Phần lớn phương pháp hiện đại dùng các thuật toán mạnh để cải thiện độ chính xác nhưng chưa quan tâm đầy đủ đến giảm chiều dữ liệu và giải thích

đóng góp của từng đặc trưng vào kết quả cuối cùng, điều rất quan trọng trong ứng dụng lâm sàng. Một khía cạnh thiết yếu khi phân tích tập dữ liệu lớn là tận dụng các công nghệ tính toán song song để đạt hiệu năng tính toán cao hơn. Tầm quan trọng của vấn đề này được nhấn mạnh trong [26,27]. Trong nghiên cứu này, chúng tôi đề xuất triển khai OpenMP phù hợp với vai trò ngày càng lớn của các kiến trúc máy tính đa lõi hiện đại.

Nghiên cứu này nhằm cải thiện quá trình dự đoán nguy cơ đột quỵ bằng cách tích hợp thuật toán XGBoost với phương pháp PCA tối ưu và triển khai các phương pháp XAI nhằm tăng tính minh bạch và khả năng diễn giải của kết quả phân tích.

Đóng góp chính của phương pháp đề xuất là tích hợp một số công nghệ hiện đại để cải thiện quy trình dự đoán nguy cơ đột quỵ:

- Kết hợp XGBoost, một phương pháp học máy mạnh nổi tiếng về hiệu năng cao trong các bài toán dự báo, với PCA ở giai đoạn tiền xử lý để giảm chiều và cải thiện cấu trúc dữ liệu, qua đó tăng độ chính xác của mô hình.
- Song song hóa PCA bằng công nghệ OpenMP có thể giảm đáng kể thời gian xử lý các tập dữ liệu lớn, điều đặc biệt quan trọng trong các ứng dụng y tế nơi tốc độ ra quyết định có thể mang tính sống còn.
- Tích hợp XAI vào quá trình PCA làm tăng tính minh bạch và khả năng hiểu mô hình, cung cấp diễn giải tốt hơn cho chuyên gia y tế. Điều này giúp tăng niềm tin vào mô hình, đồng thời hỗ trợ phát hiện bất thường và nhiễu trong dữ liệu.

Do đó, tính mới của phương pháp nằm ở việc áp dụng tích hợp các phương pháp học máy, công nghệ tính toán và công cụ giải thích, cho phép tạo ra các mô hình dự báo nguy cơ đột quỵ chính xác hơn,

nhANH hơn và dễ diễn giải hơn, có ý nghĩa lớn đối với sự phát triển của ngành chăm sóc sức khỏe.

Chương 2

PHƯƠNG PHÁP

Giả sử có tập dữ liệu

$$D = \{(x_i, y_i)\}, \quad i = 1, \dots, N,$$

gồm các cặp (x_i, y_i) , trong đó $x_i \in \mathbb{R}^d$ là vector các đặc trưng đầu vào của bệnh nhân, $y_i \in \{0, 1\}$ là biến nhị phân, với 1 biểu thị có đột quy và 0 biểu thị không đột quy; N là số bản ghi và d là số đặc trưng đầu vào. Biến mục tiêu y_i được sử dụng để huấn luyện và kiểm thử mô hình học máy.

Dưới đây chúng tôi mô tả phương pháp đề xuất.

Trước khi xử lý dữ liệu, kiểm tra bản ghi trùng được thực hiện nhằm bảo đảm tính duy nhất của tập dữ liệu và tránh làm sai lệch kết quả mô hình do các mẫu lặp, nhưng không tìm thấy bản ghi trùng. Các giá trị thiếu được khảo sát và chỉ xuất hiện ở cột BMI, sau đó được điền bằng giá trị trung bình. Cách này ngăn mô hình bị ảnh hưởng bởi dữ liệu không đầy đủ, bởi missing có thể gây thiên lệch và kết luận không chính xác nếu không được xử lý phù hợp. Việc điền giá trị trung bình giúp duy trì phân bố của cột và tính nhất quán của dữ liệu. Ngoài ra, kiểm tra ngoại lệ được thực hiện bằng các phương pháp trực quan như boxplot, cùng với phương pháp khoảng tứ phân vị (IQR). Các giá trị nằm ngoài 1,5 lần IQR tính từ các tứ phân vị được xác định là bất thường và được thay bằng giá trị biên tương ứng. Những điều chỉnh này được thực hiện để bảo đảm tính nhất quán của dữ liệu và ngăn các bất thường làm sai lệch kết quả mô hình.

Phân tích dữ liệu khám phá (EDA) [28] được sử dụng để phân

tích sơ bộ và xác định các vấn đề tiềm ẩn, chẳng hạn mất cân bằng lớp và dữ liệu thiếu, có thể ảnh hưởng tiêu cực đến mô hình.

Dữ liệu được tâm hóa bằng cách xây dựng ma trận

$$X_{\text{centered}} = X - \bar{x}, \quad \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i,$$

trong đó $\bar{x}$ là vector giá trị trung bình.

Ma trận hiệp phương sai S được tính như sau:

$$S = \frac{1}{N-1} X_{\text{centered}}^T X_{\text{centered}}.$$

Các trị riêng và vector riêng của ma trận hiệp phương sai S được tính bằng phương pháp Jacobi, được song song hóa bằng OpenMP để tăng tốc:

$$Sv_j = \lambda_j v_j,$$

trong đó λ_j là các trị riêng và v_j là các vector riêng.

Để giảm chiều, k vector riêng lớn nhất V_k được chọn, sau đó dữ liệu được biến đổi thành ma trận đặc trưng mới:

$$X_{\text{reduced}} = X_{\text{centered}} V_k.$$

Ma trận đặc trưng X_{reduced} được đưa vào thuật toán XGBoost. Hàm mục tiêu của mô hình có dạng:

$$L(\theta) = \sum_{i=1}^N \ell(y_i, \hat{y}_i(\theta)) + \Omega(\theta),$$

trong đó

$$\ell(y_i, \hat{y}_i) = -[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

là hàm mất mát logistic, $\hat{y}_i(\theta)$ là dự báo của mô hình, θ là các tham số mô hình và $\Omega(\theta)$ là thành phần regularization.

Để tối ưu hiệu năng mô hình, chúng tôi sử dụng Grid Search để điều chỉnh siêu tham số. Quy trình này tìm kiếm có hệ thống trên

một tập siêu tham số xác định trước nhằm tối thiểu hóa hàm mất mát và cải thiện độ chính xác. Trong trường hợp này, các siêu tham số của XGBoost được điều chỉnh gồm độ sâu cây, learning rate, số lượng cây, gamma (regularization), minimum child weight, tỷ lệ dữ liệu huấn luyện và tỷ lệ đặc trưng. Mô hình được đánh giá bằng ROC-AUC, phù hợp với bài toán phân loại nhị phân và cho biết khả năng phân biệt giữa các lớp. Mục tiêu là tìm sự cân bằng tối ưu giữa độ chính xác huấn luyện và khả năng khái quát hóa, ngăn overfitting trong khi cải thiện hiệu năng mô hình.

Các phương pháp cân bằng sau được sử dụng:


- Undersampling để giảm số lượng mẫu của lớp chiếm ưu thế.
- Oversampling bằng SMOTE (Synthetic Minority Over-sampling Technique) [29] để sinh các mẫu tổng hợp cho lớp ít đại diện hơn.

Để diễn giải dự báo của mô hình, chúng tôi sử dụng phương pháp SHAP [30], ước lượng đóng góp của từng đặc trưng j vào dự báo của từng mẫu i :

$$\text{SHAP}_j(x_i) = \phi_j(x_i),$$

trong đó $\phi_j(x_i)$ là giá trị SHAP thể hiện đóng góp của đặc trưng j vào dự báo cho mẫu i . Ở đây i là chỉ số của các mẫu riêng lẻ trong tập dữ liệu, $i = 1, 2, \dots, N$, và N là số bản ghi; j là chỉ số của các đặc trưng riêng lẻ, $j = 1, 2, \dots, d$, với d là số đặc trưng đầu vào của mỗi bệnh nhân. Trong phân tích của chúng tôi, SHAP được áp dụng cho các đặc trưng gốc chứ không phải các thành phần chính, nhằm duy trì khả năng diễn giải dự báo mô hình theo các biến đầu vào ban đầu.

Hình 2.1 minh họa phương pháp trên. Thuật toán 1 mô tả cách triển khai tìm trị riêng và vector riêng bằng thuật toán quay Jacobi sử dụng OpenMP.



Hình 2.1. Sơ đồ luồng của phương pháp đề xuất.

Thuật toán 1: Tính trị riêng và vector riêng song song

Thuật toán 1 trong bài báo trình bày phép quay Jacobi song song. Ma trận đầu vào được khởi tạo cùng ma trận vector riêng, sau đó lặp cho đến khi hội tụ hoặc đạt số vòng lặp tối đa. Ở mỗi vòng lặp, thuật toán tìm phần tử ngoài đường chéo có trị tuyệt đối lớn nhất, tính góc quay Jacobi, cập nhật ma trận và vector riêng, đồng thời sử dụng các chỉ thị `#pragma omp` để song song hóa những vòng lặp độc lập. Các vùng tới hạn được dùng khi nhiều luồng có khả năng cập nhật chung một biến. Sau hội tụ, các phần tử đường chéo của ma trận chứa các trị riêng và ma trận tích lũy chứa các vector riêng. Phần thuật toán được giữ nguyên về logic như trong bài báo gốc; hình ảnh thuật toán gốc nằm trên cùng trang với Hình 1.

Trong triển khai xử lý song song của thuật toán Jacobi (xem Thuật toán 1), các chỉ thị OpenMP (`#pragma omp`) được sử dụng để song song hóa các giai đoạn chính khi tính trị riêng, nhờ đó

tăng hiệu năng do nhiều luồng có thể được thực thi đồng thời. Các vùng critical được sử dụng để bảo đảm cập nhật an toàn các biến dùng chung có thể bị thay đổi bởi nhiều luồng cùng lúc, ngăn race condition. Ngoài ra, thuật toán kiểm tra hội tụ bằng cách theo dõi ngưỡng chính xác eps, cho phép thoát hiệu quả khỏi vòng lặp khi đạt độ chính xác mong muốn.

Việc lựa chọn phương pháp Jacobi để tính trị riêng và vector riêng xuất phát từ tính phù hợp của nó đối với song song hóa khi làm việc với các tập dữ liệu nhiều chiều, điều đặc biệt liên quan đến các mô hình dự đoán nguy cơ đột quỵ nơi hiệu quả tính toán là yếu tố then chốt. Như được nêu trong bài báo, tính lặp của phương pháp Jacobi và sự phụ thuộc của nó vào các phép biến đổi ma trận khiến nó rất phù hợp với triển khai OpenMP. Điều này cho phép tận dụng hiệu quả các kiến trúc đa lõi hiện đại và tăng tốc đáng kể quá trình tính toán. Ngoài ra, đặc tính hội tụ của thuật toán kết hợp với khả năng xử lý song song của OpenMP giúp chi phí tính toán vẫn hợp lý ngay cả đối với các tập dữ liệu lớn. Mặc dù các phương pháp thay thế như phân rã QR hoặc power iteration cũng có thể hiệu quả, phương pháp Jacobi được chọn vì tính đơn giản và khả năng cân bằng giữa độ chính xác và hiệu năng. Trong nghiên cứu tương lai, chúng tôi dự định xem xét các phương pháp thay thế này và so sánh với Jacobi để xác định cách tiếp cận hiệu quả nhất tùy thuộc vào điều kiện và đặc trưng của từng tập dữ liệu.

Triển khai PCA bằng OpenMP cải thiện đáng kể tốc độ xử lý các tập dữ liệu lớn bằng cách song song hóa các bước then chốt như tính trị riêng và các vector của ma trận hiệp phương sai. Việc thực hiện song song các phép toán như quay Jacobi phân phối tải trên nhiều luồng, làm giảm đáng kể thời gian thực thi. Kiểm tra hội tụ

bằng ngưỡng chính xác eps bảo đảm độ chính xác yêu cầu. OpenMP cho phép sử dụng hiệu quả kiến trúc đa lõi, qua đó giảm thời gian tính toán. Điều này làm cho PCA dựa trên OpenMP đặc biệt hữu ích trong các ứng dụng cần tốc độ và độ chính xác, nhất là y tế và các lĩnh vực nhạy cảm về thời gian.

Như vậy, bài báo trình bày một mô hình dựa trên XGBoost, thực hiện giảm chiều bằng PCA và diễn giải kết quả thông qua SHAP. Mô hình không chỉ đạt độ chính xác cao khi dự đoán nguy cơ đột quỵ mà còn cho phép giải thích quyết định dựa trên đóng góp của từng đặc trưng. Điều này quan trọng đối với thực hành y khoa vì cho phép bác sĩ hiểu các yếu tố khác nhau tác động thế nào đến nguy cơ đột quỵ.

XGBoost được lựa chọn vì độ tin cậy trên các tập dữ liệu mất cân bằng, nơi các trường hợp thuộc lớp thiểu số xuất hiện phổ biến như trong bài toán này. Khả năng regularization của XGBoost giảm overfitting hiệu quả trong khi vẫn duy trì độ chính xác cao trong phân loại nhị phân. Thuật toán phù hợp để xử lý các tập dữ liệu y tế lớn có mẫu phức tạp nhờ tính mở rộng và hiệu quả.

SHAP được sử dụng để diễn giải dự báo mô hình; nó cung cấp cách diễn giải theo các biến có ý nghĩa lâm sàng. Điều này tăng niềm tin và tính hữu dụng, cho phép bác sĩ đưa ra quyết định có cơ sở dựa trên giải thích của mô hình.

PCA thiết yếu đối với việc giảm chiều dữ liệu y tế nhiều chiều, giữ lại thông tin quan trọng nhất đồng thời loại bỏ dư thừa và nhiễu. Điều này tăng hiệu quả tính toán, giảm nguy cơ overfitting và cải thiện hiệu năng dự báo đột quỵ.

Chương 3

KẾT QUẢ

Trong bài báo này, phương pháp đề xuất được kiểm thử trên hai tập dữ liệu: Dataset 1 [31] và Dataset 2 [32]. Dataset 1 gồm 5.110 bản ghi duy nhất với các đặc trưng: id, giới tính, tuổi, tăng huyết áp, bệnh tim mạch, tình trạng hôn nhân (đã kết hôn/chưa kết hôn), loại công việc, nơi cư trú, mức glucose máu, chỉ số khối cơ thể (BMI), tình trạng hút thuốc và thông tin đột quỵ. Trong tổng số bản ghi, 249 trường hợp dương tính với đột quỵ, cho thấy dữ liệu mất cân bằng đáng kể. Để phân tích phân bố quan sát ở từng biến phân loại, các biểu đồ cột được xây dựng; ví dụ với biến “gender”, số quan sát của từng nhóm (nam, nữ, khác) được hiển thị. Dataset 2 gồm 5.769.190 bản ghi và có các thuộc tính tương tự: id, giới tính, tuổi, tăng huyết áp, bệnh tim mạch, tình trạng hôn nhân, loại công việc, nơi cư trú, glucose máu, BMI, tình trạng hút thuốc và chẩn đoán. Cả hai tập được loại bản ghi trùng và kiểm tra giá trị thiếu; missing được điền ở tập thứ nhất và loại bỏ ở tập thứ hai. Ngoại lệ của các thuộc tính số được kiểm tra cùng với cân bằng lớp. Ở Dataset 1, nơi số ca dương tính (lớp thiếu số) nhỏ, SMOTE được áp dụng để tạo các mẫu tổng hợp bằng nội suy giữa các mẫu lớp thiếu số hiện có. Cách tiếp cận này giúp giảm mất cân bằng lớp và giảm thiên lệch về lớp đa số. Ở Dataset 2, nơi lớp đa số có nhiều mẫu hơn và toàn bộ tập dữ liệu rất lớn, random undersampling được sử dụng. Thay vì sinh dữ liệu nhân tạo, chúng tôi giảm lớp đa số xuống bằng kích thước lớp thiếu số, vì bổ sung mẫu nhân tạo không phải lúc nào cũng phản ánh dữ liệu thực tế. Điều này giúp mô hình không overfit vào lớp đa

số và cải thiện hiệu năng trên lớp thiếu số.


Bảng 3.1 trình bày kết quả tìm trị riêng và vector riêng bằng thuật toán quay Jacobi cho Dataset 1. Để tăng hiệu quả tính toán, tính toán song song bằng OpenMP được sử dụng. Ngoài ra, nghiên cứu giảm chiều dữ liệu bằng PCA, giúp giải thích 95% phương sai của dữ liệu.

Bảng 3.1. Thời gian thực thi của thuật toán quay Jacobi dựa trên OpenMP cho Dataset 1

Tham số	Giá trị
Thời gian tính toán không song song, giây	0.0008801
Thời gian tính toán (OpenMP), giây	0.0006494
Số thuộc tính ban đầu	19
Số thuộc tính sau PCA	13
Tỷ lệ phương sai được giải thích, %	95

Thời gian trong Bảng 3.1 không thay đổi đáng kể so với thuật toán tuần tự, được giải thích bởi kích thước nhỏ của ma trận hiệp phương sai (xem Hình 3.1); vì vậy, song song hóa để xuất sẽ hữu ích hơn đối với lượng dữ liệu lớn. Để đánh giá hiệu quả của song song hóa bằng OpenMP, một thí nghiệm được thực hiện với các ma trận có kích thước khác nhau. Để tạo ra khác biệt hiệu năng đủ rõ, các ma trận kích thước 100, 200, 300, 400 và 500 được sinh. Các ma trận được điền giá trị từ 0 đến 1, mô phỏng chuẩn hóa MinMax. Thời gian tính toán được đo và so sánh nhằm đánh giá tác động của song song hóa. Kết quả ở Bảng 3.2 cho thấy ảnh hưởng của OpenMP trong việc giảm thời gian tính toán. Tính toán hiệu quả đặc biệt quan trọng trong y khoa đối với chẩn đoán, dự báo và ra quyết định kịp thời, ảnh hưởng trực tiếp đến sức khỏe và kết quả của bệnh nhân. Hơn nữa, các phương pháp tính toán tiên tiến cho phép xử lý tập dữ

liệu lớn với độ chính xác cao hơn, cải thiện độ chính xác nghiên cứu và tối ưu hóa việc sử dụng tài nguyên.



Hình 3.1. Ma trận hiệp phương sai (Dataset 1).


Bảng 3.2. Ảnh hưởng của OpenMP đến thời gian tính toán (giây) đối với các ma trận có kích thước khác nhau

Phương pháp/Kích thước (N)	100	200	300	400
Có OpenMP	0.5029	5.8377	40.0427	128.957
Không OpenMP	0.5299	7.7465	62.9582	218.853


Việc sử dụng OpenMP tạo ra lợi ích ngay cả đối với các tập dữ liệu nhỏ vì nó làm giảm thời gian xử lý ở các giai đoạn lặp và tối ưu việc sử dụng bộ xử lý đa lõi. Điều này tạo ra một triển khai tổng quát và có khả năng mở rộng, vẫn hiệu quả cả với dữ liệu hiện tại và các tập dữ liệu lớn hơn trong tương lai.

Hình 3.2 thể hiện phương sai tích lũy theo thành phần, cho

thấy phương sai tích lũy như thế nào khi sử dụng phương pháp thành phần chính. Hình 3.3 minh họa tỷ lệ phần trăm phương sai được giải thích bởi từng thành phần, cho phép ước lượng đóng góp của chúng vào tổng phương sai dữ liệu.



Hình 3.2. Phương sai tích lũy theo thành phần cho Dataset 1.




Hình 3.3. Tỷ lệ phương sai được giải thích bởi từng thành phần cho Dataset 1.

Sau khi áp dụng PCA, các thành phần chính được thu được cùng với các hệ số (trọng số) của đặc trưng gốc trong các thành phần mới. Các thành phần chính PCA được hình thành dưới dạng tổ hợp tuyến tính của các đặc trưng gốc, và các trọng số phản ánh


đóng góp của từng đặc trưng gốc vào thành phần chính tương ứng.

Hình 3.4 minh họa trọng số của các đặc trưng trong thành phần chính thứ nhất, còn Hình 3.5 minh họa trọng số trong thành phần chính thứ hai. Phân tích cho thấy thành phần thứ nhất chịu ảnh hưởng đáng kể bởi các đặc trưng như tuổi, `work_type_children` và `smoking_status_Unknown`. Trong khi đó, thành phần thứ hai chịu ảnh hưởng nhiều nhất bởi giới tính và `work_type_self-employed`.



Hình 3.4. Trọng số đặc trưng trong thành phần chính thứ nhất cho Dataset 1.

Các tập dữ liệu y tế có những vấn đề đặc thù như mất cân bằng lớp do tính hiếm của ca bệnh, giá trị thiếu do hồ sơ không đầy đủ và ngoại lệ do sai số đo lường hoặc các tình huống y khoa đặc biệt. Dữ liệu nhiều chiều và nhu cầu diễn giải quyết định của mô hình làm phân tích trở nên khó khăn, đòi hỏi các phương pháp chuyên biệt; nếu không, dự báo có thể không chính xác hoặc sai lệch. Mô




Hình 3.5. Trọng số đặc trưng trong thành phần chính thứ hai cho Dataset 1.

hình của chúng tôi xử lý các vấn đề đặc thù này. Chẳng hạn, mất cân bằng lớp được giải quyết bằng SMOTE và giảm ngẫu nhiên lớp đa số để tránh thiên lệch. Dữ liệu thiếu được điền bằng giá trị trung bình và ngoại lệ được xử lý bằng phương pháp IQR để giảm tác động của nhiễu. PCA giảm chiều trong khi duy trì 95% biến thiên, qua đó tăng tốc tính toán và cải thiện độ chính xác. Ngoài ra, nghiên cứu áp dụng công cụ XAI SHAP, cho phép phân tích chi tiết tác động của phương pháp PCA lên từng trường hợp riêng lẻ trong mẫu.

Hình 3.6 cung cấp phân rã chi tiết ảnh hưởng của từng biến đầu vào lên dự báo cho một mẫu dữ liệu cụ thể. Có thể thấy đóng góp lớn nhất đến từ `work_type_Private` và trạng thái `ever_married`. Ngoài ra, giới tính cũng có ảnh hưởng đáng kể đến dự báo. Tuổi và chỉ số khối cơ thể (BMI) có ảnh hưởng nhỏ hơn so với các đặc trưng khác.


Dấu của trọng số thể hiện hướng tác động của đặc trưng: trọng số âm biểu thị tác động nghịch lên biến mục tiêu (ví dụ, giảm tuổi có thể gắn với tăng giá trị biến mục tiêu), trong khi trọng số dương biểu thị tác động thuận (ví dụ, BMI tăng đi kèm tăng giá trị mục tiêu). Điều này giúp bác sĩ xác định các yếu tố chủ chốt ảnh hưởng đến nguy cơ của bệnh nhân và hiểu hướng tác động của chúng, góp phần cá nhân hóa điều trị, ra quyết định có cơ sở và lập kế hoạch phòng ngừa. Trực quan hóa cũng giúp giải thích hiệu quả cho bệnh nhân cách đặc trưng của họ ảnh hưởng đến tiên lượng.



Hình 3.6. SHAP Waterfall cho mẫu dữ liệu đầu tiên (Dataset 1).

Hình 3.7 trình bày các biến đầu vào được sắp xếp theo giá trị SHAP tuyệt đối trung bình trên toàn bộ tập dữ liệu. Biểu đồ cho thấy tác động của từng đặc trưng lên kết quả. Đóng góp lớn nhất đến từ mức glucose máu trung bình (avg_glucose_level); việc tăng chỉ số này gắn với tăng giá trị biến mục tiêu do mô hình dự báo. Các đặc trưng quan trọng khác gồm work_type_Private, BMI, tuổi và work_type_Govt_job, cũng có tác động đáng kể đến kết quả dự báo.


Biểu đồ Beeswarm (Hình 3.8) là một cách hiển thị giá trị SHAP giàu thông tin, cho thấy không chỉ mức quan trọng tương đối của



Hình 3.7. SHAP Bar (Dataset 1).

đặc trưng mà còn mối quan hệ thực tế của chúng với kết quả dự báo. Mỗi điểm trên biểu đồ đại diện cho một quan sát, màu của điểm thể hiện ảnh hưởng của đặc trưng lên dự báo cho quan sát đó: màu đỏ biểu thị làm tăng giá trị dự báo, màu xanh biểu thị làm giảm. Độ đậm màu phản ánh cường độ ảnh hưởng: màu càng đậm thì tác động càng mạnh. Phân bố các điểm dọc trục X cho thấy ảnh hưởng của một đặc trưng thay đổi theo giá trị của nó như thế nào. Chẳng hạn, mức glucose cao nhìn chung gắn với nguy cơ tăng, và nguy cơ cũng tăng theo tuổi. Đây là thông tin hữu ích để xác định các khía cạnh cần kiểm soát như glucose, BMI hoặc tuổi và cá nhân hóa cách điều trị bệnh nhân. Công cụ này cũng hỗ trợ ưu tiên các biện pháp phòng ngừa.

Bảng 3.3 cho thấy thời gian thực thi các giai đoạn khác nhau của thuật toán đề xuất và so sánh với kết quả của các tác giả trong [21].



Hình 3.8. SHAP Beeswarm (Dataset 1).

Bảng 3.3. Thời gian thực thi các giai đoạn khác nhau của thuật toán đề xuất

Giai đoạn thuật toán	Thời gian thực thi (s)
Tìm trị riêng và vector riêng	6.25×10^{-5}
Tính ma trận hiệp phương sai	0.00260
Huấn luyện mô hình	1.34685
Tổng thời gian thực thi	1.50010
Tổng thời gian của thuật toán trong [21]	4.52611


Như có thể thấy từ Bảng 3.4, tốc độ nhanh hơn hơn 3 lần so với [21]. Trong nghiên cứu này, chúng tôi chia dữ liệu thành 80% để huấn luyện mô hình và 20% để kiểm thử. Sau đó, chúng tôi so sánh các chỉ số định lượng khác về lợi ích đạt được (xem Bảng 3.4). Ở đây, phương pháp của chúng tôi a) là kết quả không cân bằng lớp và b) là kết quả có cân bằng lớp.


Bảng 3.4. So sánh kết quả thu được với kết quả hiện có

	Precision			Recall			F1-score			Support		
	[21]	a)	b)	[21]	a)	b)	[21]	a)	b)	[21]	a)	b)
0	0.97	0.95	0.96	0.87	0.97	0.93	0.92	0.96	0.94	960	960	976
1	0.21	0.24	0.93	0.52	0.15	0.96	0.29	0.18	0.95	62	62	968
accuracy							0.85	0.92	0.95	1022	1022	1944
macro avg	0.59	0.59	0.95	0.69	0.56	0.95	0.61	0.57	0.95	1022	1022	1944
weighted avg	0.92	0.90	0.95	0.85	0.92	0.95	0.88	0.92	0.95	1022	1022	1944

Hiệu năng của mô hình đề xuất được đánh giá toàn diện trên Dataset 1. Ma trận nhầm lẫn (Hình 3.9), đường cong ROC-AUC (Hình 3.10) và kết quả kiểm định chéo 10 fold (Bảng 3.5) cung cấp cái nhìn chi tiết về độ chính xác phân loại và độ vững của phương pháp.

Kết quả được thu trong môi trường Google Colab (bộ xử lý Intel(R) Xeon(R) CPU @ 2.20 GHz). Trong môi trường này, chúng tôi đạt độ chính xác 95%, vượt kết quả được báo cáo trong [21]. Việc tăng độ chính xác đạt được đồng thời với giảm thời gian thực thi nhờ giảm chiều dữ liệu.

**Hình 3.9.** Ma trận nhầm lẫn (Dataset 1).



Hình 3.10. Đường cong ROC-AUC (Dataset 1).

Bảng 3.5. Kết quả kiểm định chéo 10 fold (Dataset 1)

Chỉ số đánh giá	Giá trị
Độ chính xác trung bình	0.9532
Độ chính xác từng fold	0.95344473, 0.95858612, 0.94830334, 0.94830334, 0.94958869, 0.95215938, 0.95851995, 0.94951094, 0.95594595, 0.95723295

Phương pháp đề xuất trong bài báo cũng được kiểm thử trên Dataset 2. Bảng 3.6 trình bày kết quả thu được khi không dùng và khi dùng PCA.

Bảng 3.6. So sánh kết quả thu được khi không dùng và khi dùng PCA

	Precision		Recall		F1-score		Support	
	Không PCA	Có PCA	Không PCA	Có PCA	Không PCA	Có PCA	Không PCA	Có PCA
0	0.98	0.99	0.92	0.97	0.95	0.98	136758	10613
1	0.93	0.97	0.98	0.99	0.96	0.98	137596	10605
accuracy	0.95 / 0.98						274354	21218
macro avg	0.96	0.98	0.95	0.98	0.95	0.98	274354	21218
weighted avg	0.96	0.98	0.95	0.98	0.95	0.98	273454	21218

Các kiểm định ý nghĩa thống kê được thực hiện để xác nhận khác biệt hiệu năng giữa phương pháp dựa trên PCA và baseline không PCA. Hai kiểm định được sử dụng: paired t-test và Mann-Whitney U. Kiểm định đầu tiên phù hợp để so sánh hai mẫu liên quan, chẳng hạn kết quả từ cùng một tập dữ liệu dưới hai phương pháp khác nhau. Mann-Whitney U so sánh phân bố của hai mẫu độc lập và đặc biệt hữu ích khi giả định phân phối chuẩn không thỏa mãn. Kết quả trong Bảng 3.7 cho thấy có khác biệt có ý nghĩa thống kê giữa phương pháp PCA và baseline ($p\text{-value} < 0.05$). Điều này gợi ý rằng bổ sung PCA tạo ra cải thiện có ý nghĩa so với baseline.


Bảng 3.7. p -value của các kiểm định thống kê

Kiểm định	$p\text{-value}$
Paired t-test	$5.475817566209107 \times 10^{-10}$
Mann-Whitney U test	0.0001796225049907081


Hiệu năng của phương pháp đề xuất khi có và không PCA tiếp tục được phân tích bằng ma trận nhầm lẫn và đường cong ROC-AUC. Hình 3.11 trình bày ma trận nhầm lẫn cho Dataset 2 có PCA, trong khi Hình 3.12 cho đường cong ROC-AUC tương ứng. Để so sánh, Hình 3.13 hiển thị ma trận nhầm lẫn cho Dataset 2 không PCA, và Hình 3.14 minh họa ROC-AUC cho cùng tập dữ liệu khi không PCA. Các trực quan này cung cấp so sánh rõ ràng về khác biệt hiệu năng giữa hai cách tiếp cận.

Sau khi sử dụng PCA, số chiều được giảm còn 13 đặc trưng giải thích 95% phương sai. Hình 3.15 và Hình 3.16 lần lượt thể hiện phương sai tích lũy theo thành phần và tỷ lệ phần trăm phương sai được giải thích bởi từng thành phần.

Tương tự Dataset 1, chúng tôi áp dụng các phương pháp trí




Hình 3.11. Ma trận nhầm lẫn (Dataset 2, có PCA).




Hình 3.12. Đường cong ROC-AUC (Dataset 2, có PCA).

tuệ nhân tạo giải thích được. Hình 3.17 minh họa SHAP Waterfall cho mẫu dữ liệu đầu tiên của Dataset 2, thể hiện tác động của các đặc trưng quan trọng lên dự báo mô hình. Đóng góp đáng kể nhất đến từ mức glucose máu: tăng chỉ số này dẫn đến tăng giá trị dự báo của mô hình. Tuổi cũng có ảnh hưởng đáng kể, dù kém rõ hơn glucose. Giới tính nữ có tác động âm, nghĩa là đối với nữ, giá trị dự




Hình 3.13. Ma trận nhầm lẫn (Dataset 2, không PCA).




Hình 3.14. Đường cong ROC-AUC (Dataset 2, không PCA).

báo trung bình thấp hơn nam. Làm việc trong khu vực công và BMI có tác động âm ở mức vừa phải. Các đặc trưng khác cũng ảnh hưởng đến dự báo nhưng nhỏ hơn. Như vậy, mức glucose và tuổi là các biến dự báo chủ chốt trong mô hình, cho thấy chúng có ảnh hưởng quyết định đến kết quả cuối cùng.

Hình 3.18 cho thấy SHAP Bar của Dataset 2. Có thể thấy ảnh




Hình 3.15. Phương sai tích lũy theo thành phần cho Dataset 2.




Hình 3.16. Tỷ lệ phương sai được giải thích bởi từng thành phần cho Dataset 2.

hưởng lớn nhất lên dự báo mô hình trong trường hợp này là tuổi: khi tuổi bệnh nhân tăng, xác suất giá trị dự báo cao hơn cũng tăng. Mức glucose máu cũng có tác động dương đáng kể lên kết quả dự báo. Làm việc trong khu vực tư nhân là một yếu tố dương bổ sung. Cả hai giới (nam và nữ) đều ảnh hưởng đến dự báo, nhưng ảnh hưởng của nữ rõ hơn một chút. Các đặc trưng khác có ít hoặc gần như không có tác động đến kết quả dự báo.

Hình 3.19 một lần nữa cho thấy các yếu tố có ảnh hưởng lớn




Hình 3.17. SHAP Waterfall cho mẫu dữ liệu đầu tiên (Dataset 2).



Hình 3.18. SHAP Bar (Dataset 2).

nhất là tuổi, mức glucose, giới tính, BMI và loại công việc, điều phù hợp với kỳ vọng.

Kết quả nghiên cứu chứng minh hiệu quả của việc tích hợp PCA với XGBoost trong dự đoán nguy cơ đột quỵ. Triển khai PCA được tối ưu làm giảm đáng kể số chiều dữ liệu, từ đó tăng cả tốc độ xử lý và độ chính xác của XGBoost. Việc sử dụng thêm SHAP cho phép xác định các biến gốc quan trọng nhất ảnh hưởng đến kết quả dự báo. Sự tích hợp này đặc biệt có giá trị trong chẩn đoán y khoa,



Hình 3.19. SHAP Beeswarm (Dataset 2).

nơi cả tốc độ lẫn độ chính xác của phân tích đều quan trọng vì liên quan đến tính mạng con người.

Chương 4

THẢO LUẬN

Trong bài báo này, phương pháp đề xuất được kiểm thử trên hai tập dữ liệu. Các kết quả chính đã được mô tả trong phần Kết quả. Để so sánh chi tiết hơn với các công trình hiện có và xác định vị trí của phương pháp đề xuất, chúng tôi bổ sung so sánh với các nghiên cứu liên quan. Cụ thể, Bảng 4.1 so sánh phương pháp của chúng tôi với ba công trình trên Dataset 1.

Bảng 4.1. So sánh các phương pháp dự đoán và kết quả trong nghiên cứu của chúng tôi với các nghiên cứu khác

Thuộc tính	[18]	[33]	[34]	Phương pháp của chúng tôi
Phương pháp	Hồi quy logistic, cây quyết định, random forest, k-NN, SVM, Naive Bayes	Random Forest, XGBoost, hồi quy logistic, nơ-ron	Random Forest, Naive Bayes, hồi quy logistic	XGBoost kết hợp PCA để giảm chiều, SMOTE để cân bằng dữ liệu
Độ chính xác, %	82	92.55	-	95
F1-score	82.3	92.40	80	94.5

Đối với Dataset 2, không xác định được nghiên cứu liên quan, có thể vì tập dữ liệu này mới được công bố gần đây. Vì vậy, hiệu năng mô hình trên Dataset 2 được đánh giá thêm bằng hệ số tương quan Matthews (MCC) và hệ số Cohen's Kappa (CK). MCC là một chỉ số cân bằng để đánh giá chất lượng mô hình phân loại, đặc biệt trên dữ liệu mất cân bằng, bởi nó xét cả bốn phần tử của ma trận lỗi (TP, TN, FP, FN), với giá trị từ -1 (hoàn toàn không phù hợp) đến 1 (phân loại hoàn hảo), trong đó 0 biểu thị dự báo ngẫu nhiên. CK đo mức độ nhất quán giữa dự báo của mô hình và kết quả thực tế, cũng có khoảng giá trị từ -1 đến 1, trong đó giá trị dương biểu thị

mức nhất quán vượt quá ngẫu nhiên. Ngoài ra, kiểm định chéo được thực hiện. Tóm tắt kết quả cross-validation và các chỉ số hiệu năng bổ sung cho Dataset 2 được trình bày trong Bảng 4.2.

Bảng 4.2. Kết quả kiểm định chéo và các chỉ số hiệu năng bổ sung

Chỉ số đánh giá	Giá trị
Điểm cross-validation trung bình	0.99028
Điểm ở từng fold	0.98993, 0.98829, 0.99016, 0.99209, 0.99090, 0.98983, 0.98749, 0.99075, 0.99309, 0.99022
MCC	0.9634
CK	0.9632

Kết quả trong Bảng 4.2 cho thấy chất lượng cao của mô hình. Điểm cross-validation trung bình 0,99028 thể hiện hiệu năng ổn định trên các fold dữ liệu khác nhau. Các giá trị ở từng fold, từ 0,98829 đến 0,99209, cho thấy biến thiên nhỏ, xác nhận độ tin cậy của mô hình. Các giá trị MCC và CK cao chỉ ra mô hình xử lý tốt bài toán phân loại ngay cả khi có khả năng mất cân bằng lớp và tạo ra dự báo tốt hơn đáng kể so với dự báo ngẫu nhiên.

Mặc dù mô hình đề xuất có hiệu quả cao trong dự đoán nguy cơ đột quy, việc triển khai trong môi trường lâm sàng gặp một số thách thức. Những thách thức này gồm tích hợp vào các hệ thống thông tin y tế hiện có với định dạng dữ liệu không đồng nhất, nhu cầu kiểm thử trên các mẫu lâm sàng thực và bảo đảm đáp ứng yêu cầu tốc độ tính toán cho các quyết định tác nghiệp. Những thách thức tương tự được xử lý trong các công trình về phương pháp lai, cụ thể là nghiên cứu sử dụng Harris Hawks Optimization và Cuckoo Search Algorithm để lựa chọn các đặc trưng quan trọng trong dữ liệu sinh học nhiều chiều [35]. Điều này cải thiện độ chính xác và ổn

định của mô hình và hỗ trợ ra quyết định trong thực hành y khoa.

Mặc dù phương pháp đề xuất có một số ưu điểm, nó cũng có những hạn chế. Kết hợp XGBoost với PCA để giảm chiều giúp tăng độ chính xác mô hình, nhưng cách tiếp cận này có thể khó cấu hình, gây khó khăn khi áp dụng cho các tập dữ liệu khác, đặc biệt nếu dữ liệu không có vấn đề nhiều chiều rõ rệt. Bên cạnh đó, tính toán song song qua OpenMP để tăng tốc PCA chỉ mang lại lợi ích đáng kể với các tập dữ liệu lớn, trong khi với tập dữ liệu nhỏ, mức tăng hiệu năng không tỷ lệ thuận với chi phí triển khai công nghệ.

Các thuật toán metaheuristic như Genetic Algorithm, Particle Swarm Optimization và nhiều phương pháp khác đang được sử dụng tích cực để cải thiện phân tích dữ liệu y tế nhiều chiều. Nghiên cứu [36] cho thấy việc tích hợp Random Drift Optimization với XGBoost nâng độ chính xác phân loại dữ liệu ung thư lên 99,14%, vượt các phương pháp truyền thống như SVM và Naive Bayes. Cụ thể, đối với phát hiện sớm ung thư vú, một phương pháp lai kết hợp Harris Hawk Optimization và Whale Optimization với học sâu được trình bày trong [37], đạt độ chính xác phân loại 99,0%, cũng vượt các thuật toán tối ưu truyền thống. Các cách tiếp cận này thể hiện tiềm năng lớn trong cải thiện mô hình y tế bằng cách tăng độ chính xác, khả năng thích nghi và năng lực cung cấp điều trị cá nhân hóa. Ngoài ra, việc áp dụng các phương pháp metaheuristic để lựa chọn gene và cải thiện độ chính xác chẩn đoán trong thực hành y khoa cũng rất quan trọng, như trình bày trong [38], nơi các cách tiếp cận metaheuristic giúp cải thiện lựa chọn đặc trưng và bảo đảm độ chính xác phân loại cao, có thể đóng góp vào phát triển điều trị cá nhân hóa trong ung thư học.

Chương 5

TÁI HIỆN KẾT QUẢ VÀ ĐỊNH HƯỚNG CẢI TIẾN

Chương này trình bày phần thực nghiệm độc lập của nhóm theo ba tầng tách biệt: **đọc lại kết quả công bố của tác giả, tái hiện trên giao thức đánh giá minh bạch và mở rộng/cải tiến trên cùng tập kiểm tra**. Cách tách này giúp tránh diễn giải sai khi các bảng trong bài báo có thay đổi đáng kể về *support* sau các bước xử lý mất cân bằng.

5.1 Đọc lại giao thức và kết quả công bố của tác giả

5.1.1 Ý nghĩa của các bảng so sánh trong bài báo

Với Dataset 1, Table 5 của tác giả so sánh ba nhóm kết quả: kết quả tham chiếu từ công trình [21], phương pháp của tác giả khi chưa balancing và phương pháp của tác giả sau balancing. Tuy nhiên, support trong bảng thay đổi rõ rệt: hai cột đầu sử dụng tổng support 1.022, trong khi cột sau balancing có tổng support 1.944 với hai lớp gần cân bằng. Do đó, các chỉ số Precision, Recall và F1 sau balancing không được tính trên cùng phân bố đánh giá với hai cột trước đó.

Với Dataset 2, Table 7 của tác giả được trình bày như một so sánh giữa mô hình không dùng PCA và mô hình có dùng PCA. Điểm cần lưu ý là support của hai cấu hình không giống nhau: cấu hình without PCA có tổng support 274.354, còn cấu hình with PCA có tổng support 21.218. Về nguyên tắc, PCA chỉ làm giảm số chiều đặc trưng, không tự làm giảm số quan sát. Vì vậy, sự thay đổi support

phải đến từ một bước lấy mẫu hoặc một tập đánh giá khác chưa được mô tả đủ chi tiết trong bài báo.

Bảng 5.1. Đọc lại support trong Table 5 và Table 7 của tác giả

Bảng	Cấu hình	Support lớp 0	Support lớp 1	Tổng	Diễn giải
Table 5 - D1	[21]	960	62	1.022	Gần đúng 20% của Dataset 1, chưa cân bằng test
Table 5 - D1	Our approach (a)	960	62	1.022	Cùng support với [21], chưa balancing trong tập đánh giá
Table 5 - D1	Our approach (b)	976	968	1.944	Tập đánh giá gần cân bằng; không cùng support với hai cột trước
Table 7 - D2	Without PCA	136.758	137.596	274.354	Support gần cân bằng do có bước sampling trước đó
Table 7 - D2	With PCA	10.613	10.605	21.218	Support thay đổi mạnh; PCA không giải thích được việc giảm số dòng

Bảng 5.1 cho thấy điểm quan trọng nhất của quá trình tái hiện: kết quả của tác giả là mốc tham chiếu học thuật, nhưng không nên được xem là hoàn toàn tương đương với kết quả của nhóm nếu nhóm đánh giá trên test gốc không cân bằng.

5.1.2 Những thành phần có thể và chưa thể tái dựng chính xác

Nhóm tái dựng được các thành phần chính của pipeline: XGBoost, xử lý mất cân bằng đúng theo hướng bài báo sử dụng, PCA giữ khoảng 95% phương sai và đánh giá bằng các chỉ số Precision, Recall, F1-score, Accuracy, MCC, Cohen's Kappa. Tuy nhiên, bài báo không công bố danh sách sample thuộc train/test split, random seed đầy đủ và vị trí chính xác của resampling tương đối với train/test split và cross-validation.


Bảng 5.2. Những thành phần có thể và chưa thể tái dựng chính xác từ bài báo

Thành phần	Mức độ xác định	Diễn giải
Dataset 1 dùng SMOTE	Rõ	Nhóm sử dụng cùng kỹ thuật balancing
Dataset 2 dùng random undersampling	Rõ	Nhóm sử dụng cùng họ kỹ thuật balancing
Chia dữ liệu 80/20	Rõ ở mức tỷ lệ	Không có exact split hoặc danh sách sample
Balancing trước hay sau split	Chưa rõ	Không đủ thông tin để tái dựng duy nhất
Balancing trong cross-validation	Chưa rõ	Không rõ resampling trước CV hay bên trong từng training fold
Tập tính classification report	Không định	ổn Support trong các bảng thay đổi sau balancing/PCA

5.2 Giao thức tái hiện của nhóm

5.2.1 Nguyên tắc đánh giá

Để các thí nghiệm có thể so sánh công bằng, nhóm sử dụng một giao thức nghiêm ngặt và minh bạch hơn: dữ liệu được chia train/test trước; mọi bước imputation, encoding, scaling, PCA và balancing chỉ được fit trên train; test set không được resample; tất cả cấu hình được đánh giá trên cùng test split. Như vậy, khi so sánh các mô hình của nhóm với nhau, khác biệt về chỉ số phản ánh khác biệt mô hình thay vì khác biệt về tập đánh giá.



Hình 5.1. Quy trình đánh giá được sử dụng trong các thí nghiệm của nhóm.

5.2.2 Số mẫu trước và sau balancing

Bảng 5.3 trình bày rõ số mẫu lớp 0 và lớp 1 trong từng giai đoạn. Điểm quan trọng là **support của test không thay đổi sau balancing**. Đây là khác biệt lớn so với cách support xuất hiện trong Table 5 và Table 7 của tác giả.

Bảng 5.3. Số mẫu trong giao thức của nhóm trước và sau balancing

Dataset	Giai đoạn	Train lớp 0	Train lớp 1	Test lớp 0	Test lớp 1	Ghi chú
Dataset 1	Sau split ban đầu	3.889	199	972	50	Test có 1.022 mẫu, prevalence lớp 1 khoảng 4,89% Chỉ train được cân bằng; test giữ nguyên PCA giảm số feature, không giảm số dòng
Dataset 1	Sau SMOTE trên train	3.889	3.889	972	50	
Dataset 1	Sau PCA	3.889	3.889	972	50	
Dataset 2	Sau split ban đầu	4.245.040	188.768	1.061.261	47.192	Test có 1.108.453 mẫu Chỉ train được lấy mẫu lại PCA không thay đổi support
Dataset 2	Sau random undersampling trên train	188.768	188.768	1.061.261	47.192	
Dataset 2	Sau PCA	188.768	188.768	1.061.261	47.192	

Bảng này là phần bắt buộc để đọc kết quả phía sau. Nếu test bị cân bằng lại, Precision, weighted average và Accuracy có thể thay đổi rất mạnh. Vì vậy, trong báo cáo này, các kết quả của nhóm luôn được hiểu là kết quả trên phân bố test ban đầu.

5.3 Tái hiện kết quả theo dạng classification report

Để nhất quán với cách tác giả trình bày Table 5 và Table 7, nhóm bổ sung classification report cho pipeline tái hiện cuối cùng. Các bảng dưới đây trình bày Precision, Recall, F1-score và Support theo từng lớp, kèm Accuracy, Macro average và Weighted average.

5.3.1 Dataset 1

Pipeline tái hiện cuối cùng của nhóm trên Dataset 1 sử dụng balancing, PCA và tuning. Confusion matrix tương ứng là: $TN = 760$, $FP = 212$, $FN = 11$, $TP = 39$. Tức là mô hình phát hiện được 39/50 ca stroke trong test, nhưng phải đánh đổi bằng 212 false positive.

Bảng 5.4. Dataset 1: classification report của nhóm trên test giữ nguyên phân bố

Lớp / trung bình	Precision	Recall	F1-score	Support
0 - No stroke	0,9857	0,7819	0,8721	972
1 - Stroke	0,1554	0,7800	0,2591	50
Accuracy			0,7818	1.022
Macro avg	0,5706	0,7809	0,5656	1.022
Weighted avg	0,9451	0,7818	0,8421	1.022

So với baseline không balancing, Recall của lớp stroke tăng từ 0,0600 lên 0,7800. Tuy nhiên Precision chỉ đạt 0,1554 do số false positive lớn. Điều này phản ánh bản chất của bài toán mất cân bằng: tăng khả năng bắt ca stroke thường làm giảm độ chính xác trong các cảnh báo dương tính.

5.3.1.1 Đối chiếu với [21] và hai cấu hình trong Table 5

Để làm rõ ý nghĩa của kết quả tái hiện, Bảng 5.5 đặt kết quả [21], hai cấu hình (a), (b) của tác giả, pipeline tái hiện và phương án cải

tiến của nhóm cạnh nhau. Cột support được giữ trong bảng vì đây là thông tin quyết định việc các metric có thể được so sánh trực tiếp hay chỉ mang tính tham khảo.

Bảng 5.5. Dataset 1: đối chiếu Table 5 với kết quả tái hiện và cải tiến của nhóm

Phương án	Accuracy	Precision (1)	Recall (1)	F1 (1)	Support	Diễn giải
[21]	0,85	0,21	0,52	0,29	960/62	Mốc tham chiếu trên test mất cân bằng, tổng 1.022 mẫu
Tác giả (a)	0,92	0,24	0,15	0,18	960/62	Accuracy/Precision cao hơn [21] nhưng Recall và F1 giảm mạnh
Tác giả (b)	0,95	0,93	0,96	0,95	976/968	Support đổi sang gần 50:50; không so trực tiếp với các cột test mất cân bằng
Nhóm – tái hiện	0,7818	0,1554	0,7800	0,2591	972/50	Recall cao hơn [21] và (a), đổi lại Accuracy/Precision thấp hơn
Nhóm – cải tiến	0,8434	0,1944	0,7000	0,3043	972/50	F1 cao hơn [21] và (a), Recall cao hơn rõ rệt; Accuracy gần [21]

So với [21], pipeline tái hiện của nhóm chưa cao hơn ở mọi chỉ số: Accuracy giảm từ 0,85 xuống 0,7818, Precision giảm từ 0,21 xuống 0,1554 và F1 giảm nhẹ từ 0,29 xuống 0,2591; ngược lại Recall tăng đáng kể từ 0,52 lên 0,78. Khi chuyển sang phương án cải tiến, F1 đạt 0,3043, cao hơn mức 0,29 của [21], đồng thời Recall vẫn đạt 0,70, cao hơn 0,52. Accuracy 0,8434 gần mức 0,85 của [21] và Precision 0,1944 thấp hơn nhẹ mức 0,21. Vì vậy, kết quả cải tiến có thể được diễn giải là **cân bằng phát hiện lớp stroke tốt hơn [21] về Recall và F1, với một đánh đổi nhỏ ở Accuracy và Precision**; tuy nhiên đây vẫn là đối chiếu tham khảo vì exact test samples không hoàn toàn giống nhau.

So với cột (a) của tác giả, sự đánh đổi còn rõ hơn: cột (a) đạt Accuracy 0,92 và Precision 0,24 nhưng Recall chỉ 0,15 và F1 0,18. Phương án cải tiến của nhóm giảm Accuracy/Precision nhưng tăng Recall lên 0,70 và F1 lên 0,3043. Cột (b) không được dùng để kết

luyện hơn/kém trực tiếp vì support đã thay đổi từ 1.022 mẫu mất cân bằng sang 1.944 mẫu gần cân bằng.

5.3.2 Dataset 2

Pipeline tái hiện cuối cùng của nhóm trên Dataset 2 sử dụng random undersampling, PCA và tuning. Confusion matrix tương ứng là: TN = 1.024.239, FP = 37.022, FN = 263, TP = 46.929.

Bảng 5.6. Dataset 2: classification report của nhóm trên test giữ nguyên phân bố

Lớp / trung bình	Precision	Recall	F1-score	Support
0 - No stroke	0,9997	0,9651	0,9821	1.061.261
1 - Stroke	0,5590	0,9944	0,7157	47.192
Accuracy			0,9664	1.108.453
Macro avg	0,7794	0,9798	0,8489	1.108.453
Weighted avg	0,9810	0,9664	0,9708	1.108.453

Kết quả Dataset 2 cho thấy pipeline tái hiện bắt được gần như toàn bộ lớp stroke với Recall 0,9944, đồng thời F1 đạt 0,7157. So với Dataset 1, Precision cao hơn đáng kể do dữ liệu lớn hơn và tín hiệu phân loại ổn định hơn.

5.4 Diễn biến kết quả qua các bước xây dựng pipeline


Bảng 5.7 trình bày quá trình từ baseline tới pipeline tái hiện hoàn chỉnh. Nó cũng giải thích vì sao chỉ nhìn Accuracy có thể gây hiểu nhầm trong bài toán stroke prediction mất cân bằng.

Bảng 5.7. Diễn biến kết quả qua các bước xây dựng pipeline trên test giữ nguyên phân bố lớp


Dữ liệu	Bước	Accuracy	Precision	Recall	F1	ROC-AUC	MCC
Dataset 1	Baseline, không PCA	0,9501	0,4286	0,0600	0,1053	0,8307	0,1462
Dataset 1	Baseline + PCA	0,9491	0,3333	0,0400	0,0714	0,8011	0,1013
Dataset 1	Balancing	0,9119	0,1296	0,1400	0,1346	0,7880	0,0884
Dataset 1	Balancing + PCA	0,8249	0,1272	0,4400	0,1973	0,7716	0,1637
Dataset 1	Balancing + PCA + tuning	0,7818	0,1554	0,7800	0,2591	0,8118	0,2816
Dataset 2	Baseline, không PCA	0,9612	0,9152	0,0986	0,1780	0,9319	0,2934
Dataset 2	Baseline + PCA	0,9638	0,9723	0,1538	0,2656	0,9641	0,3792
Dataset 2	Balancing	0,8166	0,1807	0,9360	0,3030	0,9376	0,3639
Dataset 2	Balancing + PCA	0,8572	0,2262	0,9722	0,3670	0,9714	0,4304
Dataset 2	Balancing + PCA + tuning	0,9664	0,5590	0,9944	0,7157	0,9976	0,7322

Trên Dataset 1, baseline không PCA đạt Accuracy 0,9501 nhưng Recall chỉ 0,0600; mô hình gần như dự đoán lớp đa số và bỏ sót hầu hết ca đột quy. Sau khi hoàn thiện balancing, PCA và tuning, Recall tăng lên 0,7800, F1 lên 0,2591 và MCC lên 0,2816, dù Accuracy giảm. Đây là minh họa trực tiếp cho việc Accuracy cao ban đầu không đồng nghĩa mô hình hữu ích cho lớp stroke.

Trên Dataset 2, Recall tăng từ 0,0986 ở baseline lên 0,9944 ở pipeline hoàn chỉnh; F1 tăng từ 0,1780 lên 0,7157 và MCC từ 0,2934 lên 0,7322. Kết quả này xác nhận vai trò của xử lý mất cân bằng đối với lớp mục tiêu trên chính protocol cố định của nhóm.



Hình 5.2. Diễn biến hiệu năng qua các bước xây dựng pipeline trên Dataset 1.



Hình 5.3. Diễn biến hiệu năng qua các bước xây dựng pipeline trên Dataset 2.

5.5 Ablation: balancing, PCA và tuning

Các kết quả trên cho phép phân biệt rõ vai trò của từng thành phần. Thứ nhất, balancing là cần thiết nếu mục tiêu là phát hiện lớp stroke. Thứ hai, PCA không mặc nhiên cải thiện mọi cấu hình: trên Dataset 1, chỉ thêm PCA vào baseline làm Recall giảm từ 0,0600 xuống 0,0400; lợi ích của PCA phụ thuộc vào pipeline mà nó được

kết hợp. Thứ ba, tuning làm thay đổi mạnh điểm vận hành của mô hình, vì vậy cần đánh giá Recall, Precision, F1 và MCC thay vì chỉ Accuracy.

Quan trọng về thuật ngữ: **SMOTE trên Dataset 1 và random undersampling trên Dataset 2 không phải đề xuất cải tiến của nhóm**; đây là các kỹ thuật balancing đã được tác giả sử dụng và nhóm tái hiện. Thử nghiệm PCA/no-PCA là *ablation*. Các phương pháp thay thế như SMOTENC, cost-sensitive learning và tối ưu threshold mới được xem là phần mở rộng của nhóm.

5.6 Mở rộng/cải tiến trên cùng giao thức đánh giá

Từ benchmark giữ nguyên test distribution, nhóm thử các lựa chọn thay thế mà không thay đổi test split. Nhờ đó, các kết luận “cải thiện” trong phần này là phép so sánh hợp lệ giữa các experiment của nhóm.

5.6.1 Dataset 1: SMOTE, SMOTENC và cost-sensitive learning

Dataset 1 so sánh SMOTE, SMOTENC và XGBoost có trọng số lớp; mỗi phương pháp được khảo sát với và không với PCA.

Bảng 5.8. Dataset 1: các phương pháp xử lý mất cân bằng tại ngưỡng 0,5

Phương pháp	PCA	Accuracy	Precision	Recall	F1	ROC-AUC	MCC
SMOTE	Không	0,8620	0,1946	0,5800	0,2915	0,8412	0,2791
SMOTE	Có	0,8513	0,1964	0,6600	0,3028	0,8195	0,3033
SMOTENC	Không	0,9295	0,2963	0,3200	0,3077	0,8290	0,2709
SMOTENC	Có	0,9315	0,2619	0,2200	0,2391	0,8170	0,2044
Weighted	Không	0,9511	0,5000	0,0200	0,0385	0,8263	0,0926
Weighted	Có	0,7329	0,1296	0,7800	0,2222	0,8241	0,2416

Không có phương pháp thống trị mọi metric. SMOTENC không PCA có F1 0,3077 tại threshold 0,5 nhưng Recall chỉ 0,3200. Weighted

+ PCA giữ Recall 0,7800 nhưng Precision chỉ 0,1296. Vì vậy nhóm tiếp tục lựa chọn threshold trên validation theo các mức Specificity mục tiêu, thay vì lựa chọn hậu nghiệm từ test.

Bảng 5.9. Dataset 1: các điểm vận hành được lựa chọn từ validation

Spec. mục tiêu	Cấu hình	Ngưỡng	Acc.	Prec.	Recall	F1	MCC
85%	Weighted + PCA	0,6704	0,8434	0,1944	0,7000	0,3043	0,3119
90%	Weighted, không PCA	0,1305	0,8757	0,1870	0,4600	0,2659	0,2368
95%	Weighted, không PCA	0,1902	0,9188	0,2381	0,3000	0,2655	0,2248

Tại Specificity mục tiêu khoảng 85%, Weighted + PCA đạt F1 0,3043 và MCC 0,3119, cao hơn baseline tái hiện tương ứng F1 0,2591 và MCC 0,2816; Recall giảm từ 0,7800 xuống 0,7000. Vì vậy đây là cải thiện về sự cân bằng của quyết định, không phải cải thiện đồng thời mọi metric.

5.6.2 Dataset 2: undersampling và cost-sensitive learning

Dataset 2 so sánh random undersampling với weighted XGBoost, có và không PCA.

Bảng 5.10. Dataset 2: các phương pháp xử lý mất cân bằng tại ngưỡng 0,5

Phương pháp	PCA	Accuracy	Precision	Recall	F1	ROC-AUC	MCC
Undersampling	Không	0,9799	0,7049	0,9086	0,7939	0,9945	0,7905
Undersampling	Có	0,9847	0,7401	0,9886	0,8465	0,9987	0,8484
Weighted	Không	0,9729	0,6150	0,9726	0,7536	0,9963	0,7618
Weighted	Có	0,9421	0,4233	0,9932	0,5936	0,9956	0,6282

Ở Dataset 2, phương án tốt nhất vẫn là **Undersampling + PCA**. Weighted XGBoost không vượt cấu hình này về F1/MCC. Do undersampling chính là họ phương pháp đã có trong paper, kết quả

này không được mô tả là thuật toán balancing mới vượt tác giả. Điều nhóm chứng minh được là trên cùng strict protocol, cấu hình được thiết lập/tuning lại đạt Accuracy 0,9847, F1 0,8465 và MCC 0,8484 trong khi Recall vẫn 0,9886.

Việc hạ threshold có thể đưa Recall lên rất cao nhưng phải trả giá bằng số false positive. Chẳng hạn với Undersampling + PCA tại mức Specificity mục tiêu 85%, Recall đạt 1,0000 nhưng Precision chỉ 0,2346 và tạo 153.928 false positive. Do đó Recall 100% chỉ là một điểm vận hành, không phải bằng chứng dự đoán hoàn hảo.

5.7 Tổng hợp: tái hiện và cải tiến trên cùng test set

Bảng 5.11 chỉ tổng hợp các kết quả do nhóm thực nghiệm trên **cùng test split giữ nguyên phân bố lớp**. Kết quả công bố của tác giả không được đưa vào bảng này vì support và giao thức đánh giá không tương đương. Nhờ đó, mọi kết luận tăng/giảm dưới đây đều là so sánh trực tiếp và có cùng mẫu đánh giá.

Bảng 5.11. Tổng hợp baseline tái hiện và phương án cải tiến của nhóm trên cùng test set

Dữ liệu	Metric	Tái hiện	Cải tiến	Diễn giải
D1	Accuracy	0,7818	0,8434	Tăng Accuracy khi điều chỉnh điểm vận hành
D1	Precision	0,1554	0,1944	Precision lớp stroke tăng
D1	Recall	0,7800	0,7000	Đánh đổi 0,08 Recall để giảm false positive và tăng F1/MCC
D1	F1	0,2591	0,3043	F1 tăng khoảng 17,4% tương đối
D1	MCC	0,2816	0,3119	MCC tăng, cho thấy cân bằng dự đoán hai lớp tốt hơn
D2	Accuracy	0,9664	0,9847	Accuracy tăng rõ rệt trên cùng test
D2	Precision	0,5590	0,7401	Precision lớp stroke tăng mạnh
D2	Recall	0,9944	0,9886	Recall giảm rất nhẹ và vẫn ở mức cao
D2	F1	0,7157	0,8465	F1 tăng khoảng 18,3% tương đối
D2	MCC	0,7322	0,8484	MCC tăng đáng kể
D2	ROC-AUC	0,9976	0,9987	Cải thiện nhẹ khả năng xếp hạng xác suất

Trên Dataset 1, phương án cải tiến không tối đa hóa Recall

bằng mọi giá. Recall giảm từ 0,7800 xuống 0,7000 nhưng Accuracy, Precision, F1 và MCC đều tăng; đây là một điểm vận hành cân bằng hơn giữa phát hiện ca stroke và hạn chế false positive. Trên Dataset 2, cải tiến rõ ràng hơn: Precision, F1, MCC và Accuracy đều tăng đáng kể trong khi Recall chỉ giảm từ 0,9944 xuống 0,9886. Vì cả hai cột sử dụng cùng test set, đây là các kết luận cải tiến trực tiếp và có giá trị hơn việc đối chiếu các con số được tính trên support khác nhau.

5.8 Hạn chế và hướng cải tiến tiếp theo

Dataset 1 nhỏ và chỉ có ít trường hợp stroke trong test, nên kết quả nhạy với split. Dataset 2 có quy mô lớn nhưng là dữ liệu synthetic, do đó các chỉ số rất cao cần được diễn giải thận trọng. Quan trọng hơn đối với mục tiêu tái hiện, bài báo không công bố đủ chi tiết để tái dựng chính xác sampling/evaluation protocol; nhóm vì vậy ưu tiên tính minh bạch và khả năng kiểm chứng của giao thức riêng thay vì điều chỉnh pipeline để ép kết quả gần số công bố.

Vòng cải tiến hiện tại chủ yếu nằm ở chiến lược xử lý mất cân bằng, ablation PCA và lựa chọn threshold. Bước tiếp theo sẽ giữ nguyên train/test split và strict protocol hiện tại để khảo sát các cải tiến ở mức thuật toán hoặc hàm mất mát. Một phương án mới chỉ được kết luận tốt hơn baseline khi được đánh giá trên cùng test, cùng metric và cùng lớp mục tiêu. Mục tiêu ưu tiên là nâng F1/MCC, giảm false positive nhưng vẫn duy trì Recall cao và khả năng giải thích của mô hình.

5.9 Thử nghiệm mở rộng với các mô hình và cơ chế học cho dữ liệu mất cân bằng

Sau các thử nghiệm tái hiện và cải tiến dựa trên XGBoost, nhóm tiếp tục khảo sát khả năng cải thiện bằng cách thay đổi họ thuật toán và cơ chế xử lý mất cân bằng. Mục tiêu không chỉ là tăng Accuracy, mà ưu tiên khả năng phát hiện lớp *stroke* trong khi hạn chế cảnh báo dương tính giả. Các phương pháp được khảo sát gồm CatBoost, LightGBM, Balanced Random Forest, EasyEnsemble và XGBoost với Focal Loss. Đây là ba hướng mở rộng khác nhau: thay đổi họ boosting, xử lý mất cân bằng ở cấp độ thuật toán và sử dụng ensemble/hàm mất mát chuyên biệt cho lớp thiểu số.

5.9.1 Giao thức thực nghiệm mở rộng

Outer train/test split tiếp tục được giữ cố định ở tỷ lệ 80/20 với `random_state=42`. Test set giữ nguyên phân bố ban đầu, không được resample và không tham gia lựa chọn mô hình hay threshold. Từ outer-training set, nhóm tách inner validation với seed 2026 để xác định operating threshold; một điểm vận hành chính yêu cầu Specificity trên validation đạt tối thiểu 85%. Threshold sau đó được cố định trước khi đánh giá trên outer test.

Các chỉ số báo cáo gồm Accuracy, Precision, Recall, F1, MCC và ROC-AUC. Trong bối cảnh mất cân bằng, F1 và MCC được dùng để đánh giá sự cân bằng tổng thể, còn Recall được xem là guardrail cho khả năng phát hiện stroke. Việc chọn threshold trên validation thay vì hậu nghiệm trên test nhằm hạn chế thiên lệch do lựa chọn điểm vận hành sau khi đã quan sát kết quả cuối.

5.9.2 Dataset 1: so sánh các họ mô hình mới

CatBoost được huấn luyện trực tiếp trên các biến phân loại nguyên bản với `auto_class_weights=Balanced`, không One-Hot Encoding, PCA hay SMOTE. LightGBM giữ toàn bộ training set và dùng `scale_pos_weight`. Balanced Random Forest tạo các mẫu cân bằng bên trong quá trình xây dựng cây. EasyEnsemble và Focal-loss XGBoost được dùng như các thí nghiệm sàng lọc bổ sung cho bài toán mất cân bằng.

Bảng 5.12. Dataset 1: kết quả các phương pháp mở rộng trên cùng outer test

Phương pháp	Acc.	Prec.	Recall	F1	MCC	ROC-AUC	Vai trò
XGBoost cải tiến (Exp. 13)	0,8434	0,1944	0,7000	0,3043	0,3119	0,8241	Mốc cải tiến trước đó
CatBoost	0,7867	0,1640	0,8200	0,2733	0,3036	0,8364	Recall/ROC-AUC cao
LightGBM weighted	0,8327	0,1543	0,5400	0,2400	0,2220	0,7865	Không cải thiện
Balanced Random Forest	0,8483	0,2000	0,7000	0,3111	0,3184	0,8274	Tốt nhất tổng thể
EasyEnsemble*	0,8454	0,1860	0,6400	0,2883	0,2860	0,8309	Screening
Focal-loss XGBoost	0,8405	0,1844	0,6600	0,2882	0,2893	0,8317	Không cải thiện

Balanced Random Forest tạo ra điểm vận hành cân bằng nhất. So với XGBoost cải tiến ở Experiment 13, Recall giữ nguyên 0,70, trong khi Accuracy tăng từ 0,8434 lên 0,8483, Precision từ 0,1944 lên 0,2000, F1 từ 0,3043 lên 0,3111 và MCC từ 0,3119 lên 0,3184. Mức tăng tương đối khoảng 2,2% ở F1 và 2,1% ở MCC, vì vậy được diễn giải là **cải thiện biên (marginal improvement)**, không phải sự vượt trội lớn.

CatBoost cho Recall và ROC-AUC cao nhất, lần lượt 0,82 và 0,8364. Điều này cho thấy khả năng xếp hạng nguy cơ tốt khi xử lý trực tiếp biến categorical, nhưng lợi thế ranking chưa chuyển thành F1/MCC tốt nhất tại operating point được chọn. LightGBM, EasyEnsemble và Focal-loss XGBoost không vượt Balanced Random Forest hoặc XGBoost cải tiến trên các chỉ số cân bằng chính.

*EasyEnsemble sử dụng cấu hình giới hạn tài nguyên tính toán sau khi cấu hình mặc định không phù hợp với môi trường chạy; vì

vậy kết quả được xem là screening experiment, không phải bằng chứng chính để xếp hạng mô hình.

5.9.3 Dataset 2: class weighting so với data-level balancing

Dataset 2 sau làm sạch có 5.542.261 quan sát; outer-training set gồm 4.433.808 và outer-test set gồm 1.108.453 mẫu. LightGBM được chạy trên toàn bộ outer-training set, không undersampling hay SMOTE; mất cân bằng được xử lý bằng `scale_pos_weight`. Kết quả được so sánh với cấu hình XGBoost + undersampling + PCA tốt nhất ở Experiment 13.

Bảng 5.13. Dataset 2: so sánh XGBoost cải tiến và LightGBM weighted trên full data

Phương pháp	Acc.	Prec.	Recall	F1	MCC	ROC-AUC
XGBoost + undersampling + PCA	0,9847	0,7401	0,9886	0,8465	0,8484	0,9987
LightGBM weighted	0,9587	0,5079	0,9926	0,6720	0,6943	0,9973

LightGBM tăng Recall nhẹ từ 0,9886 lên 0,9926 nhưng Precision giảm mạnh từ 0,7401 xuống 0,5079; F1 giảm còn 0,6720 và MCC còn 0,6943. Kết quả cho thấy class weighting giúp hạn chế false negative nhưng tạo nhiều false positive hơn. Trên Dataset 2, **data-level balancing bằng undersampling kết hợp XGBoost cho trade-off Precision-Recall tốt hơn algorithm-level class weighting của LightGBM.**

CatBoost cũng được khảo sát cho Dataset 2, nhưng huấn luyện full 4,43 triệu quan sát vượt giới hạn bộ nhớ của môi trường thực nghiệm. Một probe dùng stratified subset được thực hiện để kiểm tra tính khả thi, song không được đưa vào bảng so sánh full-data và không được dùng để kết luận hơn/kém so với XGBoost hay LightGBM. Cách trình bày này tránh đánh đồng một thí nghiệm giới hạn tài nguyên với các experiment sử dụng toàn bộ training set.

5.9.4 Đúc kết từ thử nghiệm mở rộng

Các thử nghiệm cho thấy thay thế XGBoost bằng một họ thuật toán mới không tự động tạo ra cải thiện. Với Dataset 1 nhỏ và mất cân bằng mạnh, Balanced Random Forest cho cải thiện nhỏ nhưng nhất quán về Accuracy, Precision, F1 và MCC khi giữ nguyên Recall. CatBoost lại nổi bật ở Recall và ROC-AUC, cho thấy một operating objective khác có thể dẫn đến lựa chọn mô hình khác.

Với Dataset 2 quy mô lớn, XGBoost kết hợp undersampling và PCA vẫn là cấu hình tốt nhất xét đồng thời Precision, Recall, F1 và MCC. LightGBM weighted đạt Recall cao hơn nhưng phải đánh đổi bằng số false positive lớn hơn. Do đó, ảnh hưởng của **cơ chế xử lý mất cân bằng và operating threshold ít nhất quan trọng tương đương việc lựa chọn họ mô hình.**

Kết luận của giai đoạn mở rộng không phải là một thuật toán mới có thể thay thế XGBoost trong mọi trường hợp. Thay vào đó, phương pháp tối ưu phụ thuộc vào cấu trúc và quy mô dữ liệu: **Balanced Random Forest là phương án mở rộng tốt nhất cho Dataset 1**, trong khi **XGBoost + undersampling + PCA tiếp tục là cấu hình tốt nhất cho Dataset 2**. Các kết quả âm tính của LightGBM, EasyEnsemble và Focal-loss XGBoost cũng được giữ lại để bảo đảm báo cáo phản ánh đầy đủ quá trình thử nghiệm thay vì chỉ lựa chọn hậu nghiệm các kết quả thuận lợi.

KẾT LUẬN

Báo cáo thực hiện ba nhiệm vụ chính: trình bày có hệ thống phương pháp của bài báo gốc, tái hiện độc lập các thành phần cốt lõi của pipeline trên hai bộ dữ liệu và khảo sát các hướng mở rộng sau tái hiện. Báo cáo phân biệt rõ **phương pháp của tác giả, đánh giá có kiểm soát của nhóm, ablation** và **mở rộng/cải tiến**, tránh xem mọi thay đổi trong balancing hoặc PCA đều là đóng góp mới.

Về xử lý mất cân bằng, nhóm sử dụng đúng loại kỹ thuật mà bài báo mô tả: SMOTE cho Dataset 1 và random undersampling cho Dataset 2. Tuy nhiên, việc đọc lại các bảng kết quả của tác giả cho thấy không thể khôi phục chính xác toàn bộ evaluation protocol. Bài báo nêu tỷ lệ chia train/test 80/20 nhưng không mô tả đủ rõ balancing được thực hiện trước hay sau split, cách resampling được đặt trong cross-validation, hay exact split và random seed. Đáng chú ý, support của Dataset 1 sau balancing gần 50:50; ở Dataset 2, support của các thí nghiệm có và không PCA thay đổi mạnh mặc dù PCA về nguyên tắc chỉ giảm số đặc trưng chứ không làm giảm số quan sát. Vì vậy, khoảng cách giữa metric của nhóm và metric được công bố không thể được quy hoàn toàn cho chất lượng mô hình tái hiện.

Nhóm do đó sử dụng một protocol cố định và minh bạch cho các phép so sánh nội bộ: chia train/test trước, fit preprocessing/PCA/resampling chỉ trên train hoặc trong training fold, và giữ nguyên phân bố lớp của test. Trên Dataset 1, baseline không PCA đạt Accuracy 0,9501 nhưng Recall chỉ 0,0600; sau khi hoàn thiện balancing, PCA và tuning, Recall tăng lên 0,7800, F1-score lên 0,2591 và MCC lên 0,2816. Trên Dataset 2, Recall tăng từ 0,0986 lên 0,9944; F1-score tăng từ

0,1780 lên 0,7157 và MCC từ 0,2934 lên 0,7322. Kết quả này cho thấy Accuracy đơn lẻ có thể gây hiểu nhầm trong bài toán mất cân bằng và xác nhận vai trò của balancing đối với lớp stroke.

Các kết quả của tác giả vẫn được đặt cạnh kết quả nhóm như một mức tham chiếu. Tuy nhiên, do evaluation distribution và các chi tiết sampling không tương đồng hoặc không được mô tả đầy đủ, báo cáo không coi các cặp số này là phép so sánh trực tiếp để kết luận mô hình của nhóm tốt hơn hay kém hơn tác giả.

Trong ablation study, SMOTE đối với Dataset 1 và Random UnderSampler đối với Dataset 2 được xem là thành phần của baseline tái hiện; thử nghiệm PCA/no-PCA dùng để đánh giá đóng góp của giảm chiều. Kết quả cho thấy PCA không mặc nhiên cải thiện mọi trường hợp, mà hiệu quả phụ thuộc vào dataset và cách nó được kết hợp với balancing và tuning.

Ở vòng cải tiến thứ nhất, Dataset 1 được khảo sát thêm SMOTENC và cost-sensitive XGBoost. Cấu hình Weighted + PCA tại Specificity khoảng 85% đạt Recall 0,7000, F1-score 0,3043 và MCC 0,3119. Trên Dataset 2, cấu hình Random UnderSampler + PCA được thiết lập/tuning lại đạt Accuracy 0,9847, Precision 0,7401, Recall 0,9886, F1-score 0,8465, ROC-AUC 0,9987 và MCC 0,8484 trên test giữ nguyên phân bố.

Ở vòng mở rộng thuật toán, nhóm tiếp tục thử CatBoost, LightGBM, Balanced Random Forest, EasyEnsemble và Focal-loss XGBoost dưới cùng strict protocol. Trên Dataset 1, **Balanced Random Forest** tạo cải thiện biên so với XGBoost Weighted + PCA: giữ Recall ở 0,7000 nhưng tăng Accuracy từ 0,8434 lên 0,8483, Precision từ 0,1944 lên 0,2000, F1 từ 0,3043 lên 0,3111 và MCC từ 0,3119 lên 0,3184. CatBoost đạt Recall 0,8200 và ROC-AUC 0,8364, cao nhất trong

nhóm challenger ở hai tiêu chí này, nhưng không đạt F1/MCC tốt nhất. LightGBM, EasyEnsemble và Focal-loss XGBoost không tạo cải thiện tổng thể so với cấu hình tốt nhất.

Trên Dataset 2, LightGBM weighted chạy trên toàn bộ training set đạt Recall 0,9926, cao hơn nhẹ XGBoost + undersampling + PCA, nhưng Precision chỉ 0,5079, F1 0,6720 và MCC 0,6943. Do đó XGBoost + undersampling + PCA vẫn là cấu hình tốt nhất xét đồng thời Precision, Recall, F1 và MCC. CatBoost full-data không hoàn thành do giới hạn bộ nhớ; probe trên subset chỉ được dùng để đánh giá tính khả thi và không tham gia so sánh hiệu năng chính.

Tổng thể, các thí nghiệm cho thấy không tồn tại một họ mô hình mới duy nhất thắng trên cả hai dataset. Với Dataset 1 nhỏ và mất cân bằng mạnh, ensemble chuyên cho imbalance như Balanced Random Forest cho điểm vận hành tốt hơn một chút. Với Dataset 2 quy mô lớn, XGBoost kết hợp data-level balancing tiếp tục tạo trade-off tốt hơn class weighting của LightGBM. Điều này củng cố kết luận rằng **cơ chế xử lý mất cân bằng và lựa chọn operating threshold có ảnh hưởng ít nhất tương đương việc lựa chọn họ mô hình.**

Các hướng tiếp theo nên tập trung vào xác nhận độ ổn định của các chênh lệch nhỏ bằng repeated stratified split hoặc bootstrap confidence interval, đánh giá calibration và chi phí false positive/false negative, và kiểm chứng trên dữ liệu lâm sàng ngoài mẫu. Đây là các bước có giá trị hơn việc tiếp tục bổ sung nhiều classifier mới mà không thay đổi câu hỏi nghiên cứu.

TÀI LIỆU THAM KHẢO

- [1] Dev S, Wang H, Nwosu CS, Jain N, Veeravalli B, John D. A predictive analytics approach for stroke prediction using machine learning and neural networks. *Healthc Anal.* 2022;2:100032. <https://doi.org/10.1016/j.health.2022.100032>.
- [2] Bikku T, Fritz RA, Colón YJ, Herrera F. Machine learning identification of organic compounds using visible light. 2022. <https://doi.org/10.48550/ARXIV.2204.11832>.
- [3] Kovtun O, Kovtun V. Machine Learning-Based Approach to Transcribing Language Units. In: 2024 14th International Conference on Advanced Computer Information Technologies (ACIT), Ceske Budejovice. Czech Republic: IEEE; 2024. pp. 636–639. <https://doi.org/10.1109/ACIT62333.2024.10712598>.
- [4] Gupta A et al. Predicting stroke risk: an effective stroke prediction model based on neural networks. *J Neurorestoratol.* 2024:100156. <https://doi.org/10.1016/j.jnrt.2024.100156>.
- [5] JalajaJayalakshmi V, Geetha V, Ijaz MM. Analysis and Prediction of Stroke using Machine Learning Algorithms. In: 2021 International Conference on Advancements in Electrical, Electronics, Communication Computing and Automation (ICAECA), Coimbatore. India: IEEE; 2021. pp. 1–5. <https://doi.org/10.1109/ICAECA52838.2021.9675545>.
- [6] Bikku T. Multi-layered deep learning perceptron approach for health risk prediction. *J Big Data.* 2020;7(1):50. <https://doi.org/10.1186/s40537-020-00316-7>.

- [7] Upadhyay R, Panse P, Soni A, Rathore Bhatt U. Principal component analysis as a dimensionality reduction and data preprocessing technique. *SSRN Electron J*. 2019. <https://doi.org/10.2139/ssrn.3364221>.
- [8] Izonin I, Gamra A, Boychuk O, et al. PCA-NuSVR Framework for Predicting Local and Global Indicators of Tunneling-induced Building Damage. Proceedings of the 1st International Conference on Smart Automation & Robotics for Future Industry (SMARTINDUSTRIAL 2024). 2024;3699:32-46.
- [9] Booker NK, Knights P, Gates JD, Clegg RE. Applying principal component analysis (PCA) to the selection of forensic analysis methodologies. *Eng Fail Anal*. 2022;132:105937. <https://doi.org/10.1016/j.engfailanal.2021.105937>.
- [10] Mochurad L, Panto R. A Parallel Algorithm for the Detection of Eye Disease. In: Advances in Intelligent Systems, Computer Science and Digital Economics IV, vol. 158. Hu Z, Wang Y, He M, eds. Lecture Notes on Data Engineering and Communications Technologies. Cham: Springer Nature Switzerland; 2023. pp. 111-125. https://doi.org/10.1007/978-3-031-24475-9_10.
- [11] Althiban AS, Alharbi HM, Al Khuzayem LA, Eassa FE. Predicting software defects in hybrid MPI and OpenMP parallel programs using machine learning. *Electronics*. 2023;13(1):182. <https://doi.org/10.3390/electronics13010182>.
- [12] Mochurad L, Kotsiumbas O, Protsyk I. A model for weather forecasting based on parallel calculations. In: Advances in Artificial Systems for Medicine and Education VI, vol. 159. Hu Z, Ye Z,

- He M, eds. Lecture Notes on Data Engineering and Communications Technologies. Cham: Springer Nature Switzerland; 2023. pp. 35–46. https://doi.org/10.1007/978-3-031-24468-1_4.
- [13] Ali S, et al. Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. *InfFusion*. 2023;99:101805. <https://doi.org/10.1016/j.inffus.2023.101805>.
- [14] Bikku T. Fuzzy associated trust-based data security in cloud computing by mining user behaviour. *Int J Adv Intell Paradig*. 2023;25(3/4):382–97. <https://doi.org/10.1504/IJAIP.2023.132377>.
- [15] Tazin T, Alam MN, Dola NN, Bari MS, Bourouis S, Monirujjaman Khan M. Stroke disease detection and prediction using robust learning approaches. *J Healthc Eng*. 2021:1–12. <https://doi.org/10.1155/2021/7633381>.
- [16] Patereha Y, Melnyk M. Prediction of the occurrence of stroke based on machine learning models. *Comput Des Syst Theory Pract*. 2024;6(1):17–27. <https://doi.org/10.23939/cds2024.01.017>.
- [17] Dritsas E, Trigka M. Stroke risk prediction with machine learning techniques. *Sensors*. 2022;22(13):4670. <https://doi.org/10.3390/s22134670>.
- [18] Sailasya G, Kumari GL. Analyzing the performance of stroke prediction using ML classification algorithms. *Int J Adv Comput Sci Appl*. 2021;12(6). <https://doi.org/10.14569/IJACSA.2021.0120662>.
- [19] Dhillon S, Bansal C, Sidhu B. Machine learning based approach

- using xgboost for heart stroke prediction. International Conference on Emerging Technologies: AI, IoT, and CPS for Science & Technology Applications. 2021. p. 1-6.
- [20] Chung C-C, Su EC-Y, Chen J-H, Chen Y-T, Kuo C-Y. XGBoost-based simple three-item model accurately predicts outcomes of acute ischemic stroke. *Diagnostics*. 2023;13(5):842. <https://doi.org/10.3390/diagnostics13050842>.
- [21] Tumpanjawat. Stroke Prediction: EDA | Resampling | XGBoost. Kaggle. 2024. Available: <https://www.kaggle.com/code/tumpanjawat/stroke-prediction-eda-resampling-xgboost>.
- [22] Mainali S, Darsie ME, Smetana KS. Machine learning in action: stroke diagnosis and outcome prediction. *Front Neurol*. 2021;12:73434. <https://doi.org/10.3389/fneur.2021.734345>.
- [23] Fang G, Huang Z, Wang Z. Predicting ischemic stroke outcome using deep learning approaches. *Front Genet*. 2022;12:827522. <https://doi.org/10.3389/fgene.2021.827522>.
- [24] Srinivasu PN, Sirisha U, Sandeep K, Praveen SP, Maguluri LP, Bikku T. An interpretable approach with explainable ai for heart stroke prediction. *Diagnostics*. 2024;14(2):128. <https://doi.org/10.3390/diagnostics14020128>.
- [25] Mienye ID, Jere N. Optimized ensemble learning approach with explainable ai for improved heart disease prediction. *Information*. 2024;15(7):394. <https://doi.org/10.3390/info15070394>.
- [26] Singamaneni KK, Budati AK, Bikku T. An Efficient Q-KPABE framework to enhance cloud-based iot security and privacy. *Wirel Pers Commun*. 2024. <https://doi.org/10.1007/s11277-024-10908-8>.

- [27] Bikku T, Malligunta KK, Thota S, Surapaneni PP. Improved quantum algorithm: a crucial stepping stone in quantum-powered drug discovery. *J Electron Mater*. 2024. <https://doi.org/10.1007/s11664-024-11275-7>.
- [28] Da Poian V, et al. Exploratory data analysis (EDA) machine learning approaches for ocean world analog mass spectrometry. *Front Astron Space Sci*. 2023;10:1134141. <https://doi.org/10.3389/fspas.2023.1134141>.
- [29] Elreedy D, Atiya AF. A Comprehensive Analysis of Synthetic Minority Oversampling Technique (SMOTE) for handling class imbalance. *Inf Sci*. 2019;505:32–64. <https://doi.org/10.1016/j.ins.2019.07.070>.
- [30] Nohara Y, Matsumoto K, Soejima H, Nakashima N. Explanation of machine learning models using shapley additive explanation and application for real data in hospital. *Comput Methods Programs Biomed*. 2022;214:106584. <https://doi.org/10.1016/j.compbi.2021.106584>.
- [31] Soriano F. Stroke Prediction Dataset. 2024. Available: <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>.
- [32] Pranav Prakash. Stroke Prediction – Health Care Synthetic Dataset. 2024. Available: <https://www.kaggle.com/datasets/pranavp1999/stroke-prediction-health-care-synthetic-dataset>.
- [33] Sahriar S, et al. Unlocking stroke prediction: harnessing projection-based statistical feature extraction with ML algorithms. *Heliyon*. 2024;10(5):e27411. [https://doi.org/10.1016/j.heliyon.2024.10\(5\):e27411](https://doi.org/10.1016/j.heliyon.2024.10(5):e27411).

2024.e27411.

- [34] Wisesty UN, Wirayuda TAB, Sthevanie F, Rismala R. Analysis of data and feature processing on stroke prediction using wide range machine learning model. *J Online Inform.* 2024;9(1):29-40. <https://doi.org/10.15575/join.v9i1.1249>.
- [35] Yaqoob A, Verma NK, Aziz RM, Saxena A. Enhancing Feature Selection Through Metaheuristic Hybrid Cuckoo Search and Harris Hawks Optimization for Cancer Classification. In: *Metaheuristics for Machine Learning*, 1st ed. Kalita K, Ganesh N, Balamurugan S, eds. Wiley; 2024. pp. 95-134. <https://doi.org/10.1002/9781394233953.ch4>.
- [36] Abdel-Basset M, Abdel-Fatah L, Sangaiah AK. Metaheuristic algorithms: a comprehensive review. In: *Computational Intelligence for Multimedia Big Data on the Cloud with Engineering Applications*. Elsevier; 2018. pp. 185-231. <https://doi.org/10.1016/B978-0-12-813314-9.00010-4>.
- [37] Yaqoob A, Verma NK, Aziz RM, Shah MA. Optimizing cancer classification: a hybrid RDO-XGBoost approach for feature selection and predictive insights. *Cancer Immunol Immunother.* 2024;73(12):261 <https://doi.org/10.1007/s00262-024-03843-x>.
- [38] Yaqoob A, Verma NK, Aziz RM, Shah MA. RNA-Seq analysis for breast cancer detection: a study on paired tissue samples using hybrid optimization and deep learning techniques. *J Cancer Res Clin Oncol.* 2024;150(10):455. <https://doi.org/10.1007/s00432-024-05968-z>.