

**ĐẠI HỌC QUỐC GIA HÀ NỘI**  
**TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN**

**CẢI THIỆN DỰ ĐOÁN NGUY CƠ ĐỘT QUÝ BẰNG CÁCH  
TÍCH HỢP XGBOOST, PHÂN TÍCH THÀNH PHẦN CHÍNH  
TỐI ƯU VÀ TRÍ TUỆ NHÂN TẠO GIẢI THÍCH ĐƯỢC**

**Học phần:** HỌC MÁY VÀ KHAI PHÁ DỮ LIỆU

**Giảng viên hướng dẫn:** TRẦN TRỌNG HIẾU

**Học viên thực hiện:**

1. TÔNG VIỆT TÚ - Mã học viên: 25007845
2. NGUYỄN THỊ NHẬT LINH - Mã học viên: 25007871

**HÀ NỘI – 09/2026**

# THÔNG TIN BÀI BÁO GỐC

**Tên bài báo:** Improving stroke risk prediction by integrating XGBoost, optimized principal component analysis, and explainable artificial intelligence.

**Tác giả:** Lesia Mochurad, Viktoriia Babii, Yuliia Boliubash và Yulianna Mochurad.

**Tạp chí:** BMC Medical Informatics and Decision Making (2025) 25:63.

**DOI:** <https://doi.org/10.1186/s12911-025-02894-z>.

**Nguồn dữ liệu:**

- <https://www.kaggle.com/fedesoriano/stroke-prediction-datasets>
- <https://www.kaggle.com/datasets/pranavp1999/stroke-prediction-health-care-synthetic-dataset>

# GIỚI THIỆU BÁO CÁO

Báo cáo này được thực hiện trong khuôn khổ học phần Khai phá dữ liệu, với mục tiêu tìm hiểu và trình bày lại một công trình nghiên cứu ứng dụng học máy trong lĩnh vực y tế — cụ thể là bài toán dự đoán nguy cơ đột quỵ.

**Lý do lựa chọn bài báo:** đây là một nghiên cứu tích hợp đồng thời ba kỹ thuật đã được giới thiệu trong học phần: (1) thuật toán học máy có giám sát mạnh (XGBoost), (2) kỹ thuật giảm chiều dữ liệu (PCA), và (3) trí tuệ nhân tạo giải thích được (XAI, cụ thể là SHAP). Việc bài báo kết hợp cả ba khía cạnh này trong một quy trình xử lý dữ liệu y tế thực tế giúp minh họa rõ mối liên hệ giữa lý thuyết khai phá dữ liệu và một ứng dụng có ý nghĩa thực tiễn cao.

## Mục tiêu của báo cáo:

- Trình bày lại có hệ thống nội dung bài báo gốc bằng tiếng Việt, bám sát cấu trúc: bối cảnh – phương pháp – kết quả – thảo luận – kết luận.
- Diễn giải các công thức và thuật toán then chốt (PCA bằng phép quay Jacobi song song hóa OpenMP, hàm mục tiêu XGBoost, phương pháp SHAP) theo cách dễ tiếp cận.
- Liên hệ nội dung bài báo với các khái niệm đã học trong học phần (tiền xử lý dữ liệu, giảm chiều, cân bằng lớp, đánh giá mô hình, khả năng diễn giải mô hình).
- Đưa ra nhận xét, đánh giá về phương pháp, điểm mạnh, hạn chế và khả năng áp dụng của nghiên cứu.

**Phạm vi báo cáo:** báo cáo trình bày lại nội dung học thuật chính của bài báo gốc, thực nghiệm để kiểm chứng kết quả thực tế; từ đó rút ra nhận xét, đánh giá của cá nhân. Các số liệu, bảng biểu, hình vẽ là kết quả từ việc chạy thực nghiệm của nhóm khi thực hiện đề tài.

# TÓM TẮT

Tính cấp thiết của nghiên cứu xuất phát từ số lượng ngày càng tăng các bệnh của hệ mạch máu não, đặc biệt là đột quỵ, một trong những nguyên nhân hàng đầu gây tàn tật và tử vong trên thế giới. Để cải thiện các mô hình dự đoán nguy cơ đột quỵ về cả hiệu quả và khả năng diễn giải, nhóm tác giả đề xuất tích hợp các thuật toán học máy hiện đại với các phương pháp giảm chiều dữ liệu, cụ thể là XGBoost và phân tích thành phần chính (PCA) được tối ưu hóa, qua đó cấu trúc dữ liệu và tăng tốc độ xử lý, đặc biệt đối với các tập dữ liệu lớn. Trí tuệ nhân tạo giải thích được (XAI), cụ thể là SHAP, được tích hợp vào quá trình PCA, làm tăng tính minh bạch và khả năng diễn giải, giúp các chuyên gia y tế hiểu rõ hơn các yếu tố nguy cơ.

Mô hình được kiểm thử trên hai tập dữ liệu với pipeline chống rò rỉ dữ liệu. ROC-AUC kiểm định chéo đạt 0.824 (Dataset 1) và 0.997 (Dataset 2). Trên tập kiểm tra giữ nguyên tỷ lệ mất cân bằng gốc: Dataset 1 đạt accuracy 78.2% (recall 78%, precision 15.5%, MCC 0.282); Dataset 2 đạt accuracy 96.6% (recall 99.4%, precision 55.9%, MCC 0.732). PCA cải thiện có ý nghĩa thống kê ở Dataset 2 nhưng làm giảm nhẹ độ chính xác ở Dataset 1.

Kết quả cho thấy việc kết hợp XGBoost, PCA song song hóa bằng OpenMP và SHAP là khả thi và khả năng diễn giải được cho chuyên gia y tế. Đồng thời, kết quả cũng cho thấy rõ giới hạn thực tế của bài toán dự đoán đột quỵ trên dữ liệu mất cân bằng mạnh: độ chính xác tổng thể cao có thể gây hiểu lầm nếu không xem xét cùng với precision, recall, ROC-AUC và MCC. Do đó, phương pháp đề xuất có tiềm năng ứng dụng trong sàng lọc và hỗ trợ ra quyết định lâm sàng, với điều kiện được diễn giải đúng cách và kết hợp với đánh giá chuyên môn.

**Từ khóa:** Học máy, công nghệ tính toán song song, phương pháp SHAP, cân bằng lớp, phương pháp PCA.

# Mục lục

|                                                                       |             |
|-----------------------------------------------------------------------|-------------|
| <b>THÔNG TIN BÀI BÁO GỐC</b>                                          | <b>i</b>    |
| <b>GIỚI THIỆU BÁO CÁO</b>                                             | <b>ii</b>   |
| <b>TÓM TẮT</b>                                                        | <b>iii</b>  |
| <b>MỤC LỤC</b>                                                        | <b>iv</b>   |
| <b>DANH MỤC CÁC CHỮ VIẾT TẮT</b>                                      | <b>vi</b>   |
| <b>DANH MỤC HÌNH VẼ</b>                                               | <b>vii</b>  |
| <b>DANH MỤC BẢNG BIỂU</b>                                             | <b>viii</b> |
| <b>1 BỐI CẢNH</b>                                                     | <b>1</b>    |
| 1.1 Đặt vấn đề . . . . .                                              | 1           |
| 1.2 Vai trò của xử lý dữ liệu và giảm chiều (PCA) . . . . .           | 1           |
| 1.3 Nhu cầu về trí tuệ nhân tạo giải thích được (XAI) . . . . .       | 3           |
| 1.4 Tổng quan các phương pháp học máy hiện có cho dự đoán đột quy . . | 3           |
| 1.5 Các nghiên cứu liên quan . . . . .                                | 6           |
| 1.6 Mục tiêu và đóng góp của nghiên cứu . . . . .                     | 7           |
| <b>2 PHƯƠNG PHÁP</b>                                                  | <b>8</b>    |
| 2.1 Định nghĩa bài toán . . . . .                                     | 8           |
| 2.2 Tiền xử lý dữ liệu . . . . .                                      | 8           |
| 2.3 PCA song song hóa bằng OpenMP . . . . .                           | 9           |
| 2.4 Mô hình XGBoost . . . . .                                         | 9           |
| 2.5 Cân bằng lớp dữ liệu . . . . .                                    | 10          |
| 2.6 Diễn giải mô hình bằng SHAP . . . . .                             | 10          |

|          |                                                                   |           |
|----------|-------------------------------------------------------------------|-----------|
| 2.7      | Tổng kết phương pháp . . . . .                                    | 12        |
| <b>3</b> | <b>KẾT QUẢ</b>                                                    | <b>13</b> |
| 3.1      | Tổng quan dữ liệu và tiền xử lý . . . . .                         | 13        |
| 3.2      | Kết quả phân tích thành phần chính PCA và chiều dữ liệu . . . . . | 14        |
| 3.3      | Hiệu năng mô hình cơ sở (baseline) . . . . .                      | 16        |
| 3.4      | Tinh chỉnh siêu tham số (Grid Search) . . . . .                   | 19        |
| 3.5      | Kết quả kiểm định chéo (Cross-validation) . . . . .               | 20        |
| 3.6      | Hiệu năng trên tập kiểm tra (hold-out) . . . . .                  | 20        |
| 3.7      | Kiểm định ý nghĩa thống kê . . . . .                              | 23        |
| 3.8      | Phân tích trọng số PCA và kết quả SHAP . . . . .                  | 24        |
| 3.9      | Đánh giá hiệu năng song song hóa OpenMP . . . . .                 | 28        |
| <b>4</b> | <b>THẢO LUẬN</b>                                                  | <b>31</b> |
| <b>5</b> | <b>ĐỀ XUẤT HƯỚNG NGHIÊN CỨU TIẾP THEO</b>                         | <b>34</b> |
|          | <b>KẾT LUẬN</b>                                                   | <b>36</b> |
|          | <b>TÀI LIỆU THAM KHẢO</b>                                         | <b>37</b> |

# DANH MỤC CÁC CHỮ VIẾT TẮT

| Chữ viết tắt | Nội dung                                                               |
|--------------|------------------------------------------------------------------------|
| AI           | Trí tuệ nhân tạo (Artificial Intelligence)                             |
| ANN          | Mạng nơ-ron nhân tạo (Artificial Neural Network)                       |
| CK           | Hệ số Cohen's Kappa                                                    |
| CNN          | Mạng nơ-ron tích chập (Convolutional Neural Network)                   |
| EDA          | Phân tích dữ liệu khám phá (Exploratory Data Analysis)                 |
| IQR          | Khoảng tứ phân vị (Interquartile Range)                                |
| k-NN         | K láng giềng gần nhất (k-Nearest Neighbors)                            |
| LIME         | Local Interpretable Model-agnostic Explanations                        |
| LSTM         | Long Short-Term Memory                                                 |
| MCC          | Hệ số tương quan Matthews (Matthews Correlation Coefficient)           |
| OpenMP       | Open Multi-Processing                                                  |
| PCA          | Phân tích thành phần chính (Principal Component Analysis)              |
| ROC-AUC      | Diện tích dưới đường cong ROC                                          |
| SHAP         | SHapley Additive exPlanations                                          |
| SMOTE        | Synthetic Minority Over-sampling Technique                             |
| SVM          | Máy vector hỗ trợ (Support Vector Machine)                             |
| XAI          | Trí tuệ nhân tạo giải thích được (Explainable Artificial Intelligence) |
| XGBoost      | Extreme Gradient Boosting                                              |

## Danh sách hình vẽ

|      |                                                                        |    |
|------|------------------------------------------------------------------------|----|
| 2.1  | Sơ đồ luồng của phương pháp đề xuất. . . . .                           | 11 |
| 3.1  | Phương sai tích lũy theo thành phần - Dataset 1 . . . . .              | 15 |
| 3.2  | Tỷ lệ phương sai được giải thích bởi từng thành phần - Dataset 1 . . . | 15 |
| 3.3  | Phương sai tích lũy theo thành phần - Dataset 2 . . . . .              | 15 |
| 3.4  | Tỷ lệ phương sai được giải thích bởi từng thành phần - Dataset 2 . . . | 15 |
| 3.5  | Trọng số đặc trưng trong thành phần chính thứ nhất - Dataset 1 . . . . | 16 |
| 3.6  | Trọng số đặc trưng trong thành phần chính thứ hai - Dataset 1 . . . .  | 16 |
| 3.7  | Trọng số đặc trưng trong thành phần chính thứ nhất - Dataset 2 . . . . | 16 |
| 3.8  | Trọng số đặc trưng trong thành phần chính thứ hai - Dataset 2 . . . .  | 16 |
| 3.9  | Ma trận nhầm lẫn của mô hình không có PCA - Dataset 1 . . . . .        | 18 |
| 3.10 | Ma trận nhầm lẫn của mô hình có PCA - Dataset 1 . . . . .              | 18 |
| 3.11 | Ma trận nhầm lẫn của mô hình không có PCA - Dataset 2 . . . . .        | 18 |
| 3.12 | Ma trận nhầm lẫn của mô hình có PCA - Dataset 2 . . . . .              | 18 |
| 3.13 | Ma trận nhầm lẫn của mô hình cuối cùng - Dataset 1 . . . . .           | 22 |
| 3.14 | Đường cong ROC-AUC của mô hình cuối cùng - Dataset 1 . . . . .         | 22 |
| 3.15 | Ma trận nhầm lẫn của mô hình cuối cùng - Dataset 2 . . . . .           | 23 |
| 3.16 | Đường cong ROC-AUC của mô hình cuối cùng - Dataset 2 . . . . .         | 23 |
| 3.17 | SHAP Waterfall (Dataset 1). . . . .                                    | 25 |
| 3.18 | SHAP Bar (Dataset 1). . . . .                                          | 25 |
| 3.19 | SHAP Beewarm (Dataset 1). . . . .                                      | 26 |
| 3.20 | SHAP Waterfall (Dataset 2). . . . .                                    | 26 |
| 3.21 | SHAP Bar (Dataset 2). . . . .                                          | 27 |
| 3.22 | SHAP Beewarm (Dataset 2). . . . .                                      | 27 |
| 3.23 | Thời gian thực thi Jacobi theo kích thước ma trận . . . . .            | 29 |
| 3.24 | Speedup của OpenMP so với phiên bản tuần tự . . . . .                  | 29 |



## Danh sách bảng

|     |                                                                           |    |
|-----|---------------------------------------------------------------------------|----|
| 1.1 | So sánh các phương pháp học máy hiện có cho dự đoán đột quy . . . .       | 4  |
| 3.1 | Tổng quan dữ liệu sau làm sạch và chia tập . . . . .                      | 14 |
| 3.2 | Kết quả PCA (ngưỡng phương sai giải thích 95%) . . . . .                  | 14 |
| 3.3 | Hiệu năng mô hình cơ sở (baseline) trên tập kiểm tra . . . . .            | 17 |
| 3.4 | Siêu tham số tốt nhất tìm được bằng Grid Search . . . . .                 | 19 |
| 3.5 | Kết quả kiểm định chéo 10-fold (trung bình $\pm$ độ lệch chuẩn) . . . . . | 20 |
| 3.6 | Kết quả thực nghiệm chi tiết trên hai tập dữ liệu . . . . .               | 21 |
| 3.7 | Hiệu năng trên tập kiểm tra (hold-out cuối cùng) . . . . .                | 22 |
| 3.8 | So sánh hiệu năng và kiểm định thống kê tác động của PCA . . . . .        | 24 |
| 3.9 | Thời gian thực thi Jacobi tuần tự và OpenMP . . . . .                     | 28 |
| 4.1 | So sánh hiệu năng với các nghiên cứu liên quan . . . . .                  | 31 |
| 4.2 | Kết quả các chỉ số đánh giá mô hình . . . . .                             | 32 |

# Chương 1

## BỐI CẢNH

### 1.1 Đặt vấn đề

Đột quỵ vẫn là một trong những nguyên nhân hàng đầu gây tử vong và tàn tật trên toàn thế giới. Tỷ lệ đột quỵ gia tăng đòi hỏi các chiến lược phòng ngừa hiệu quả và chẩn đoán kịp thời. Việc sử dụng các công nghệ tiên tiến như học máy [1–3] có thể cải thiện đáng kể dự đoán nguy cơ và khả năng nhận diện sớm những bệnh nhân cần được chăm sóc. Hiểu được cơ chế của các rối loạn mạch máu não là chìa khóa để phát triển các chiến lược phòng ngừa và điều trị đột quỵ hiệu quả, qua đó giảm thiểu hậu quả của bệnh và cải thiện chất lượng cuộc sống của bệnh nhân.

Việc sử dụng trí tuệ nhân tạo trong bối cảnh này mở ra những triển vọng mới để cải thiện thực hành y khoa. Tích hợp các mô hình học máy như XGBoost hoặc mạng nơ-ron cho phép dự đoán chính xác nguy cơ đột quỵ dựa trên các đặc trưng riêng của từng bệnh nhân [4,5]. Điều này bao gồm cả các yếu tố nguy cơ truyền thống lẫn các tham số mới được xác định thông qua phân tích lượng dữ liệu lớn. Nhờ đó, các chuyên gia y tế có thể đánh giá nguy cơ và triển khai các biện pháp phòng ngừa kịp thời hiệu quả hơn. Các thuật toán học máy như XGBoost thể hiện mức độ chính xác cao khi giải quyết những bài toán phức tạp, bao gồm cả dự báo y khoa. Việc tối ưu các thuật toán này cho những mục tiêu cụ thể, trong đó có dự đoán nguy cơ đột quỵ, là một bước quan trọng để nâng cao hiệu quả của các quyết định y tế.

### 1.2 Vai trò của xử lý dữ liệu và giảm chiều (PCA)

Giảm tác động của các bất thường và nhiễu trong dữ liệu là một bước then chốt trong xử lý dữ liệu, bởi chất lượng dữ liệu ảnh hưởng trực tiếp đến độ chính xác và độ tin cậy của mô hình học máy. Các bất thường như ngoại lệ hoặc dữ liệu sai có thể làm sai lệch đáng kể kết quả phân tích, dẫn đến các kết luận không chính xác hoặc thậm chí

các khuyến nghị có hại [6]. Phân tích thành phần chính (PCA) giúp xác định và loại bỏ các bất thường này bằng cách tập trung vào những đặc trưng chính và giàu thông tin nhất của tập dữ liệu [7,8]. Điều này không chỉ cải thiện chất lượng dữ liệu mà còn nâng cao độ tin cậy của kết quả, bởi các mô hình được huấn luyện trên dữ liệu đã làm sạch có thể đưa ra dự báo chính xác và ổn định hơn.

Ngoài ra, PCA làm giảm độ phức tạp của mô hình, điều đặc biệt quan trọng trong các ứng dụng y khoa nơi các quyết định có thể ảnh hưởng đến sức khỏe bệnh nhân [9]. Bằng cách giảm số lượng biến cần phân tích, PCA đơn giản hóa quá trình huấn luyện mô hình và dẫn đến xử lý dữ liệu nhanh hơn. Sự đơn giản của các mô hình sau khi áp dụng PCA khiến chúng dễ hiểu và dễ diễn giải hơn đối với các chuyên gia y tế vốn có thể không có kiến thức chuyên sâu về thống kê hay học máy. Điều này quan trọng vì bác sĩ và nhân viên lâm sàng cần hiểu cách thức và lý do một dự báo cụ thể được đưa ra trước khi sử dụng trong thực hành. Hơn nữa, giảm số lượng biến giúp tránh quá tải thông tin, từ đó nâng cao khả năng hiểu các yếu tố nguy cơ nền tảng. Vì vậy, ứng dụng PCA trong nghiên cứu và thực hành y khoa là một bước quan trọng hướng tới tối ưu hóa quá trình ra quyết định và tăng hiệu quả của can thiệp y tế.

Tuy nhiên, thuật toán tuần tự ở giai đoạn tiền xử lý có thể tiêu tốn nhiều thời gian do độ phức tạp tính toán cao, bởi PCA truyền thống đòi hỏi tài nguyên đáng kể để tính các trị riêng và vector riêng của ma trận hiệp phương sai, đặc biệt nghiêm trọng đối với các tập dữ liệu lớn. Khi quá trình xử lý chỉ diễn ra trên một lõi CPU, tài nguyên tính toán sẵn có không được tận dụng, dẫn đến độ trễ. Vì vậy, trong nghiên cứu này, nhóm tác giả đề xuất sử dụng các công nghệ tính toán song song hiện đại, cụ thể là OpenMP, cho phép áp dụng phương pháp đề xuất trên bất kỳ hệ thống máy tính đa lõi nào [10–12]. Điều này sẽ tăng hiệu quả xử lý dữ liệu nhờ tối ưu hóa việc sử dụng tài nguyên tính toán, từ đó giảm thời gian thực thi thuật toán và nâng cao hiệu năng.

### **1.3 Nhu cầu về trí tuệ nhân tạo giải thích được (XAI)**

Việc áp dụng PCA có thể vẫn là một “hộp đen”, gây khó khăn cho việc diễn giải và hiểu những yếu tố nào đã đóng góp vào quá trình giảm chiều dữ liệu. Điều này có thể làm giảm niềm tin của các chuyên gia y tế và nhà nghiên cứu đối với mô hình, vì họ có thể không hiểu tại sao một số đặc trưng lại tác động đến kết quả mạnh hơn các đặc trưng khác. Vì vậy, cần tăng cường bước này bằng các kỹ thuật XAI [13], giúp xác định những đặc trưng có ảnh hưởng lớn nhất đến kết quả PCA, nhờ đó các nhà nghiên cứu và chuyên gia y tế hiểu rõ hơn cách các đặc tính cụ thể của dữ liệu hình thành kết quả phân tích. Tương tự nghiên cứu [14] đề xuất một cách tiếp cận để tăng cường bảo mật điện toán đám mây bằng cách phân tích hành vi người dùng và đánh giá độ tin cậy của họ, nhóm tác giả sử dụng các phương pháp trí tuệ nhân tạo giải thích được nhằm cải thiện khả năng diễn giải và tính minh bạch của các mô hình dự đoán nguy cơ đột quỵ.

### **1.4 Tổng quan các phương pháp học máy hiện có cho dự đoán đột quỵ**

Dự đoán đột quỵ là một khía cạnh quan trọng của y học, bởi chẩn đoán kịp thời có thể làm giảm đáng kể hậu quả của bệnh và cải thiện chất lượng cuộc sống của bệnh nhân. Nhiều phương pháp học máy khác nhau được sử dụng trong nghiên cứu khoa học, mỗi phương pháp có ưu điểm và nhược điểm riêng. Bảng 1.1 trình bày so sánh các phương pháp học máy hiện có cho dự đoán đột quỵ.

**Bảng 1.1.** So sánh các phương pháp học máy hiện có cho dự đoán đột quy

| Phương pháp      | Mô tả                                                                                                                                                                                | Ưu điểm                                                                                  | Nhược điểm                                                                     |
|------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| Hồi quy Logistic | Mô hình hóa xác suất đột quy dựa trên các yếu tố nguy cơ. Sử dụng hàm sigmoid và gradient descent để xây dựng mô hình. Đánh giá hiệu năng mô hình khi có và không có regularization. | Độ chính xác cao (trên 95%), có thể cải thiện thông qua regularization và dễ triển khai. | Độ chính xác hạn chế khi quan hệ phi tuyến; nhạy với lựa chọn tham số.         |
| Cây quyết định   | Một tập các cây quyết định được huấn luyện trên các tập con dữ liệu khác nhau, sử dụng biểu quyết để đưa ra quyết định cuối cùng.                                                    | Trực quan hóa quyết định, dễ diễn giải.                                                  | Có xu hướng overfitting nếu không regularization.                              |
| Random Forest    | Tổng hợp kết quả từ nhiều cây quyết định, làm giảm nguy cơ overfitting.                                                                                                              | Độ chính xác cao (96%), độ tin cậy tốt.                                                  | Có thể chậm trên các tập dữ liệu lớn.                                          |
| Naive Bayes      | Phân loại dựa trên giả định các đặc trưng độc lập.                                                                                                                                   | Đơn giản, hiệu quả trong nhiều bài toán phân loại.                                       | Độ chính xác đạt 82%; hạn chế khi tồn tại quan hệ phức tạp giữa các đặc trưng. |

| Phương pháp                | Mô tả                                                                                                                                                        | Ưu điểm                                                                                                    | Nhược điểm                                                                                          |
|----------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| k-NN                       | Phân loại các quan sát mới dựa trên các láng giềng gần nhất trong tập huấn luyện.                                                                            | Đơn giản và rõ ràng.                                                                                       | Khó mở rộng, nhạy với lựa chọn tham số $k$ .                                                        |
| SVM                        | Sử dụng các hàm kernel để xử lý phân bố phi tuyến.                                                                                                           | Hiệu quả cao trên dữ liệu nhiều chiều.                                                                     | Nhạy với lựa chọn tham số, gặp khó khăn với tập dữ liệu lớn.                                        |
| Học sâu (CNN)              | Sử dụng mạng nơ-ron tích chập (CNN) để phân tích ảnh y khoa.                                                                                                 | Độ chính xác cao trong phát hiện các mẫu phức tạp.                                                         | Đòi hỏi tập dữ liệu lớn và tài nguyên tính toán mạnh.                                               |
| Mạng nơ-ron nhân tạo (ANN) | Mô hình học máy sử dụng resampling, tránh rò rỉ dữ liệu, lựa chọn đặc trưng và các kỹ thuật diễn giải như permutation importance và LIME để dự đoán đột quỵ. | Khả năng diễn giải cao với LIME, resampling và lựa chọn đặc trưng hiệu quả; độ chính xác dự báo cao (95%). | Phụ thuộc vào kiểm định trên tập dữ liệu bên ngoài và cần tối ưu liên tục để đạt hiệu năng tốt hơn. |
| XGBoost                    | Thuật toán tăng cường gradient kết hợp nhiều phương pháp để đạt kết quả tốt hơn.                                                                             | Hiệu quả dự báo và khả năng diễn giải cao; độ chính xác trên 97%.                                          | Khó cấu hình tham số, yêu cầu tài nguyên tính toán.                                                 |

## 1.5 Các nghiên cứu liên quan

Công trình [15] so sánh các thuật toán như hồi quy logistic, phân loại cây quyết định, random forest và voting classifier; random forest đạt độ chính xác cao nhất, khoảng 96%. Nghiên cứu [16] đánh giá hiệu quả các thuật toán phân loại, đặc biệt Naive Bayes, đạt độ chính xác khoảng 82%, nhưng dữ liệu bị giới hạn ở một khu vực địa lý duy nhất, hạn chế khả năng khái quát hóa.

Nghiên cứu [17] và [18] tập trung vào stacking và lựa chọn đặc trưng tự động; [17] cho thấy phương pháp stacking đạt AUC 98.9%, trong khi [18] nhấn mạnh tầm quan trọng của dữ liệu chất lượng cao. Các nghiên cứu [19] và [20] sử dụng XGBoost, đạt độ chính xác 97.56% và AUC 0.8595 tương ứng, cho thấy tiềm năng áp dụng lâm sàng ở cấp cá nhân.

Công trình [21] sử dụng XGBoost để dự đoán sự xuất hiện của bệnh, đạt độ chính xác cao (97%) khi dự đoán trường hợp không đột quỵ, nhưng độ chính xác dự đoán đột quỵ chỉ khoảng 20%; nghiên cứu này cũng gặp dữ liệu thiếu ở biến "bmi". Công trình [22] cho thấy Random Forest đạt độ chính xác cao nhất ( $\sim 96\%$ ), nhưng bị giới hạn bởi kích thước mẫu. Công trình [23] nghiên cứu CNN và LSTM, cho thấy các phương pháp học máy truyền thống trong một số trường hợp vẫn vượt học sâu.

Các tác giả của [24] đề xuất dự đoán đột quỵ tim bằng ANN với độ chính xác 95%, áp dụng permutation importance và LIME, nhưng không sử dụng giảm chiều dữ liệu (PCA) hay tính toán song song — đây là hai điểm mà nghiên cứu hiện tại bổ sung so với [24]. Công trình gần đây nhất [25] trình bày tối ưu XGBoost bằng ensemble và tối ưu Bayes, cho hiệu năng cao nhưng chưa nhấn mạnh việc tích hợp cơ chế giải thích để tăng độ tin cậy trong ứng dụng lâm sàng.

Tổng quan tài liệu cho thấy những thách thức chính vẫn là khả năng diễn giải thấp của mô hình học máy và độ phức tạp khi xử lý các tập dữ liệu y tế lớn có nhiều đặc trưng. Phần lớn phương pháp hiện đại dùng các thuật toán mạnh để cải thiện độ chính xác nhưng chưa quan tâm đầy đủ đến giảm chiều dữ liệu và giải thích đóng góp của từng đặc trưng vào kết quả cuối cùng [26,27].

## 1.6 Mục tiêu và đóng góp của nghiên cứu

Nghiên cứu này nhằm cải thiện quá trình dự đoán nguy cơ đột quỵ bằng cách tích hợp thuật toán XGBoost với phương pháp PCA tối ưu và triển khai các phương pháp XAI nhằm tăng tính minh bạch và khả năng diễn giải của kết quả phân tích. Đóng góp chính của phương pháp đề xuất gồm:

- Kết hợp XGBoost với PCA ở giai đoạn tiền xử lý để giảm chiều và cải thiện cấu trúc dữ liệu, qua đó tăng độ chính xác của mô hình.
- Song song hóa PCA bằng công nghệ OpenMP, giảm đáng kể thời gian xử lý các tập dữ liệu lớn — quan trọng trong các ứng dụng y tế nơi tốc độ ra quyết định có thể mang tính sống còn.
- Tích hợp XAI vào quá trình PCA, làm tăng tính minh bạch và khả năng hiểu mô hình, hỗ trợ phát hiện bất thường và nhiễu trong dữ liệu.

Do đó, tính mới của phương pháp nằm ở việc áp dụng tích hợp các phương pháp học máy, công nghệ tính toán và công cụ giải thích, cho phép tạo ra các mô hình dự báo nguy cơ đột quỵ chính xác hơn, nhanh hơn và dễ diễn giải hơn, có ý nghĩa lớn đối với sự phát triển của ngành chăm sóc sức khỏe.



## Chương 2

# PHƯƠNG PHÁP

### 2.1 Định nghĩa bài toán

Giả sử có tập dữ liệu

$$D = \{(x_i, y_i)\}, \quad i = 1, \dots, N,$$

gồm các cặp  $(x_i, y_i)$ , trong đó  $x_i \in \mathbb{R}^d$  là vector các đặc trưng đầu vào của bệnh nhân,  $y_i \in \{0, 1\}$  là biến nhị phân, với 1 biểu thị có đột quỵ và 0 biểu thị không đột quỵ;  $N$  là số bản ghi và  $d$  là số đặc trưng đầu vào. Biến mục tiêu  $y_i$  được sử dụng để huấn luyện và kiểm thử mô hình học máy.

### 2.2 Tiền xử lý dữ liệu

Trước khi xử lý dữ liệu, kiểm tra bản ghi trùng được thực hiện nhằm bảo đảm tính duy nhất của tập dữ liệu và tránh làm sai lệch kết quả mô hình do các mẫu lặp. Các giá trị thiếu (missing) chỉ xuất hiện ở cột BMI và được điền bằng giá trị trung bình, giúp duy trì phân bố của cột và tránh mô hình bị thiên lệch do dữ liệu không đầy đủ. Ngoại lai (outliers) được kiểm tra bằng boxplot kết hợp phương pháp khoảng tứ phân vị (IQR): các giá trị nằm ngoài 1.5 lần IQR được xác định là bất thường và thay bằng giá trị biên tương ứng. Những điều chỉnh này được thực hiện để bảo đảm tính nhất quán của dữ liệu và ngăn các bất thường làm sai lệch kết quả mô hình.

Phân tích dữ liệu khám phá (EDA) [28] được sử dụng để phân tích sơ bộ và xác định các vấn đề tiềm ẩn, chẳng hạn mất cân bằng lớp và dữ liệu thiếu, có thể ảnh hưởng tiêu cực đến mô hình.

## 2.3 PCA song song hóa bằng OpenMP

Dữ liệu được tâm hóa bằng cách xây dựng ma trận

$$X_{\text{centered}} = X - \bar{x}, \quad \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i,$$

trong đó  $\bar{x}$  là vector giá trị trung bình.

Ma trận hiệp phương sai  $S$  được tính như sau:

$$S = \frac{1}{N-1} X_{\text{centered}}^T X_{\text{centered}}.$$

Các trị riêng và vector riêng của ma trận hiệp phương sai  $S$  được tính bằng phương pháp Jacobi, được song song hóa bằng OpenMP để tăng tốc:

$$Sv_j = \lambda_j v_j,$$

trong đó  $\lambda_j$  là các trị riêng và  $v_j$  là các vector riêng.

Để giảm chiều,  $k$  vector riêng lớn nhất  $V_k$  được chọn, sau đó dữ liệu được biến đổi thành ma trận đặc trưng mới:

$$X_{\text{reduced}} = X_{\text{centered}} V_k.$$

## 2.4 Mô hình XGBoost

Ma trận đặc trưng  $X_{\text{reduced}}$  được đưa vào thuật toán XGBoost. Hàm mục tiêu của mô hình có dạng:

$$L(\theta) = \sum_{i=1}^N \ell(y_i, \hat{y}_i(\theta)) + \Omega(\theta),$$

trong đó

$$\ell(y_i, \hat{y}_i) = -[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

là hàm mất mát logistic,  $\hat{y}_i(\theta)$  là dự báo của mô hình,  $\theta$  là các tham số mô hình và  $\Omega(\theta)$  là thành phần regularization.

Để tối ưu hiệu năng mô hình, chúng tôi sử dụng Grid Search để điều chỉnh siêu tham số. Quy trình này tìm kiếm có hệ thống trên một tập siêu tham số xác định trước nhằm

tối thiểu hóa hàm mất mát và cải thiện độ chính xác. Trong trường hợp này, các siêu tham số của XGBoost được điều chỉnh gồm độ sâu cây, learning rate, số lượng cây, gamma (regularization), minimum child weight, tỷ lệ dữ liệu huấn luyện và tỷ lệ đặc trưng. Mô hình được đánh giá bằng ROC-AUC, phù hợp với bài toán phân loại nhị phân và cho biết khả năng phân biệt giữa các lớp. Mục tiêu là tìm sự cân bằng tối ưu giữa độ chính xác huấn luyện và khả năng khái quát hóa, ngăn overfitting trong khi cải thiện hiệu năng mô hình.

## 2.5 Cân bằng lớp dữ liệu

Các phương pháp cân bằng sau được sử dụng:

- Undersampling để giảm số lượng mẫu của lớp chiếm ưu thế.
- Oversampling bằng SMOTE (Synthetic Minority Over-sampling Technique) [29] để sinh các mẫu tổng hợp cho lớp ít đại diện hơn.


## 2.6 Diễn giải mô hình bằng SHAP

Để diễn giải dự báo của mô hình, chúng tôi sử dụng phương pháp SHAP [30], ước lượng đóng góp của từng đặc trưng  $j$  vào dự báo của từng mẫu  $i$ :

$$\text{SHAP}_j(x_i) = \phi_j(x_i),$$

trong đó  $\phi_j(x_i)$  là giá trị SHAP thể hiện đóng góp của đặc trưng  $j$  vào dự báo cho mẫu  $i$ . Ở đây  $i$  là chỉ số của các mẫu riêng lẻ trong tập dữ liệu,  $i = 1, 2, \dots, N$ , và  $N$  là số bản ghi;  $j$  là chỉ số của các đặc trưng riêng lẻ,  $j = 1, 2, \dots, d$ , với  $d$  là số đặc trưng đầu vào của mỗi bệnh nhân. SHAP được áp dụng cho các đặc trưng gốc chứ không phải các thành phần chính, nhằm duy trì khả năng diễn giải dự báo mô hình theo các biến đầu vào ban đầu.

Hình 2.1 minh họa quy trình của phương pháp đề xuất. Thuật toán 1 mô tả cách triển khai tìm trị riêng và vector riêng bằng thuật toán quay Jacobi sử dụng OpenMP.



**Hình 2.1.** Sơ đồ luồng của phương pháp đề xuất.

### Thuật toán 1: Tính trị riêng và vector riêng song song

Thuật toán trình bày phép quay Jacobi song song. Ma trận đầu vào được khởi tạo cùng ma trận vector riêng, sau đó lặp cho đến khi hội tụ hoặc đạt số vòng lặp tối đa. Ở mỗi vòng lặp, thuật toán tìm phần tử ngoài đường chéo có trị tuyệt đối lớn nhất, tính góc quay Jacobi, cập nhật ma trận và vector riêng, đồng thời sử dụng các chỉ thị `#pragma omp` để song song hóa những vòng lặp độc lập. Các vùng tới hạn (critical) được dùng khi nhiều luồng có khả năng cập nhật chung một biến, nhằm ngăn race condition. Thuật toán kiểm tra hội tụ bằng cách theo dõi ngưỡng chính xác `eps`, cho phép thoát hiệu quả khỏi vòng lặp khi đạt độ chính xác mong muốn. Sau hội tụ, các phần tử đường chéo của ma trận chứa các trị riêng và ma trận tích lũy chứa các vector riêng.

Việc lựa chọn phương pháp Jacobi xuất phát từ tính phù hợp của nó đối với song song hóa khi làm việc với các tập dữ liệu nhiều chiều. Mặc dù các phương pháp thay thế như phân rã QR hoặc power iteration cũng có thể hiệu quả, phương pháp Jacobi được chọn vì tính đơn giản và khả năng cân bằng giữa độ chính xác và hiệu năng. Trong

nghiên cứu tương lai, nhóm tác giả dự định so sánh Jacobi với các phương pháp thay thế này. Triển khai PCA bằng OpenMP cải thiện đáng kể tốc độ xử lý các tập dữ liệu lớn bằng cách song song hóa các bước then chốt như tính trị riêng và vector riêng của ma trận hiệp phương sai, phân phối tải trên nhiều luồng và giảm đáng kể thời gian thực thi.

## **2.7 Tổng kết phương pháp**

Tóm lại, phương pháp đề xuất xây dựng một pipeline gồm ba khối chính: XGBoost để dự báo, PCA (song song hóa bằng OpenMP) để giảm chiều, và SHAP để diễn giải kết quả.

XGBoost được lựa chọn vì độ tin cậy trên các tập dữ liệu mất cân bằng, nơi các trường hợp thuộc lớp thiểu số xuất hiện phổ biến như trong bài toán này. PCA giúp giảm chiều dữ liệu y tế nhiều chiều, giữ lại thông tin quan trọng nhất đồng thời loại bỏ dư thừa và nhiễu. SHAP cung cấp cách diễn giải dự báo theo các biến có ý nghĩa lâm sàng, giúp bác sĩ hiểu các yếu tố khác nhau tác động thế nào đến nguy cơ đột quỵ. Sự kết hợp này cho phép xử lý các tập dữ liệu lớn, phức tạp, hỗ trợ bác sĩ ra quyết định dựa trên sự giải thích của mô hình, đồng thời giảm nguy cơ overfitting và cải thiện hiệu năng dự báo.

## Chương 3

### KẾT QUẢ

#### 3.1 Tổng quan dữ liệu và tiền xử lý

Phương pháp đề xuất được kiểm thử trên hai tập dữ liệu mất cân bằng: Dataset 1 (5.110 bản ghi, 4.87% ca đột quy) và Dataset 2 (5,542,261 bản ghi, 4.26% ca đột quy). Cả hai tập đều được phân chia theo tỷ lệ 80/20 cho huấn luyện/kiểm thử, kết hợp kỹ thuật phân tầng (stratify) theo biến mục tiêu để bảo toàn tỷ lệ phân bố lớp. Quá trình tiền xử lý được thực hiện tương thích với đặc thù từng tập dữ liệu:

- **Xử lý dữ liệu và chuẩn hóa:** Với Dataset 1, giá trị khuyết thiếu (missing) ở biến BMI được gán bằng giá trị trung bình trên tập huấn luyện; trong khi Dataset 2 loại bỏ trực tiếp các bản ghi thiếu. Cả hai tập đều xử lý giá trị ngoại lai (outliers) bằng phương pháp khoảng tứ phân vị (IQR) và áp dụng mã hóa one-hot cho các biến định tính, đưa không gian dữ liệu về đồng nhất 21 đặc trưng đầu vào.
- **Cân bằng lớp:** Dataset 1 sử dụng kỹ thuật SMOTE để sinh mẫu tổng hợp cho lớp thiếu số quy mô nhỏ. Dataset 2 áp dụng phương pháp lấy mẫu giảm ngẫu nhiên (random undersampling) nhằm tối ưu chi phí tính toán, tránh hiện tượng quá khớp (overfitting) và nâng cao hiệu năng nhận diện ca bệnh.

Về chất lượng dữ liệu trước khi xử lý: biến duy nhất có giá trị thiếu ở cả hai tập dữ liệu là BMI, với tỷ lệ thiếu gần tương đương nhau — 201/5,110 bản ghi (3.93%) ở Dataset 1 và 3,955/5,542,261 bản ghi (3.96%) ở Dataset 2; các biến còn lại không có giá trị thiếu. Về ngoại lệ theo ngưỡng IQR (tính trước khi cắt), avg\_glucose\_level có tỷ lệ ngoại lệ cao nhất ở cả hai tập (Dataset 1: 12.27%; Dataset 2: 12.03%), tiếp theo là BMI (Dataset 1: 2.24%; Dataset 2: 2.28%); riêng biến tuổi không có bản ghi nào vượt ngưỡng IQR ở cả hai tập dữ liệu.

Kết quả sau khi xử lý và làm sạch dữ liệu ở Dataset 1, 2 được thể hiện ở bảng 3.1

**Bảng 3.1.** Tổng quan dữ liệu sau làm sạch và chia tập

| Chỉ tiêu                           | Dataset 1     | Dataset 2             |
|------------------------------------|---------------|-----------------------|
| Số bản ghi sau làm sạch            | 5,110         | 5,542,261             |
| Số ca dương tính (đột quy)         | 249 (4.87%)   | 235,961 (4.26%)       |
| Số dòng train / test               | 4,088 / 1,022 | 4,433,808 / 1,108,453 |
| Dương tính trong train / test      | 199 (4.87%)   | 188,769 (4.26%)       |
|                                    | / 50 (4.89%)  | / 47,192 (4.26%)      |
| Số đặc trưng đầu vào (sau one-hot) | 21            | 21                    |
| Chiến lược cân bằng lớp            | SMOTE         | Random undersampling  |

### 3.2 Kết quả phân tích thành phần chính PCA và chiều dữ liệu

Bảng 3.2 trình bày kết quả giảm chiều bằng PCA. Để tăng hiệu quả tính toán khi tìm trị riêng và vector riêng của ma trận hiệp phương sai, thuật toán quay Jacobi được song song hóa bằng OpenMP.

**Bảng 3.2.** Kết quả PCA (ngưỡng phương sai giải thích 95%)

| Chỉ tiêu                    | Dataset 1 | Dataset 2 |
|-----------------------------|-----------|-----------|
| Số đặc trưng đầu vào        | 21        | 21        |
| Số thành phần chính giữ lại | 11        | 11        |
| Tỷ lệ phương sai giải thích | 96.90%    | 96.96%    |


Kết quả PCA cho thấy với ngưỡng 95% phương sai, 11 thành phần chính được giữ lại, giải thích được 96,90% phương sai với Dataset 1 và 96.96% đối với Dataset 2. Trước PCA có 21 đặc trưng, sau tiền xử lý và sau PCA còn 11 đặc trưng, giảm gần một nửa số đặc trưng nhưng vẫn giữ được gần như toàn bộ thông tin.

Hình 3.1, 3.3 thể hiện phương sai tích lũy theo thành phần của Dataset 1,2, cho thấy phương sai tích lũy như thế nào khi sử dụng phương pháp thành phần chính.


Hình 3.2, 3.4 minh họa tỷ lệ phần trăm phương sai được giải thích bởi từng thành

phần, cho phép ước lượng đóng góp của chúng vào tổng phương sai dữ liệu.


Phân tích chi tiết theo từng thành phần cho thấy hai thành phần đầu tiên đóng góp lớn nhất: PC1 giải thích khoảng 30.9% phương sai và PC2 giải thích thêm khoảng 15.6% (cộng dồn khoảng 46.5%) — tỷ lệ gần như giống hệt nhau giữa Dataset 1 và Dataset 2, cho thấy cấu trúc tương quan giữa các đặc trưng khá ổn định dù quy mô mẫu chênh lệch rất lớn (5,110 so với 5,542,261 bản ghi). Từ PC3 trở đi, mỗi thành phần chỉ đóng góp thêm dưới 12%, giảm dần đều cho đến khi đạt ngưỡng 95% ở thành phần thứ 11.




**Hình 3.1.** Phương sai tích lũy theo thành phần - Dataset 1



**Hình 3.2.** Tỷ lệ phương sai được giải thích bởi từng thành phần - Dataset 1




**Hình 3.3.** Phương sai tích lũy theo thành phần - Dataset 2




**Hình 3.4.** Tỷ lệ phương sai được giải thích bởi từng thành phần - Dataset 2

Hình 3.5, 3.6 cho thấy ở Dataset 1 thành phần thứ nhất chịu ảnh hưởng đáng kể bởi age (tuổi), bmi và avg\_glucose\_level. Thành phần thứ hai chịu ảnh hưởng nhiều nhất bởi avg\_glucose\_level. Điều này cũng tương tự khi phân tích ở Dataset 2 (Hình 3.7, 3.8)







**Hình 3.5.** Trọng số đặc trưng trong thành phần chính thứ nhất - Dataset 1



**Hình 3.6.** Trọng số đặc trưng trong thành phần chính thứ hai - Dataset 1



**Hình 3.7.** Trọng số đặc trưng trong thành phần chính thứ nhất - Dataset 2



**Hình 3.8.** Trọng số đặc trưng trong thành phần chính thứ hai - Dataset 2

### 3.3 Hiệu năng mô hình cơ sở (baseline)


Trước khi cân bằng lớp và tinh chỉnh siêu tham số, XGBoost với tham số mặc định được huấn luyện trực tiếp trên dữ liệu mất cân bằng gốc, có và không có PCA, để làm mốc so sánh (baseline). Bảng 3.3 trình bày kết quả trên tập kiểm tra.

**Bảng 3.3.** Hiệu năng mô hình cơ sở (baseline) trên tập kiểm tra


| Chỉ tiêu          | D1-không PCA | D1-có PCA | D2-không PCA | D2-có PCA |
|-------------------|--------------|-----------|--------------|-----------|
| Accuracy          | 0.9501       | 0.9491    | 0.9612       | 0.9638    |
| Precision (lớp 1) | 0.4286       | 0.3333    | 0.9152       | 0.9723    |
| Recall (lớp 1)    | 0.0600       | 0.0400    | 0.0986       | 0.1538    |
| F1 (lớp 1)        | 0.1053       | 0.0714    | 0.1780       | 0.2656    |
| ROC-AUC           | 0.8307       | 0.8011    | 0.9319       | 0.9641    |
| MCC               | 0.1462       | 0.1013    | 0.2934       | 0.3792    |

Kết quả mô hình baseline trên Dataset 1 và Dataset 2 cho thấy chỉ số độ chính xác (Accuracy) đạt mức cao (95–96%), nhưng Recall ở lớp dương lại rơi xuống mức rất thấp (4–15%). Đây là minh chứng điển hình cho hiện tượng ”cạm bẫy độ chính xác” (Accuracy Trap) thường gặp trên các tập dữ liệu mất cân bằng nghiêm trọng. Cụ thể, khi lớp dương chỉ chiếm khoảng 4.3–4.9% tổng số mẫu, một mô hình dự đoán baseline (luôn đưa ra kết luận ”không đột quỵ”) vẫn dễ dàng đạt được mức Accuracy tương đương nhưng hoàn toàn thất bại trong việc phát hiện ca bệnh.


- Accuracy không còn đại diện cho hiệu năng thực tế của mô hình trong bài toán chẩn đoán y khoa này, đòi hỏi phải bổ sung hoặc thay thế bằng các chỉ số phù hợp hơn như Precision, Recall, F1-score hay AUC-ROC.
- Kết quả baseline khẳng định tính cấp thiết của việc triển khai các giải pháp xử lý ở giai đoạn tiếp theo, bao gồm việc áp dụng các kỹ thuật cân bằng dữ liệu (Oversampling, Undersampling, SMOTE) kết hợp với tinh chỉnh siêu tham số nhằm nâng cao năng lực nhận diện lớp dương cho mô hình.




**Hình 3.9.** Ma trận nhầm lẫn của mô hình không có PCA - Dataset 1



**Hình 3.10.** Ma trận nhầm lẫn của mô hình có PCA - Dataset 1



**Hình 3.11.** Ma trận nhầm lẫn của mô hình không có PCA - Dataset 2



**Hình 3.12.** Ma trận nhầm lẫn của mô hình có PCA - Dataset 2

Nhìn vào ma trận nhầm lẫn của bước baseline, số ca dương tính được phát hiện đúng rất thấp: ở Dataset 1 trên 50 ca đột quỵ thật trong tập kiểm tra, mô hình chỉ phát hiện đúng 2 ca (có PCA) hoặc 3 ca (không PCA); ở Dataset 2 trên 47,192 ca dương tính,

mô hình phát hiện đúng 7,260 ca (có PCA, recall 15.4%) và 4,653 ca (không PCA, recall 9.9%). Đây là biểu hiện cụ thể của cạn kiệt accuracy đã nêu ở trên: mô hình gần như luôn dự đoán lớp đa số, khiến accuracy cao nhưng gần như vô dụng cho mục tiêu sàng lọc lâm sàng.

### 3.4 Tinh chỉnh siêu tham số (Grid Search)

Bảng 3.4 trình bày siêu tham số tốt nhất được tìm bằng Grid Search, sử dụng ROC-AUC làm tiêu chí lựa chọn, kết hợp Stratified K-Fold, với việc cân bằng lớp và PCA được đặt bên trong pipeline (chỉ fit trên phần train của mỗi fold) để tránh rò rỉ dữ liệu.

**Bảng 3.4.** Siêu tham số tốt nhất tìm được bằng Grid Search

| Siêu tham số                        | Dataset 1     | Dataset 2     |
|-------------------------------------|---------------|---------------|
| n_estimators                        | 200           | 400           |
| max_depth                           | 3             | 5             |
| learning_rate                       | 0.03          | 0.10          |
| min_child_weight                    | 5             | 1             |
| gamma                               | 0.2           | 0.0           |
| subsample                           | 0.8           | 0.8           |
| colsample_bytree                    | 0.8           | 0.8           |
| <b>ROC-AUC tốt nhất (CV tuning)</b> | <b>0.8028</b> | <b>0.9913</b> |

Không gian tìm kiếm của Grid Search thực chất chỉ biến thiên 5 trong 7 siêu tham số được liệt kê ở Chương 2 — độ sâu cây (max depth), learning rate, số lượng cây (n\_estimators), gamma và minimum child weight, mỗi tham số 2 mức giá trị ( $2^5 = 32$  tổ hợp); tỷ lệ mẫu huấn luyện (subsample) và tỷ lệ đặc trưng (colsample\_bytree) được giữ cố định ở 0.8. Grid Search tự đánh giá mỗi tổ hợp bằng kiểm định chéo nội bộ chỉ 3-fold (để tiết kiệm thời gian tìm kiếm). ROC-AUC tốt nhất tìm được trong quá trình tìm kiếm (3-fold) là 0.8028 ở Dataset 1 và 0.9913 ở Dataset 2. Với Dataset 2, do quy mô lớn, Grid Search được thực hiện trên một mẫu 150,000 dòng của tập huấn luyện để bảo đảm thời gian chạy hợp lý; mô hình cuối được huấn luyện lại trên toàn bộ tập

huấn luyện với siêu tham số đã chọn.

### 3.5 Kết quả kiểm định chéo (Cross-validation)

Với siêu tham số đã tinh chỉnh (ở bước Grid search), mô hình được đánh giá bằng kiểm định chéo 10-fold trên tập huấn luyện (cân bằng lớp và PCA chỉ fit trên phần train của mỗi fold, không rò rỉ sang fold kiểm định). Kết quả được trình bày ở bảng 3.5.

**Bảng 3.5.** Kết quả kiểm định chéo 10-fold (trung bình  $\pm$  độ lệch chuẩn)

| Chỉ số              | Dataset 1           | Dataset 2           |
|---------------------|---------------------|---------------------|
| Accuracy            | $0.7652 \pm 0.0308$ | $0.9654 \pm 0.0010$ |
| Precision           | $0.1420 \pm 0.0302$ | $0.5519 \pm 0.0073$ |
| Recall              | $0.7426 \pm 0.1065$ | $0.9937 \pm 0.0005$ |
| F1-score            | $0.2381 \pm 0.0472$ | $0.7097 \pm 0.0060$ |
| ROC-AUC             | $0.8238 \pm 0.0425$ | $0.9975 \pm 0.0002$ |
| Thời gian CV (giây) | 4.59                | 93.87               |

Ở Dataset 1, accuracy dao động khá mạnh giữa các fold, từ 0.731 đến 0.816, do mỗi fold kiểm định chỉ có khoảng 20 ca dương tính — cỡ mẫu nhỏ khiến kết quả nhạy với cách chia dữ liệu; ở Dataset 2, accuracy giữa các fold rất ổn định, chỉ dao động trong khoảng 0.964–0.967, nhờ mỗi fold có khoảng 18,877 ca dương tính, đủ lớn để làm mượt sự biến động.

### 3.6 Hiệu năng trên tập kiểm tra (hold-out)

Toàn bộ hành trình cải thiện mô hình qua từng bước xử lý, đo trên tập kiểm tra, cho thấy rõ sự đánh đổi giữa các chỉ số. Kết quả chi tiết các bước thực hiện được tổng hợp ở bảng 3.6. Ở Dataset 1, Accuracy giảm dần từ 95.0% (baseline không PCA) qua 82.5% (cân bằng lớp + PCA) xuống còn 78.2% (mô hình cuối đã tinh chỉnh), trong khi Recall tăng liên tục từ 6% lên 44% rồi 78% và MCC cải thiện từ 0.146 lên 0.282; ở Dataset 2, Accuracy giảm tạm thời từ 96.1% xuống 85.7% ở bước cân bằng lớp rồi phục hồi lên 96.6% sau khi tinh chỉnh, trong khi Recall tăng từ 9.9% lên trên 99% và

MCC tăng từ 0.293 lên 0.732.

**Bảng 3.6.** Kết quả thực nghiệm chi tiết trên hai tập dữ liệu


| Dataset   | Stage           | Variant           | N-feats | Accuracy     | Precision    | Recall       | F1           | AUC          | MCC          |
|-----------|-----------------|-------------------|---------|--------------|--------------|--------------|--------------|--------------|--------------|
| Dataset 1 | Baseline        | without_pca       | 21      | <b>0.950</b> | 0.429        | 0.060        | 0.105        | <b>0.831</b> | 0.146        |
|           |                 | with_pca          | 11      | 0.949        | 0.333        | 0.040        | 0.071        | 0.801        | 0.101        |
|           | Baseline Tuning | balance_only      | 21      | 0.912        | 0.130        | 0.140        | 0.135        | 0.788        | 0.088        |
|           |                 | balance_pca       | 11      | 0.825        | 0.127        | 0.440        | 0.197        | 0.772        | 0.164        |
|           |                 | balance_pca_tuned | 11      | 0.782        | <b>0.155</b> | <b>0.780</b> | <b>0.259</b> | 0.812        | <b>0.282</b> |
| Dataset 2 | Baseline        | without_pca       | 21      | 0.961        | 0.915        | 0.099        | 0.178        | 0.932        | 0.293        |
|           |                 | with_pca          | 11      | 0.964        | <b>0.972</b> | 0.154        | 0.266        | 0.964        | 0.379        |
|           | Baseline Tuning | balance_only      | 21      | 0.817        | 0.181        | 0.936        | 0.303        | 0.938        | 0.364        |
|           |                 | balance_pca       | 11      | 0.857        | 0.226        | 0.972        | 0.367        | 0.971        | 0.430        |
|           |                 | balance_pca_tuned | 11      | <b>0.966</b> | 0.559        | <b>0.994</b> | <b>0.716</b> | <b>0.998</b> | <b>0.732</b> |

Kết quả thực nghiệm chỉ ra rằng việc áp dụng đơn lẻ các thuật toán phân loại trên dữ liệu gốc (Baseline) không đem lại hiệu quả thực tế do ảnh hưởng của mất cân bằng nhãn. Ngược lại, chu trình kết hợp giữa giảm chiều dữ liệu (PCA), xử lý cân bằng mẫu, và tinh chỉnh siêu tham số (Tuning) là chiến lược tối ưu nhất. Phương pháp này không chỉ giúp giảm đáng kể chi phí tính toán (giảm từ 21 xuống 11 đặc trưng) mà còn tối ưu hóa đồng thời các chỉ số F1-score, AUC và MCC, đặc biệt phát huy hiệu quả vượt trội trên không gian mẫu lớn của Dataset 2.


Mô hình cuối cùng được huấn luyện lại trên toàn bộ tập huấn luyện và đánh giá một lần trên tập kiểm tra (hold-out), giữ nguyên tỷ lệ mất cân bằng gốc được trình bày kết quả ở bảng 3.7, và các hình vẽ ma trận nhầm lẫn (confusion matrix) và ROC curve.

**Bảng 3.7.** Hiệu năng trên tập kiểm tra (hold-out cuối cùng)


| Chỉ số            | Dataset 1<br>( $n = 1,022$ ) | Dataset 2<br>( $n = 1,108,453$ )  |
|-------------------|------------------------------|-----------------------------------|
| Accuracy          | 0.7818                       | 0.9664                            |
| Precision (lớp 1) | 0.1554                       | 0.5590                            |
| Recall (lớp 1)    | 0.7800                       | 0.9944                            |
| F1 (lớp 1)        | 0.2591                       | 0.7157                            |
| ROC-AUC           | 0.8118                       | 0.9976                            |
| MCC               | 0.2816                       | 0.7322                            |
| Cohen's Kappa     | 0.1933                       | 0.6993                            |
| TN / FP / FN / TP | 760 / 212 / 11 / 39          | 1,024,239 / 37,022 / 263 / 46,929 |




**Hình 3.13.** Ma trận nhầm lẫn của mô hình cuối cùng - Dataset 1



**Hình 3.14.** Đường cong ROC-AUC của mô hình cuối cùng - Dataset 1



**Hình 3.15.** Ma trận nhầm lẫn của mô hình cuối cùng - Dataset 2



**Hình 3.16.** Đường cong ROC-AUC của mô hình cuối cùng - Dataset 2

Ở Dataset 1, precision thấp (15.5%) đi cùng recall khá cao (78%) phản ánh đúng đặc trưng của một bài toán sàng lọc trên dữ liệu mất cân bằng mạnh: trong số 1,022 mẫu kiểm tra chỉ có 50 mẫu dương tính, mô hình ”bắt” được 39/50 ca thật (đánh đổi bằng 212 cảnh báo giả trên 972 mẫu âm tính). Ở Dataset 2, quy mô tập kiểm tra rất lớn (hơn 1.1 triệu mẫu) giúp mô hình đạt cả recall (99.4%) và precision (55.9%) tốt hơn nhiều, MCC 0.732 cho thấy mô hình phân biệt hai lớp khá tốt dù dữ liệu mất cân bằng.

### 3.7 Kiểm định ý nghĩa thống kê

Các kiểm định ý nghĩa thống kê được thực hiện để xác nhận khác biệt hiệu năng giữa phương pháp có PCA và không có PCA. Hai kiểm định được sử dụng: paired t-test (phù hợp vì hai phương pháp dùng cùng bộ fold kiểm định chéo) và Mann-Whitney U (giả định mẫu độc lập, được thêm vào để đối chiếu). Bảng 3.7 trình bày kết quả, so sánh accuracy trung bình của 10 fold giữa pipeline ”Cân bằng lớp → XGBoost” (không PCA) và ”Cân bằng lớp → PCA → XGBoost” (có PCA), dùng cùng siêu tham số đã tinh chỉnh.



**Bảng 3.8.** So sánh hiệu năng và kiểm định thống kê tác động của PCA

| Chỉ tiêu                        | Dataset 1             | Dataset 2              |
|---------------------------------|-----------------------|------------------------|
| Accuracy TB - không PCA         | 0.8146                | 0.9214                 |
| Accuracy TB - có PCA            | 0.7652                | 0.9654                 |
| Chênh lệch (có PCA - không PCA) | -0.0494               | +0.0440                |
| p-value (paired t-test)         | $8.43 \times 10^{-5}$ | $6.44 \times 10^{-15}$ |
| p-value (Mann-Whitney U)        | 0.00282               | 0.000183               |

Cả hai kiểm định đều dựa trên 10 cặp giá trị accuracy tương ứng với 10 fold kiểm định chéo đủ số quan sát để áp dụng paired t-test một cách hợp lý. Kết quả kiểm định thống kê cho một phát hiện quan trọng: PCA không phải lúc nào cũng có lợi. Trên Dataset 2 (rất lớn, hơn 4.4 triệu dòng huấn luyện), PCA cải thiện có ý nghĩa thống kê Accuracy trung bình (tăng 0.0440 từ 0.9214 lên 0.9654,  $p < 0.001$ ), phù hợp với kỳ vọng rằng giảm chiều giúp loại bỏ nhiễu trên tập dữ liệu lớn. Ngược lại, trên Dataset 1 (chỉ 4,088 dòng huấn luyện), PCA làm giảm có ý nghĩa thống kê Accuracy trung bình (giảm 0.0494 từ 0.8146 xuống 0.7652,  $p < 0.001$ ) — có thể do việc nén còn 11 thành phần chính đã loại bỏ một phần thông tin hữu ích cho việc phân biệt lớp thiếu số vốn đã rất ít mẫu.


Cả hai kiểm định đều dựa trên 10 cặp giá trị accuracy tương ứng với 10 fold kiểm định chéo đủ số quan sát để áp dụng paired t-test một cách hợp lý. Chênh lệch trung bình Accuracy (có PCA trừ không PCA) là -0,0494 ở Dataset 1 và +0,0440 ở Dataset 2 — hai dấu trái ngược nhau minh họa rõ việc lợi ích của PCA phụ thuộc mạnh vào quy mô và đặc điểm của từng tập dữ liệu, không phải một quy luật cố định.

### 3.8 Phân tích trọng số PCA và kết quả SHAP


Sau khi áp dụng PCA, các thành phần chính được thu được cùng với trọng số (loadings) của đặc trưng gốc trong các thành phần mới.

Để diễn giải dự báo, phương pháp SHAP được áp dụng. Các hình SHAP Waterfall,


Bar và Beeswarm cho thấy mức glucose máu trung bình, tuổi, loại công việc và giới tính nằm trong nhóm đặc trưng có ảnh hưởng lớn nhất đến dự báo ở cả hai tập dữ liệu (Dataset 1: 1.090/0.495/0.488; Dataset 2: 1.800/0.952/0.842), phù hợp với hiểu biết lâm sàng về các yếu tố nguy cơ đột quỵ.




**Hình 3.17.** SHAP Waterfall (Dataset 1).




**Hình 3.18.** SHAP Bar (Dataset 1).




**Hình 3.19.** SHAP Beewarm (Dataset 1).



**Hình 3.20.** SHAP Waterfall (Dataset 2).



**Hình 3.21.** SHAP Bar (Dataset 2).



**Hình 3.22.** SHAP Beewarm (Dataset 2).

Kết quả nghiên cứu chứng minh hiệu quả của việc tích hợp PCA với XGBoost trong dự đoán nguy cơ đột quỵ. Triển khai PCA được tối ưu làm giảm đáng kể số chiều


dữ liệu, từ đó tăng cả tốc độ xử lý và độ chính xác của XGBoost. Việc sử dụng thêm SHAP cho phép xác định các biến gốc quan trọng nhất ảnh hưởng đến kết quả dự báo. Sự tích hợp này đặc biệt có giá trị trong chẩn đoán y khoa, nơi cả tốc độ lẫn độ chính xác của phân tích đều quan trọng vì liên quan đến tính mạng con người.

### 3.9 Đánh giá hiệu năng song song hóa OpenMP


Việc song song hóa thuật toán Jacobi bằng OpenMP được đánh giá bằng thí nghiệm trên các ma trận ngẫu nhiên kích thước  $N = 100, 200, 300, 400, 500$  (giá trị được điền từ 0 đến 1, mô phỏng chuẩn hóa MinMax), so sánh thời gian tính toán tuần tự và song song. Kết quả được lưu dưới dạng biểu đồ thời gian thực thi và biểu đồ speedup, cho thấy xu hướng chung là OpenMP giúp giảm thời gian tính toán, và mức giảm càng rõ rệt khi kích thước ma trận càng lớn.

**Bảng 3.9.** Thời gian thực thi Jacobi tuần tự và OpenMP

| N   | Tuần tự (s) | OpenMP (s) | Speedup | Sai số trị riêng tương đối |
|-----|-------------|------------|---------|----------------------------|
| 100 | 0.0441      | 0.0731     | 0.604   | 0                          |
| 200 | 0.2521      | 0.2733     | 0.923   | 0                          |
| 300 | 0.9019      | 0.8323     | 1.084   | 0                          |
| 400 | 2.0456      | 1.6355     | 1.251   | 0                          |
| 500 | 4.0797      | 2.6504     | 1.539   | 0                          |



**Hình 3.23.** Thời gian thực thi Jacobi theo kích thước ma trận



**Hình 3.24.** Speedup của OpenMP so với phiên bản tuần tự

Kết quả cho thấy OpenMP chưa có lợi thế ở  $N = 100$  và  $N = 200$  (speedup  $< 1$ , OpenMP chậm hơn do overhead khởi tạo luồng khi ma trận còn nhỏ), nhưng bắt đầu nhanh hơn ở  $N = 300$ . Speedup lần lượt là 0.604; 0.923; 1.084; 1.251 và 1.539 lần. Vì vậy, nhận định phù hợp với kết quả code là song song hóa có lợi khi kích thước bài toán đủ lớn, thay vì khẳng định OpenMP luôn nhanh hơn trên dữ liệu nhỏ.

Về độ chính xác số học, cả phiên bản tuần tự và song song đều hội tụ sau đúng 20 vòng lặp (sweep) ở mọi kích thước ma trận, với sai số trực giao (orthogonality error)

cực nhỏ (dưới  $2 \times 10^{-14}$ ) và sai số trị riêng tương đối giữa hai phiên bản bằng 0 — nghĩa là song song hóa bằng OpenMP không đánh đổi độ chính xác để lấy tốc độ.

## Chương 4

# THẢO LUẬN

Trong bài báo này, phương pháp đề xuất được kiểm thử trên hai tập dữ liệu. Các kết quả chính đã được mô tả trong phần Kết quả. Để so sánh chi tiết hơn với các công trình hiện có và xác định vị trí của phương pháp đề xuất, chúng tôi bổ sung so sánh với các nghiên cứu liên quan. Cụ thể, Bảng 4.1 so sánh phương pháp của nhóm tác giả với ba công trình trên Dataset 1.

**Bảng 4.1.** So sánh hiệu năng với các nghiên cứu liên quan

| Thuộc tính         | [18]                                                                      | [33]                                             | [34]                                            | Kết quả báo cáo gốc                            | Kết quả nhóm thực hiện                          |
|--------------------|---------------------------------------------------------------------------|--------------------------------------------------|-------------------------------------------------|------------------------------------------------|-------------------------------------------------|
| <b>Phương pháp</b> | Logistic Regression, Decision Tree, Random Forest, k-NN, SVM, Naive Bayes | Random Forest, XGBoost, Logistic Regression, ANN | Random Forest, Naive Bayes, Logistic Regression | XGBoost + PCA (số liệu công bố của nghiên cứu) | XGBoost + PCA (11 TP) + SMOTE (tập holdout DS1) |
| <b>Accuracy</b>    | 82%                                                                       | 92.55%                                           | –                                               | 95.32% (CV)                                    | 78.18%                                          |
| <b>F1-score</b>    | 82.3%                                                                     | 92.40%                                           | 80%                                             | –                                              | 25.91%                                          |

Đối với Dataset 2, không xác định được nghiên cứu liên quan, có thể vì tập dữ liệu này mới được công bố gần đây. Vì vậy, hiệu năng mô hình trên Dataset 2 được đánh giá thêm bằng hệ số tương quan Matthews (MCC) và hệ số Cohen's Kappa (CK). MCC là một chỉ số cân bằng để đánh giá chất lượng mô hình phân loại, đặc biệt trên dữ liệu mất cân bằng, bởi nó xét cả bốn phần tử của ma trận lỗi (TP, TN, FP, FN), với giá trị từ -1 (hoàn toàn không phù hợp) đến 1 (phân loại hoàn hảo), trong đó 0 biểu thị dự báo ngẫu nhiên. CK đo mức độ nhất quán giữa dự báo của mô hình và kết quả thực tế, cũng có khoảng giá trị từ -1 đến 1, trong đó giá trị dương biểu thị mức nhất quán vượt quá ngẫu nhiên. Ngoài ra, kiểm định chéo được thực hiện. Tóm tắt kết quả



cross-validation và các chỉ số hiệu năng bổ sung cho Dataset 2 được trình bày trong Bảng 4.2.

**Bảng 4.2.** Kết quả các chỉ số đánh giá mô hình

| Chỉ số đánh giá                             | Giá trị |
|---------------------------------------------|---------|
| Điểm cross-validation (accuracy) trung bình | 0.9654  |
| Độ lệch chuẩn giữa các fold                 | 0.0010  |
| ROC-AUC trung bình (CV)                     | 0.9975  |
| MCC (trên tập kiểm tra)                     | 0.7322  |
| Cohen's Kappa (trên tập kiểm tra)           | 0.6993  |

Kết quả trong Bảng 4.2 cho thấy chất lượng khá cao và ổn định của mô hình trên Dataset 2. Điểm cross-validation (accuracy) trung bình 0.9654 với độ lệch chuẩn rất nhỏ (0.0010) giữa các fold xác nhận độ ổn định của mô hình trên các phần dữ liệu khác nhau. ROC-AUC trung bình 0.9975 cho thấy khả năng phân biệt hai lớp rất tốt. Giá trị MCC (0.7322) và Cohen's Kappa (0.6993) trên tập kiểm tra, tuy thấp hơn mức 0.96 từng được kỳ vọng ban đầu, vẫn ở mức khá cao và chỉ ra mô hình tạo ra dự báo tốt hơn đáng kể so với dự báo ngẫu nhiên, ngay cả trên dữ liệu mất cân bằng.

Mô hình đề xuất có hiệu quả cao trong dự đoán nguy cơ đột quỵ, tuy nhiên, việc triển khai trong môi trường lâm sàng cũng gặp một số thách thức. Những thách thức này gồm tích hợp vào các hệ thống thông tin y tế hiện có với định dạng dữ liệu không đồng nhất, nhu cầu kiểm thử trên các mẫu lâm sàng thực và bảo đảm đáp ứng yêu cầu tốc độ tính toán cho các quyết định tác nghiệp. Những thách thức tương tự được xử lý trong các công trình về phương pháp lai, cụ thể là nghiên cứu sử dụng Harris Hawks Optimization và Cuckoo Search Algorithm để lựa chọn các đặc trưng quan trọng trong dữ liệu sinh học nhiều chiều [35]. Điều này cải thiện độ chính xác và ổn định của mô hình và hỗ trợ ra quyết định trong thực hành y khoa.

Phương pháp đề xuất cũng có một số ưu điểm và hạn chế nhận định. Kết hợp XGBoost với PCA để giảm chiều giúp tăng độ chính xác mô hình, nhưng cách tiếp cận này có thể khó cấu hình, gây khó khăn khi áp dụng cho các tập dữ liệu khác, đặc biệt nếu dữ

liệu không có vấn đề nhiều chiều rõ rệt. Bên cạnh đó, tính toán song song qua OpenMP để tăng tốc PCA chỉ mang lại lợi ích đáng kể với các tập dữ liệu lớn, trong khi với tập dữ liệu nhỏ, mức tăng hiệu năng không tỷ lệ thuận với chi phí triển khai công nghệ. Các thuật toán metaheuristic như Genetic Algorithm, Particle Swarm Optimization và nhiều phương pháp khác đang được sử dụng tích cực để cải thiện phân tích dữ liệu y tế nhiều chiều. Nghiên cứu [36] cho thấy việc tích hợp Random Drift Optimization với XGBoost nâng độ chính xác phân loại dữ liệu ung thư lên 99.14%, vượt các phương pháp truyền thống như SVM và Naive Bayes. Cụ thể, đối với phát hiện sớm ung thư vú, một phương pháp lai kết hợp Harris Hawk Optimization và Whale Optimization với học sâu được trình bày trong [37], đạt độ chính xác phân loại 99.0%, cũng vượt các thuật toán tối ưu truyền thống. Các cách tiếp cận này thể hiện tiềm năng lớn trong cải thiện mô hình y tế bằng cách tăng độ chính xác, khả năng thích nghi và năng lực cung cấp điều trị cá nhân hóa. Ngoài ra, việc áp dụng các phương pháp metaheuristic để lựa chọn gene và cải thiện độ chính xác chẩn đoán trong thực hành y khoa cũng rất quan trọng, như trình bày trong [38], nơi các cách tiếp cận metaheuristic giúp cải thiện lựa chọn đặc trưng và bảo đảm độ chính xác phân loại cao, có thể đóng góp vào phát triển điều trị cá nhân hóa trong ung thư học.

## Chương 5

# ĐỀ XUẤT HƯỚNG NGHIÊN CỨU TIẾP THEO

Dựa trên các phát hiện ở Chương 3 và Chương 4, nhóm đề xuất một số hướng mở rộng cụ thể cho các giai đoạn tiếp theo của nghiên cứu: dữ liệu và đánh giá, mô hình hóa

### Về dữ liệu và phương pháp đánh giá

- Bổ sung các chỉ số phù hợp hơn với dữ liệu mất cân bằng mạnh bên cạnh Accuracy, đặc biệt là PR-AUC (Precision–Recall AUC) và average precision, vốn nhạy với hiệu năng trên lớp thiểu số hơn ROC-AUC khi tỷ lệ dương tính rất thấp như ở Dataset 1 ( $\approx 4.9\%$ ).
- Khảo sát việc điều chỉnh ngưỡng phân loại (threshold tuning) thay vì dùng mặc định 0.5 – ví dụ chọn ngưỡng theo điểm cân bằng Precision–Recall mong muốn, hoặc theo chi phí lâm sàng tương đối giữa bỏ sót ca bệnh (False Negative) và cảnh báo giả (False Positive).

### Về mô hình hóa

- Với Dataset 1, do PCA hiện làm giảm Accuracy trung bình một cách có ý nghĩa thống kê, nên thử nghiệm thêm các phương án: không dùng PCA, dùng PCA với số thành phần lớn hơn (ví dụ giữ 99% phương sai thay vì 95%), hoặc dùng các phương pháp giảm chiều khác (ví dụ lựa chọn đặc trưng dựa trên độ quan trọng của XGBoost) để so sánh.
- Thử nghiệm scale\_pos\_weight của XGBoost hoặc các kỹ thuật cost-sensitive learning khác như một phương án thay thế/bổ sung cho SMOTE và undersampling, vì các phương pháp resampling có thể làm thay đổi phân phối dữ liệu theo cách không phản ánh đúng tổng thể, trong khi cost-sensitive learning giữ nguyên dữ liệu gốc.
- Thử nghiệm SMOTE-Tomek hoặc ADASYN cho Dataset 1 để so sánh với SMOTE

thuần, và thử stratified undersampling kết hợp bagging nhiều mô hình con cho Dataset 2 thay vì một lần undersampling duy nhất, nhằm tận dụng tốt hơn lượng lớn mẫu lớp đa số bị loại bỏ.

## KẾT LUẬN

Kết quả nghiên cứu xác nhận hiệu quả của việc tích hợp PCA và XGBoost trong dự đoán nguy cơ đột quỵ: giảm chiều bằng PCA giúp sử dụng tài nguyên hiệu quả hơn và giảm thời gian tính toán (đặc biệt với tập dữ liệu lớn như Dataset 2), trong khi SHAP mang lại tính minh bạch cần thiết để bác sĩ hiểu và tin tưởng vào quyết định của mô hình. Độ chính xác trên tập kiểm tra đạt 78.2% với Dataset 1 và 96.6% với Dataset 2, đi kèm khuyến cáo quan trọng: cần diễn giải các chỉ số này cùng với Precision, Recall, ROC-AUC và MCC, vì Accuracy một mình có thể gây hiểu lầm trên dữ liệu mất cân bằng mạnh.

Phương pháp có khả năng mở rộng tốt nhờ PCA giảm chiều và tính toán song song OpenMP, phù hợp để thích nghi với các bài toán y khoa khác (ví dụ dự báo bệnh tim mạch hoặc ung thư) cũng như phục vụ mục đích giáo dục và nghiên cứu trong y sinh. Hướng nghiên cứu tiếp theo bao gồm: mở rộng kiểm thử trên các tập dữ liệu lâm sàng thực lớn hơn, so sánh phương pháp Jacobi với các kỹ thuật phân rã trị riêng khác (QR, power iteration), tối ưu ngưỡng phân loại và chiến lược cân bằng lớp theo các hướng đã nêu ở phần Đề xuất, đồng thời mở rộng ứng dụng XAI để cải thiện hơn nữa khả năng diễn giải kết quả cho người dùng lâm sàng.

## TÀI LIỆU THAM KHẢO

- [1] Dev S, Wang H, Nwosu CS, Jain N, Veeravalli B, John D. A predictive analytics approach for stroke prediction using machine learning and neural networks. *Healthc Anal.* 2022;2:100032. <https://doi.org/10.1016/j.health.2022.100032>.
- [2] Bikku T, Fritz RA, Colón YJ, Herrera F. Machine learning identification of organic compounds using visible light. 2022. <https://doi.org/10.48550/ARXIV.2204.11832>.
- [3] Kovtun O, Kovtun V. Machine Learning-Based Approach to Transcribing Language Units. In: 2024 14th International Conference on Advanced Computer Information Technologies (ACIT), Ceske Budejovice. Czech Republic: IEEE; 2024. pp. 636–639. <https://doi.org/10.1109/ACIT62333.2024.10712598>.
- [4] Gupta A et al. Predicting stroke risk: an effective stroke prediction model based on neural networks. *J Neurorestoratol.* 2024:100156. <https://doi.org/10.1016/j.jnrt.2024.100156>.
- [5] JalajaJayalakshmi V, Geetha V, Ijaz MM. Analysis and Prediction of Stroke using Machine Learning Algorithms. In: 2021 International Conference on Advancements in Electrical, Electronics, Communication, Computing and Automation (ICAECA), Coimbatore. India: IEEE; 2021. pp. 1–5. <https://doi.org/10.1109/ICAECA52838.2021.9675545>.
- [6] Bikku T. Multi-layered deep learning perceptron approach for health risk prediction. *J Big Data.* 2020;7(1):50. <https://doi.org/10.1186/s40537-020-00316-7>.
- [7] Upadhyay R, Panse P, Soni A, Rathore Bhatt U. Principal component analysis as a dimensionality reduction and data preprocessing technique. *SSRN Electron*

- J. 2019. <https://doi.org/10.2139/ssrn.3364221>.
- [8] Izonin I, Gamra A, Boychuk O, et al. PCA-NuSVR Framework for Predicting Local and Global Indicators of Tunneling-induced Building Damage. Proceedings of the 1st International Conference on Smart Automation & Robotics for Future Industry (SMARTINDUSTRY 2024). 2024;3699:32–46.
- [9] Booker NK, Knights P, Gates JD, Clegg RE. Applying principal component analysis (PCA) to the selection of forensic analysis methodologies. *Eng Fail Anal.* 2022;132:105937. <https://doi.org/10.1016/j.engfailanal.2021.105937>.
- [10] Mochurad L, Panto R. A Parallel Algorithm for the Detection of Eye Disease. In: Advances in Intelligent Systems, Computer Science and Digital Economics IV, vol. 158. Hu Z, Wang Y, He M, eds. Lecture Notes on Data Engineering and Communications Technologies. Cham: Springer Nature Switzerland; 2023. pp. 111–125. [https://doi.org/10.1007/978-3-031-24475-9\\_10](https://doi.org/10.1007/978-3-031-24475-9_10).
- [11] Althiban AS, Alharbi HM, Al Khuzayem LA, Eassa FE. Predicting software defects in hybrid MPI and OpenMP parallel programs using machine learning. *Electronics.* 2023;13(1):182. <https://doi.org/10.3390/electronics13010182>.
- [12] Mochurad L, Kotsiumbas O, Protsyk I. A model for weather forecasting based on parallel calculations. In: Advances in Artificial Systems for Medicine and Education VI, vol. 159. Hu Z, Ye Z, He M, eds. Lecture Notes on Data Engineering and Communications Technologies. Cham: Springer Nature Switzerland; 2023. pp. 35–46. [https://doi.org/10.1007/978-3-031-24468-1\\_4](https://doi.org/10.1007/978-3-031-24468-1_4).
- [13] Ali S, et al. Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. *Inf Fusion.* 2023;99:101805. <https://doi.org/10.1016/j.inffus.2023.101805>.
- [14] Bikku T. Fuzzy associated trust-based data security in cloud computing by

- mining user behaviour. *Int J Adv Intell Paradig*. 2023;25(3/4):382–97. <https://doi.org/10.1504/IJAIP.2023.132377>.
- [15] Tazin T, Alam MN, Dola NN, Bari MS, Bourouis S, Monirujjaman Khan M. Stroke disease detection and prediction using robust learning approaches. *J Healthc Eng*. 2021:1–12. <https://doi.org/10.1155/2021/7633381>.
- [16] Patereha Y, Melnyk M. Prediction of the occurrence of stroke based on machine learning models. *Comput Des Syst Theory Pract*. 2024;6(1):17–27. <https://doi.org/10.23939/cds2024.01.017>.
- [17] Dritsas E, Trigka M. Stroke risk prediction with machine learning techniques. *Sensors*. 2022;22(13):4670. <https://doi.org/10.3390/s22134670>.
- [18] Sailasya G, Kumari GL. Analyzing the performance of stroke prediction using ML classification algorithms. *Int J Adv Comput Sci Appl*. 2021;12(6). <https://doi.org/10.14569/IJACSA.2021.0120662>.
- [19] Dhillon S, Bansal C, Sidhu B. Machine learning based approach using xgboost for heart stroke prediction. International Conference on Emerging Technologies: AI, IoT, and CPS for Science & Technology Applications. 2021. p. 1–6.
- [20] Chung C-C, Su EC-Y, Chen J-H, Chen Y-T, Kuo C-Y. XGBoost-based simple three-item model accurately predicts outcomes of acute ischemic stroke. *Diagnostics*. 2023;13(5):842. <https://doi.org/10.3390/diagnostics13050842>.
- [21] Tumpanjawat. Stroke Prediction: EDA | Resampling | XGBoost. Kaggle. 2024. Available: <https://www.kaggle.com/code/tumpanjawat/stroke-prediction-eda-resampling-xgboost>.
- [22] Mainali S, Darsie ME, Smetana KS. Machine learning in action: stroke diagnosis and outcome prediction. *Front Neurol*. 2021;12:734345. <https://doi.org/10.3389/fneur.2021.734345>.
- [23] Fang G, Huang Z, Wang Z. Predicting ischemic stroke outcome using deep



- learning approaches. *Front Genet.* 2022;12:827522. <https://doi.org/10.3389/fgene.2021.827522>.
- [24] Srinivasu PN, Sirisha U, Sandeep K, Praveen SP, Maguluri LP, Bikku T. An interpretable approach with explainable ai for heart stroke prediction. *Diagnostics.* 2024;14(2):128. <https://doi.org/10.3390/diagnostics14020128>.
- [25] Mienye ID, Jere N. Optimized ensemble learning approach with explainable ai for improved heart disease prediction. *Information.* 2024;15(7):394. <https://doi.org/10.3390/info15070394>.
- [26] Singamaneni KK, Budati AK, Bikku T. An Efficient Q-KPABE framework to enhance cloud-based iot security and privacy. *Wirel Pers Commun.* 2024. <https://doi.org/10.1007/s11277-024-10908-8>.
- [27] Bikku T, Malligunta KK, Thota S, Surapaneni PP. Improved quantum algorithm: a crucial stepping stone in quantum-powered drug discovery. *J Electron Mater.* 2024. <https://doi.org/10.1007/s11664-024-11275-7>.
- [28] Da Poian V, et al. Exploratory data analysis (EDA) machine learning approaches for ocean world analog mass spectrometry. *Front Astron Space Sci.* 2023;10:1134141. <https://doi.org/10.3389/fspas.2023.1134141>.
- [29] Elreedy D, Atiya AF. A Comprehensive Analysis of Synthetic Minority Oversampling Technique (SMOTE) for handling class imbalance. *Inf Sci.* 2019;505:32–64. <https://doi.org/10.1016/j.ins.2019.07.070>.
- [30] Nohara Y, Matsumoto K, Soejima H, Nakashima N. Explanation of machine learning models using shapley additive explanation and application for real data in hospital. *Comput Methods Programs Biomed.* 2022;214:106584. <https://doi.org/10.1016/j.cmpb.2021.106584>.
- [31] Soriano F. Stroke Prediction Dataset. 2024. Available: <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>.

- [32] Pranav Prakash. Stroke Prediction – Health Care Synthetic Dataset. 2024. Available: <https://www.kaggle.com/datasets/pranavp1999/stroke-prediction-health-care-synthetic-dataset>.
- [33] Sahriar S, et al. Unlocking stroke prediction: harnessing projection-based statistical feature extraction with ML algorithms. *Heliyon*. 2024;10(5):e27411. <https://doi.org/10.1016/j.heliyon.2024.e27411>.
- [34] Wisesty UN, Wirayuda TAB, Sthevanie F, Rismala R. Analysis of data and feature processing on stroke prediction using wide range machine learning model. *J Online Inform*. 2024;9(1):29–40. <https://doi.org/10.15575/join.v9i1.1249>.
- [35] Yaqoob A, Verma NK, Aziz RM, Saxena A. Enhancing Feature Selection Through Metaheuristic Hybrid Cuckoo Search and Harris Hawks Optimization for Cancer Classification. In: *Metaheuristics for Machine Learning*, 1st ed. Kalita K, Ganesh N, Balamurugan S, eds. Wiley; 2024. pp. 95–134. <https://doi.org/10.1002/9781394233953.ch4>.
- [36] Abdel-Basset M, Abdel-Fatah L, Sangaiah AK. Metaheuristic algorithms: a comprehensive review. In: *Computational Intelligence for Multimedia Big Data on the Cloud with Engineering Applications*. Elsevier; 2018. pp. 185–231. <https://doi.org/10.1016/B978-0-12-813314-9.00010-4>.
- [37] Yaqoob A, Verma NK, Aziz RM, Shah MA. Optimizing cancer classification: a hybrid RDO-XGBoost approach for feature selection and predictive insights. *Cancer Immunol Immunother*. 2024;73(12):261. <https://doi.org/10.1007/s00262-024-03843-x>.
- [38] Yaqoob A, Verma NK, Aziz RM, Shah MA. RNA-Seq analysis for breast cancer detection: a study on paired tissue samples using hybrid optimization and deep learning techniques. *J Cancer Res Clin Oncol*. 2024;150(10):455. <https://doi.org/10.1007/s00432-024-05968-z>.