

Dự đoán nguy cơ đột quỵ bằng XGBoost, PCA và XAI

Tái hiện nghiên cứu Mochurad et al. (2025)

Nhóm thực hiện

Ngày 15 tháng 8 năm 2026

1. Bài toán và động cơ

- Mục tiêu: dự đoán sớm nguy cơ đột quy từ đặc trưng bệnh nhân.
- Khó khăn: **mất cân bằng lớp**, missing/outlier, quan hệ phi tuyến, yêu cầu giải thích.
- Hướng của bài báo: **XGBoost + PCA + SHAP**; PCA được tối ưu bằng OpenMP.

Ba tiêu chí chính

Độ chính xác + tốc độ xử lý + khả năng giải thích.

2. Hai bộ dữ liệu

Bộ dữ liệu	Quy mô	Đặc trưng chính
Dataset 1	5.110 bản ghi; 249 stroke	age, hypertension, heart disease, glucose, BMI, smoking, work type, gender, residence
Dataset 2	5.769.190 bản ghi	Cấu trúc tương tự, dữ liệu tổng hợp quy mô lớn

- Dataset 1: cân bằng bằng **SMOTE**.
- Dataset 2: cân bằng bằng **undersampling**.

3. Pipeline của nghiên cứu

- 1 Làm sạch, missing, outlier, one-hot encoding.
- 2 Chuẩn hóa dữ liệu.
- 3 Cân bằng lớp trên tập train.
- 4 PCA giữ $\geq 95\%$ phương sai.
- 5 XGBoost + tuning hyperparameter.
- 6 Đánh giá: Accuracy, Precision, Recall, F1, ROC-AUC, MCC, Kappa.
- 7 XAI bằng SHAP.

4. PCA: giảm chiều

$$X_c = X - \bar{x}, \quad S = \frac{1}{N-1} X_c^T X_c,$$
$$S v_j = \lambda_j v_j, \quad X_{\text{reduced}} = X_c V_k.$$

- Chọn k sao cho cumulative explained variance đạt 95%.
- Theo bài báo Dataset 1: từ **19** đặc trưng sau xử lý xuống **13** thành phần.
- Jacobi rotation được song song hóa bằng OpenMP.

5. XGBoost và hàm mục tiêu

$$L(\theta) = \sum_{i=1}^N \ell(y_i, \hat{y}_i(\theta)) + \Omega(\theta)$$

$$\ell(y_i, \hat{y}_i) = -[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)].$$

- Tuning: depth, learning rate, số cây, gamma, min child weight, subsample, colsample.
- Regularization giúp kiểm soát overfitting.
- ROC-AUC là tiêu chí quan trọng khi lựa chọn mô hình.

6. Kết quả PCA cần tái hiện

Chạy code để sinh hình

```
../results/dataset1/balanced_pca95_cumulative_results.png
```

Chạy code để sinh hình

```
../results/dataset1/balanced_pca95_score.png
```

7. Kết quả Dataset 1 trong bài báo

- Accuracy: **95%**.
- ROC-AUC trên hình: khoảng **0.99**.
- 10-fold average accuracy: **0.9532**.
- Confusion matrix: $TN = 908$,
 $FP = 68$, $FN = 33$, $TP = 935$.

Chạy code để sinh hình
`../results/dataset1/balanced_pca95_confu`

8. Kết quả Dataset 2 trong bài báo

Chỉ số	Không PCA	Có PCA
Accuracy	0.95	0.98
F1 class 0	0.95	0.98
F1 class 1	0.96	0.98

- 10-fold CV mean: **0.99028**.
- MCC: **0.9634**; Cohen's Kappa: **0.9632**.
- Confusion matrix có PCA: $TN = 6901$, $FP = 160$, $FN = 71$, $TP = 7013$.

9. SHAP: mô hình dự đoán dựa vào đâu?

- Dataset 1: glucose, work type, BMI, age nổi bật.
- Dataset 2: age và glucose nổi bật nhất.
- Waterfall: giải thích từng quan sát.
- Bar/Beeswarm: giải thích toàn cục.

Chạy code để sinh hình
`../results/dataset1/balanced_no_pca_shap_`

10. OpenMP và tốc độ

Ma trận	100	200	300	400	500
OpenMP	0.503	5.838	40.043	128.957	363.385
Sequential	0.530	7.747	62.958	218.853	549.275

- Dataset nhỏ: overhead song song hóa làm lợi ích hạn chế.
- Ma trận lớn: khoảng cách thời gian tăng rõ rệt.
- Bài báo báo tổng thời gian 1.50010 s so với 4.52611 s ở công trình tham chiếu.

11. Thiết kế code tái hiện

- Train/test = 80/20, stratified.
- IQR bounds học từ train rồi áp cho test.
- Sampler nằm trong `imblearn.Pipeline` → tránh leakage.
- So sánh: unbalanced/no-PCA, balanced/no-PCA, balanced/PCA95.
- Xuất tự động: metrics, classification report, confusion matrix, ROC, PCA, loadings, SHAP.

12. Kết luận

- XGBoost + PCA + XAI là pipeline hợp lý cho bài toán dự đoán đột quy.
- PCA có thể giảm chiều và tăng tốc, nhưng lợi ích phụ thuộc quy mô dữ liệu.
- SHAP giúp diễn giải nhưng không thay thế kiểm định lâm sàng.
- Mục tiêu thực nghiệm: **tái hiện và đối chiếu**, không giả định sẽ khớp tuyệt đối số liệu bài báo.