

THẠC SĨ KHOA HỌC DỮ LIỆU - QH2025
KHAI PHÁ DỮ LIỆU VÀ HỌC MÁY

Dự đoán nguy cơ đột quỵ bằng XGBoost, PCA, XAI

Tái hiện nghiên cứu Mochurad et al. (2025)

Giảng viên hướng dẫn: PGS.TS.TRẦN TRỌNG HIẾU

Sinh viên thực hiện: TỐNG VIỆT TÚ - 25007845

NGUYỄN THỊ NHẬT LINH - 25007871

09/2026

1. Mục tiêu và cách tiếp cận của báo cáo

Đây không phải bản tóm tắt bài báo gốc

Báo cáo thực hiện trong khuôn khổ học phần Khai phá dữ liệu: **tìm hiểu, trình bày lại, tái hiện thực nghiệm và đề xuất cải tiến** cho một công trình đã công bố — không dừng ở việc tóm tắt.

Mục tiêu cụ thể:

- 1 Trình bày lại có hệ thống nội dung bài báo gốc bằng tiếng Việt (Chương 1–4).
- 2 Tự xây dựng và chạy lại pipeline thực nghiệm để tái lập kết quả tác giả công bố trên hai bộ dữ liệu.
- 3 Đối chiếu có kiểm soát giữa kết quả tác giả và kết quả tái hiện, xác định thành phần cần hiệu chỉnh.
- 4 Sau khi có baseline tái hiện phù hợp, khảo sát hướng cải tiến và đánh giá lợi ích thực nghiệm so với tác giả (Chương 5).

2. Bài toán và động cơ

- Mục tiêu: dự đoán sớm nguy cơ đột quỵ từ đặc trưng bệnh nhân.
- Khó khăn: **mất cân bằng lớp**, missing/outlier, quan hệ phi tuyến, yêu cầu giải thích.
- Hướng của bài báo: **XGBoost + PCA + SHAP**; PCA được tối ưu bằng OpenMP.

Ba tiêu chí chính

Độ chính xác + tốc độ xử lý + khả năng giải thích.

3. So sánh các phương pháp học máy hiện có (Bảng 1.1)

Phương pháp	Ưu điểm	Nhược điểm
Hồi quy Logistic	Độ chính xác cao ($>95\%$), dễ triển khai	Hạn chế với quan hệ phi tuyến
Cây quyết định	Trực quan, dễ diễn giải	Dễ overfitting
Random Forest	Độ chính xác cao (96%), tin cậy	Chậm với dữ liệu lớn
Naive Bayes	Đơn giản, hiệu quả	Chính xác 82%, hạn chế khi biến phụ thuộc
k-NN	Đơn giản, rõ ràng	Khó mở rộng, nhạy tham số k
SVM	Hiệu quả với dữ liệu nhiều chiều	Nhạy tham số, khó với dữ liệu lớn
Học sâu (CNN)	Chính xác cao với ảnh y khoa	Cần dữ liệu lớn, tài nguyên mạnh
ANN	Diễn giải cao (LIME), chính xác 95%	Phụ thuộc kiểm định trên dữ liệu ngoài
XGBoost	Hiệu quả dự báo & diễn giải cao, $>97\%$	Khó cấu hình tham số, cần tài nguyên

4. Giới thiệu hai bộ dữ liệu

Bộ dữ liệu	Quy mô	Đặc trưng chính
Dataset 1	5,110 bản ghi; 249 stroke	age, hypertension, heart disease, glucose, BMI, smoking, work type, gender, residence
Dataset 2	5,769,190 bản ghi	Cấu trúc tương tự, dữ liệu tổng hợp quy mô lớn

- Dataset 1: cân bằng bằng **SMOTE**.
- Dataset 2: cân bằng bằng **undersampling**.

5. Pipeline của nghiên cứu

- 1 Làm sạch, missing, outlier, one-hot encoding.
- 2 Chuẩn hóa dữ liệu.
- 3 Cân bằng lớp trên tập train.
- 4 PCA giữ $\geq 95\%$ phương sai.
- 5 XGBoost + tuning hyperparameter.
- 6 Đánh giá: Accuracy, Precision, Recall, F1, ROC-AUC, MCC, Kappa.
- 7 XAI bằng SHAP.

6. PCA: giảm chiều

$$X_c = X - \bar{x}, \quad S = \frac{1}{N-1} X_c^T X_c,$$
$$S v_j = \lambda_j v_j, \quad X_{\text{reduced}} = X_c V_k.$$

- Chọn k sao cho cumulative explained variance đạt 95%.
- Theo bài báo Dataset 1: từ **19** đặc trưng sau xử lý xuống **13** thành phần.
- Jacobi rotation được song song hóa bằng OpenMP (Bảng 3.1): thời gian tuần tự **0.0008801s** $\rightarrow$ OpenMP **0.0006494s**.



7. XGBoost và hàm mục tiêu

$$L(\theta) = \sum_{i=1}^N \ell(y_i, \hat{y}_i(\theta)) + \Omega(\theta)$$



$$\ell(y_i, \hat{y}_i) = -[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)].$$

- Tuning: depth, learning rate, số cây, gamma, min child weight, subsample, colsample.
- Regularization giúp kiểm soát overfitting.
- ROC-AUC là tiêu chí quan trọng khi lựa chọn mô hình.

8. PCA: phương sai giải thích được (D1)



9. Trọng số đặc trưng trong các thành phần chính (D1)





- PC1 chịu ảnh hưởng lớn bởi age, work_type_children, smoking_status_Unknown.
- PC2 chịu ảnh hưởng nhiều nhất bởi gender và work_type_Self-employed.

10. Kết quả Dataset 1 trong bài báo

Bảng 3.4 — so sánh với [21]: (a) chưa cân bằng, (b) đã cân bằng lớp

Chỉ số	[21]	(a)	(b)
Precision (0/1)	0.97 / 0.21	0.95 / 0.24	0.96 / 0.93
Recall (0/1)	0.87 / 0.52	0.97 / 0.15	0.93 / 0.96
F1 (0/1)	0.92 / 0.29	0.96 / 0.18	0.94 / 0.95
Accuracy	0.85	0.92	0.95
Support (0/1)	960/62	960/62	976/968

- 10-fold average accuracy: **0.9532**.
- Confusion matrix: $TN = 908$, $FP = 68$, $FN = 33$, $TP = 935$.
- ROC-AUC: khoảng **0.99** (hình dưới).



11. Kết quả Dataset 2 trong bài báo


Bảng 3.6 — so sánh không PCA vs có PCA:

Chỉ số	Không PCA	Có PCA
Precision (0/1)	0.98 / 0.93	0.99 / 0.97
Recall (0/1)	0.92 / 0.98	0.97 / 0.99
F1 (0/1)	0.95 / 0.96	0.98 / 0.98
Accuracy	0.95	0.98
Support (0/1)	136,758 / 137,596	10,613 / 10,605


- 10-fold CV mean: **0.99028**; MCC: **0.9634**; Cohen's Kappa: **0.9632**.

12. Dataset 2: confusion matrix & ROC-AUC (có/không PCA)

Có PCA



Không PCA



Confusion matrix:

- Có PCA: $TN = 6,901$, $FP = 160$, $FN = 71$, $TP = 7,013$;
- Không PCA: $TN = 6,509$, $FP = 552$, $FN = 105$, $TP = 6,979$.

13. Dataset 2: kiểm định thống kê PCA vs không PCA



Bảng 3.7 — p -value của các kiểm định thống kê

Kiểm định	p -value
Paired t-test	$\approx 5.48 \times 10^{-10}$
Mann–Whitney U test	$\approx 1.80 \times 10^{-4}$

- Cả hai kiểm định đều cho $p < 0.05 \Rightarrow$ tác giả kết luận có khác biệt có ý nghĩa thống kê giữa PCA và baseline.
- Đây là bằng chứng tác giả dùng để khẳng định PCA mang lại cải thiện có ý nghĩa (Chương 5 của nhóm sẽ kiểm chứng lại claim này).

14. SHAP: mô hình dự đoán dựa vào đâu?

- Dataset 1: glucose, work type, BMI, age nổi bật.
- Dataset 2: age và glucose nổi bật nhất.
- Waterfall: giải thích từng quan sát.
- Bar/Beeswarm: giải thích toàn cục.



15. OpenMP và tốc độ

Ma trận	100	200	300	400	500
OpenMP	0.503	5.838	40.043	128.957	363.385
Sequential	0.530	7.747	62.958	218.853	549.275

- Dataset nhỏ: overhead song song hóa làm lợi ích hạn chế.
- Ma trận lớn: khoảng cách thời gian tăng rõ rệt.
- Bảng 3.3 — chi tiết từng giai đoạn: tìm trị riêng **6.25e-05s**, tính hiệp phương sai **0.00260s**, huấn luyện mô hình **1.34685s**.
- Tổng thời gian **1.50010s** so với **4.52611s** ở công trình tham chiếu [21].

16. So sánh với các nghiên cứu khác (Chương 4)

Bảng 4.1 — Dataset 1:

Thuộc tính	[18]	[33]	[34]	Chúng tôi
Phương pháp	LR, cây quyết định, RF, k-NN, SVM, Naive Bayes	RF, XGBoost, hồi quy logistic, mạng nơ-ron	RF, Naive Bayes, hồi quy logistic	XGBoost + PCA + SMOTE
Accuracy (%)	82	92.55	—	95
F1-score	82.3	92.40	80	94.5

- Dataset 2: không có nghiên cứu liên quan để so sánh trực tiếp — đánh giá bổ sung bằng MCC (0.9634) và Cohen's Kappa (0.9632).

17. Tóm lược bài báo gốc — vấn đề cần kiểm chứng

- XGBoost + PCA + XAI là pipeline hợp lý cho bài toán dự đoán đột quy; PCA có thể giảm chiều và tăng tốc, SHAP giúp diễn giải.
 - Tuy nhiên, support trong các bảng so sánh của tác giả thay đổi bất thường giữa các cấu hình — về nguyên tắc, PCA/balancing không thể làm đổi số dòng test:
 - D1: (a) 960/62/1,022 → (b) sau balancing 976/968/**1,944**.
 - D2: without PCA 274,354 → with PCA **21,218**.
- ⇒ Cần một pipeline tái hiện với protocol đánh giá minh bạch để kiểm chứng độc lập các con số này.

18. Thiết kế code tái hiện

- Train/test = 80/20, stratified.
- IQR bounds học từ train rồi áp cho test.
- Sampler nằm trong `imblearn.Pipeline` → tránh leakage.
- So sánh: unbalanced/no-PCA, balanced/no-PCA, balanced/PCA95.
- Xuất tự động: metrics, classification report, confusion matrix, ROC, PCA, loadings, SHAP.

19. Phương thức tái hiện của nhóm

Nguyên tắc đánh giá (Hình 5.1): chia train/test trước → mọi bước imputation, encoding, scaling, PCA, balancing chỉ fit trên train → **test không được resample** → mọi cấu hình đánh giá trên cùng test split.

Dataset	Giai đoạn	Train 0	Train 1	Test (0/1)
D1	Sau split	3,889	199	972 / 50
D1	Sau SMOTE	3,889	3,889	972 / 50
D2	Sau split	4,245,040	188,768	1,061,261 / 47,192
D2	Sau undersampling	188,768	188,768	1,061,261 / 47,192

⇒ **Support của test không đổi** sau balancing — khắc phục đúng vấn đề nêu ở Slide 17 (Bảng 5.1–5.3 của báo cáo).

20. Diễn biến hiệu năng qua các bước xây dựng pipeline

Bảng 5.7 — trên test giữ nguyên phân bố lớp:

D1	Accuracy	Precision	Recall	F1	MCC
Baseline, không PCA	0.9501	0.4286	0.0600	0.1053	0.1462
Balancing+PCA+tuning	0.7818	0.1554	0.7800	0.2591	0.2816

D2	Accuracy	Precision	Recall	F1	MCC
Baseline, không PCA	0.9612	0.9152	0.0986	0.1780	0.2934
Balancing+PCA+tuning	0.9664	0.5590	0.9944	0.7157	0.7322

- Baseline Accuracy cao (0.95) nhưng Recall chỉ 0.06 — mô hình gần như bỏ sót hết ca stroke.
- Chỉ thêm PCA (chưa balancing) làm Recall D1 giảm tiếp (0.0600→0.0400) — PCA không mặc nhiên có lợi (mục 5.5).

21. Mở rộng & tổng hợp trên cùng test set

Nhóm khảo sát thêm SMOTENC, cost-sensitive learning và lựa chọn threshold trên validation (mục 5.6), rồi tổng hợp trên cùng test set (Bảng 5.11):

D1	Accuracy	Precision	Recall	F1	MCC
Tái hiện	0.7818	0.1554	0.7800	0.2591	0.2816
Cải tiến (Weighted+PCA, Spec. 85%)	0.8434	0.1944	0.7000	0.3043	0.3119

D2	Accuracy	Precision	Recall	F1	MCC
Tái hiện	0.9664	0.5590	0.9944	0.7157	0.7322
Cải tiến (Undersampling+PCA)	0.9847	0.7401	0.9886	0.8465	0.8484

- D1: đánh đổi 0.08 Recall để giảm false positive, tăng F1/MCC.
- D2: Precision, F1, MCC, Accuracy đều tăng, Recall chỉ giảm rất nhẹ.

22. Thử nghiệm mở rộng: các họ mô hình khác

Mục 5.9 — CatBoost, LightGBM, Balanced Random Forest, EasyEnsemble, Focal-loss XGBoost trên cùng outer test:

D1	Accuracy	Precision	Recall	F1	MCC
XGBoost cải tiến	0.8434	0.1944	0.7000	0.3043	0.3119
Balanced Random Forest	0.8483	0.2000	0.7000	0.3111	0.3184
CatBoost	0.7867	0.1640	0.8200	0.2733	0.3036

D2	Accuracy	Precision	Recall	F1	MCC
XGBoost+undersampling+PCA	0.9847	0.7401	0.9886	0.8465	0.8484
LightGBM weighted	0.9587	0.5079	0.9926	0.6720	0.6943

- Kết luận mục 5.9.4: **không có họ mô hình nào thắng tuyệt đối** trên mọi dataset — lựa chọn tối ưu phụ thuộc cấu trúc/quy mô dữ liệu.

23. Hạn chế và hướng cải thiện

- Dataset 1 nhỏ, chỉ 50 ca stroke trong test → kết quả nhạy với cách chia train/test.
- Dataset 2 quy mô lớn nhưng là dữ liệu *synthetic* → các chỉ số rất cao cần được diễn giải thận trọng.
- Bài báo gốc không công bố đủ chi tiết (thứ tự chia dữ liệu, resampling, tham số) để tái dựng chính xác toàn bộ protocol.
- Nhóm ưu tiên tính minh bạch và khả năng kiểm chứng của phương thức riêng, thay vì cố điều chỉnh pipeline để ép kết quả khớp số liệu công bố.

24. Kết luận

- Accuracy không đủ để đánh giá mô hình trong bài toán mất cân bằng; cần xem xét đồng thời Recall, F1-score, MCC và ROC-AUC.
- Bài báo gốc chưa mô tả đầy đủ thứ tự chia dữ liệu, resampling, PCA và các tham số thực nghiệm.
- Nhóm xây dựng một protocol minh bạch hơn: chia train/test trước, chỉ thực hiện preprocessing/balancing trên train, giữ nguyên phân bố lớp của test để tránh rò rỉ dữ liệu.
- Kết hợp balancing, PCA, tuning và lựa chọn operating threshold giúp tăng đáng kể khả năng phát hiện lớp stroke.
- D1: Balanced Random Forest cải thiện nhẹ F1-score và MCC so với XGBoost có trọng số. D2: XGBoost kết hợp undersampling và PCA vẫn cho sự cân bằng tốt nhất giữa Precision, Recall, F1-score và MCC; LightGBM đạt Recall cao hơn nhưng Precision thấp hơn.
- Không có một mô hình duy nhất tốt nhất trên mọi bộ dữ liệu — hiệu quả dự đoán phụ thuộc vào protocol đánh giá, phương pháp xử lý mất cân bằng và ngưỡng quyết định.