

Dự đoán nguy cơ đột quỵ bằng XGBoost, PCA và XAI

Tái hiện nghiên cứu Mochurad et al. (2025)

Nhóm thực hiện

Ngày 29 tháng 8 năm 2026

1. Bài toán và động cơ

- Mục tiêu: dự đoán sớm nguy cơ đột quy từ đặc trưng bệnh nhân.
- Khó khăn: **mất cân bằng lớp** (chỉ 4,3–4,9% ca dương tính), missing/outlier, quan hệ phi tuyến, yêu cầu giải thích.
- Hướng của bài báo: **XGBoost + PCA + SHAP**; PCA được tối ưu bằng OpenMP.

Ba tiêu chí chính

Độ chính xác + tốc độ xử lý + khả năng giải thích.

2. Hai bộ dữ liệu

Bộ dữ liệu	Quy mô	Đặc trưng chính
Dataset 1	5.110 bản ghi; 249 stroke (4,87%)	age, hypertension, heart disease, glucose, BMI, smoking, work type, gender, residence
Dataset 2	5.542.261 bản ghi; 235.961 stroke (4,26%)	Cấu trúc tương tự, dữ liệu tổng hợp quy mô lớn

- Chia 80/20 (stratified) cho cả hai tập; sau tiền xử lý (one-hot) đều có **21 đặc trưng đầu vào**.
- Dataset 1: cân bằng bằng **SMOTE**.
- Dataset 2: cân bằng bằng **random undersampling**.

3. Pipeline của nghiên cứu

- 1 Làm sạch, missing, outlier, one-hot encoding.
- 2 Chuẩn hóa dữ liệu.
- 3 Cân bằng lớp trên tập train (trong pipeline, tránh rò rỉ dữ liệu).
- 4 PCA giữ $\geq 95\%$ phương sai (Jacobi + OpenMP).
- 5 XGBoost + tuning hyperparameter (Grid Search, Stratified K-Fold).
- 6 Đánh giá: Accuracy, Precision, Recall, F1, ROC-AUC, MCC, Cohen's Kappa.
- 7 XAI bằng SHAP (Waterfall, Bar, Beeswarm).

4. PCA: giảm chiều

$$X_c = X - \bar{x}, \quad S = \frac{1}{N-1} X_c^T X_c,$$
$$S v_j = \lambda_j v_j, \quad X_{\text{reduced}} = X_c V_k.$$

- Chọn k sao cho cumulative explained variance đạt $\geq 95\%$.
- Theo bài báo: từ **21** đặc trưng sau tiền xử lý xuống còn **11** thành phần chính (cả hai tập dữ liệu).
- Phương sai giải thích đạt **96,90%** (Dataset 1) và **96,96%** (Dataset 2).
- Jacobi rotation được song song hóa bằng OpenMP.


5. XGBoost và hàm mục tiêu

$$L(\theta) = \sum_{i=1}^N \ell(y_i, \hat{y}_i(\theta)) + \Omega(\theta)$$


$$\ell(y_i, \hat{y}_i) = -[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)].$$

- Tuning: depth, learning rate, số cây, gamma, min child weight, subsample, colsample.
- Regularization giúp kiểm soát overfitting.
- ROC-AUC là tiêu chí quan trọng khi lựa chọn mô hình (Grid Search + Stratified K-Fold).

6. Kết quả PCA (Dataset 1)



Phương sai tích lũy theo thành phần




Tỷ lệ phương sai từng thành phần

7. Kết quả Dataset 1 (mô hình cuối cùng, hold-out)

- Accuracy: **78,18%**.
- ROC-AUC (hold-out): **0,8118**.
- 10-fold CV accuracy trung bình: **0,7652**
 $\pm$ **0,0308**.
- Precision/Recall (lớp 1): **0,1554 / 0,7800**;
MCC: **0,2816**.
- Confusion matrix: $TN = 760$, $FP = 212$,
 $FN = 11$, $TP = 39$.

Lưu ý

Precision thấp + recall khá cao là đặc trưng của sàng lọc trên dữ liệu mất cân bằng mạnh (chỉ 50/1.022 mẫu kiểm tra là dương tính).




8. Kết quả Dataset 2

Chỉ số (10-fold CV, accuracy)	Không PCA	Có PCA
Accuracy trung bình	0,9214	0,9654
$p\text{-value (paired t-test)} = 6,44 \times 10^{-15} \Rightarrow \text{PCA cải thiện có ý nghĩa thống kê}$		

- Mô hình cuối (hold-out, $n = 1.108.453$): Accuracy **0,9664**; ROC-AUC **0,9976**.
- MCC: **0,7322**; Cohen's Kappa: **0,6993**.
- Confusion matrix (hold-out): $TN = 1.024.239$, $FP = 37.022$, $FN = 263$, $TP = 46.929$.

9. SHAP: mô hình dự đoán dựa vào đâu?

- Dataset 1: **avg_glucose_level**, **age**, **bmi** nổi bật nhất; work type và giới tính có ảnh hưởng vừa phải.
- Dataset 2: **avg_glucose_level** và **age** nổi bật nhất.
- Waterfall: giải thích từng quan sát cụ thể.
- Bar/Beeswarm: giải thích tầm quan trọng toàn cục.



SHAP Bar – Dataset 1

10. OpenMP và tốc độ (thuật toán Jacobi)

Kích thước ma trận N	100	200	300	400	500
Tuần tự (s)	0,0441	0,2521	0,9019	2,0456	4,0797
OpenMP (s)	0,0731	0,2733	0,8323	1,6355	2,6504
Speedup	0,604	0,923	1,084	1,251	1,539

- $N = 100$ và $N = 200$: OpenMP **chưa** có lợi thế (overhead song song hóa lớn hơn lợi ích).
- Từ $N = 300$ trở đi: OpenMP bắt đầu nhanh hơn, khoảng cách tăng dần theo kích thước ma trận.
- Kết luận: song song hóa chỉ có lợi khi kích thước bài toán đủ lớn, không phải lúc nào cũng nhanh hơn.

11. Thiết kế code tái hiện

- Train/test = 80/20, stratified theo biến mục tiêu.
- IQR bounds học từ train rồi áp cho test (tránh rò rỉ dữ liệu).
- Sampler (SMOTE/undersampling) và PCA nằm trong `imblearn.Pipeline`, chỉ fit trên phần train của mỗi fold.
- So sánh: baseline (không PCA), sau cân bằng lớp + tinh chỉnh siêu tham số, có/không PCA.
- Đánh giá hai bước: kiểm định chéo 10-fold, sau đó một lần hold-out cuối cùng.
- Xuất tự động: metrics, confusion matrix, ROC, PCA (cumulative variance, loadings), SHAP.

12. Kết luận

- XGBoost + PCA + XAI là pipeline hợp lý cho bài toán dự đoán đột quy.
- PCA cải thiện có ý nghĩa thống kê trên Dataset 2 (dữ liệu lớn) nhưng lại làm giảm nhẹ accuracy trên Dataset 1 (dữ liệu nhỏ) – lợi ích phụ thuộc quy mô dữ liệu.
- Accuracy cao có thể gây hiểu lầm trên dữ liệu mất cân bằng mạnh; cần xem cùng Precision, Recall, ROC-AUC, MCC.
- SHAP giúp diễn giải (glucose, tuổi, BMI là yếu tố nổi bật) nhưng không thay thế kiểm định lâm sàng.
- Mục tiêu thực nghiệm: **tái hiện và đối chiếu**, không giả định sẽ khớp tuyệt đối số liệu bài báo gốc.